

Подготовка к контрольной

Семинары 1–4: парная и множественная регрессия,
фиктивные переменные, мультиколлинеарность

Условия задач

1. Теоретические вопросы

Вопрос 1

Что такое смещение оценки $\hat{\beta}$ параметра β ? Какая оценка называется несмещённой и какая — состоятельной? Приведите пример оценки, которая смещена, но состоятельна.

Вопрос 2

Перечислите предпосылки классической линейной регрессионной модели. Сформулируйте теорему Гаусса–Маркова. Что означает, что МНК-оценка — BLUE?

Вопрос 3

Напишите формулу скорректированного коэффициента детерминации и объясните смысловое отличие от обычного R^2 . Сформулируйте информационные критерии Акаике (AIC) и Шварца (BIC): формулы и для чего они используются.

Вопрос 4

По одной и той же выборке оценены регрессии Y на X и X на Y . Совпадут ли линии регрессии?

2. Задачи

Задача 1 (задание 2024/25)

В таблице приведены ежегодные значения денежной массы и национального дохода некоторой гипотетической страны (в миллиардах денежных единиц).

Год	Денежная масса	Нац. доход	Год	Денежная масса	Нац. доход
1981	2,0	5,0	1986	4,0	7,7
1982	2,5	5,5	1987	4,2	8,4
1983	3,2	6,0	1988	4,6	9,0
1984	3,6	7,0	1989	4,8	9,7
1985	3,3	7,2	1990	5,0	10,0

- Оцените регрессию национального дохода (Y) на денежную массу (X) и константу. Обоснуйте вывод основных формул.
- Рассчитайте R^2 модели.

- в) Проверьте значимость коэффициента при денежной массе на уровне 5 %.

Задача 2 (задачник ВШЭ, №2.3.2)

По ежегодным данным за 1975–1988 гг. (14 наблюдений) оценивалась зависимость цены на бензин (*Petrol*, центы за галлон) от цены на сырую нефть (*Oil*, доллары за баррель):

$$\widehat{Petrol}_i = 41,9 + 3,0 Oil_i,$$

(4,6) (0,2)

в скобках — стандартные ошибки. Сумма квадратов остатков ESS = 631,1, TSS = 12622. Предпосылки классической линейной нормальной модели выполнены.

- а) Рассчитайте коэффициент детерминации R^2 .
- б) Проверьте гипотезу о том, что рост цены на нефть на 1 долл. за баррель соответствует росту цены на бензин на 2 цента за галлон, на уровне значимости 10 %.
- в) В 1988 году цена на нефть составила 12,57 доллара за баррель. Какова ожидаемая цена на бензин? Какой должна быть цена на нефть, чтобы ожидаемая цена на бензин составила 100 центов за галлон?

Задача 3 (задачник ВШЭ, №2.3.5)

Рассчитанный по 20 наблюдениям за признаками X и Y выборочный коэффициент корреляции составил 0,5. Есть ли основания считать, что между признаками существует регрессионная зависимость? Сформулируйте основную и альтернативную гипотезы в терминах коэффициентов регрессии; уровень значимости 5 %.

Задача 4 (задачник ВШЭ, №3.1.3)

При оценивании по 40 наблюдениям зависимости $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \varepsilon_i$ получены $R^2 = 0,6$ и TSS = 200. Рассчитайте несмещённую оценку дисперсии случайной составляющей и скорректированный коэффициент детерминации.

Задача 5 (задачник ВШЭ, №3.2.4)

Исследователь оценил регрессию цены поддержанного автомобиля:

$$Цена_i = \beta_1 + \beta_2 Пробег_i + \beta_3 Поломки_i + \beta_4 Иномарка_i + \beta_5 Литраж_i + \beta_6 Длина_i + \varepsilon_i,$$

где $Иномарка_i = 1$ для иномарок и 0 для отечественных машин. Результаты (Model SS — объяснённая сумма квадратов RSS, Residual SS — остаточная ESS):

	SS	df	MS		
Model	176 083 058	5	35 216 611,6	Number of obs	50
Residual	318 894 258	44	7 247 596,78	$F(5, 44)$	4,86
Total	494 977 316	49	10 101 577,9	Prob > F	0,0013
				R^2	0,3557
				Adj R^2	XXXX

	Coef.	Std. Err.	t	P > t	95 % Conf. Interval	
пробег	−321,62	172,21	−1,87	0,068	−668,68	25,44
поломки	−466,65	603,61	−0,77	0,444	−1683,15	749,84
иномарка	5102,07	1749,39	2,92	0,006	XXXX	XXXX
литраж	−196,39	173,67	−1,13	0,264	−546,41	153,62
длина	121,71	54,31	XXXX	0,030	12,27	231,16
const	−7961,16	11653,58	−0,68	0,498	−31447,42	15525,09

- а) Заполните пропуски в таблице (XXXX).
- б) При каких уровнях значимости регрессия в целом значима? Сформулируйте основную и альтернативную гипотезы.
- в) Проверьте значимость коэффициента при переменной «литраж» на уровне 5 %, сформулировав гипотезы.
- г) Исследователь предполагает, что ожидаемая цена иномарки, претерпевшей четыре поломки, совпадает с ценой ни разу не ломавшегося отечественного автомобиля с теми же остальными характеристиками. Сформулируйте эту гипотезу в терминах коэффициентов.

Задача 6 (задачник ВШЭ, №3.2.7)

По 30 наблюдениям оценена регрессия (в скобках — стандартные ошибки):

$$\hat{Y}_i = 23,5 - 0,6 X_{2i} + 1,2 X_{3i} + 0,9 X_{4i} - 0,2 X_{5i}, \quad ESS = 150, \quad R^2 = 0,7,$$

(2,4) (0,2) (0,7) (0,1) (1,2)

ESS — сумма квадратов остатков.

- а) Рассчитайте несмещённую оценку дисперсии случайной составляющей.
- б) Рассчитайте R_{adj}^2 .
- в) При исключении каких переменных R_{adj}^2 увеличится?
- г) Постройте 95 % доверительный интервал для коэффициента при X_2 .
- д) На уровне 5 % проверьте гипотезу о том, что увеличение X_4 на единицу при прочих равных увеличивает Y в среднем на 0,5.
- е) Исследователь оценил дополнительную регрессию $\hat{Y}_i = 28,4 - 0,5(X_{2i} - X_{3i}) + 1,1X_{4i}$. Какую гипотезу он хотел проверить?

Задача 7 (задачник ВШЭ, №3.2.5)

По 25 наблюдениям оценено уравнение регрессии количества проданных бутылок газированной воды Q_i на цену газировки P_i и среднюю температуру дня T_i . В модель включена фиктивная переменная W_i , равная единице для выходных дней и нулю для будних:

$$\hat{Q}_i = 67,5 - 2,4 P_i + 2,1 T_i + 13,7 W_i, \quad R^2 = 0,7,$$

(5,7) (1,0) (1,5) (3,2)

- а) Проверьте значимость регрессии в целом на уровне 1 %.
- б) Какие регрессоры значимо влияют на объём продаж (уровень 5 %)?
- в) Постройте 95 % доверительный интервал для свободного члена.
- г) Пусть вместо W_i в уравнение включена переменная N_i , равная нулю для выходных и единице для будних дней. Как изменится оценённое уравнение?

Задача 8 (задачник ВШЭ, №3.2.10)

По 40 квартальным наблюдениям оценивается зависимость импорта косметики M от ВВП страны-импортёра Y , индекса внутренних цен Pd и индекса импортных цен Pf в логарифмах. Для сезонности введены фиктивные переменные $D2, D3, D4$ (равны единице во 2-м, 3-м и 4-м квартале соответственно). Получены регрессии (ESS — сумма квадратов остатков):

- (1) $\widehat{\ln M} = 7,6 + 0,8 \ln Y + 0,1 \ln Pd - 0,3 \ln Pf - 0,4D2 - 0,2D3 - 0,2D4$, ESS = 0,37;
- (2) $\widehat{\ln M} = 9,3 + 0,6 \ln Y - 0,1(\ln Pf + \ln Pd) - 0,3D2 - 0,1D3 - 0,3D4$, ESS = 0,48;
- (3) $\widehat{\ln M} = 9,0 + 0,6 \ln Y - 0,2(\ln Pf - \ln Pd) - 0,4D2 - 0,0D3 - 0,3D4$, ESS = 0,40;
- (4) $\widehat{\ln M} = 12,9 + 0,3 \ln Pd + 0,1 \ln Pf - 0,2D2 - 0,1D3 - 0,3D4$, ESS = 0,45;
- (5) $\widehat{\ln M} = 9,4 + 0,5 \ln Y - 0,3D2 - 0,2D3 - 0,3D4$, ESS = 0,42;
- (6) $\widehat{\ln M} = 10,1 + 0,4 \ln Y - 0,1 \ln Pd + 0,1 \ln Pf$, ESS = 1,48.

- а) Проверьте наличие сезонных эффектов на уровне 1 %.
- б) На уровне 5 % проверьте гипотезу о том, что коэффициент при $\ln Pd$ равен по модулю и противоположен по знаку коэффициенту при $\ln Pf$, то есть на импорт влияет лишь отношение цен.

Задача 9 (задачник ВШЭ, №3.2.11)

По 55 наблюдениям (30 мужчин и 25 женщин) оценена регрессия почасовой зарплаты $EARN$ на длительность обучения S (годы) и результат ЕГЭ по математике $TEST$ (ESS — сумма квадратов остатков):

Выборка	Оценённое уравнение	TSS	ESS
вся	$\widehat{EARN} = 3744,44 - 35,54 S + 3,59 TEST$	100 000 000	50 000 000
женщины	$\widehat{EARN} = 5664,05 - 114,22 S - 9,05 TEST$	51 000 000	550 000
мужчины	$\widehat{EARN} = 2783,67 + 112,11 S + 13,50 TEST$	48 000 000	870 000

- а) Найдите коэффициенты уравнения, оценённого по всей выборке:

$$\widehat{EARN} = \hat{\beta}_1 + \hat{\beta}_2 S \cdot MALE + \hat{\beta}_3 S \cdot FEMALE + \hat{\beta}_4 FEMALE + \hat{\beta}_5 TEST \cdot MALE + \hat{\beta}_6 TEST,$$

где $MALE = 1$ для мужчин, $FEMALE = 1$ для женщин (и 0 иначе).

- б) Есть ли основания считать, что зависимости для мужчин и для женщин различаются?

Задача 10 (задание 2024/25)

Оценивается модель $Y_t = \alpha + \beta_1 X_{1t} + \beta_2 X_{2t} + \beta_3 X_{3t} + \varepsilon_t$. Для проверки мультиколлинеарности оценены вспомогательные регрессии X_1 на X_2, X_3 ; X_2 на X_1, X_3 ; X_3 на X_1, X_2 с коэффициентами детерминации R_1^2, R_2^2, R_3^2 . Объясните, что такое мультиколлинеарность, и сделайте вывод о её наличии для каждого варианта:

	Вариант 1	Вариант 2	Вариант 3	Вариант 4
R_1^2	0,80	0,10	0,73	0,90
R_2^2	0,25	0,65	0,60	0,65
R_3^2	0,35	0,85	0,20	0,15

Какие есть способы решить проблему мультиколлинеарности?

Задача 11 (задачник ВШЭ, №4.1.3)

По наблюдениям за Y, X_2 и X_3 оценена корреляционная матрица:

	X_2	X_3	Y
X_2	1,0	-0,9	-0,6
X_3	-0,9	1,0	0,7
Y	-0,6	0,7	1,0

Найдите $VIF(\hat{\beta}_3)$ для регрессии $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i$.

Задача 12 (задачник ВШЭ, №4.1.11)

Для уравнения $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \beta_4 X_{4i} + \varepsilon_i$ получены корреляционная матрица регрессоров и значения VIF:

	X_2	X_3	X_4	Переменная	VIF
X_2	1			X_4	2,53
X_3	-0,4934	1		X_3	2,08
X_4	-0,6144	0,9018	1	X_2	1,62

Объясните, почему эти VIF и корреляции не могут относиться к одним и тем же данным.