

Семинар 1

Модель парной регрессии: МНК, линеаризация, проверка гипотез

Условия и решения

1. Основные формулы

1.1. Модель и предпосылки

Модель парной регрессии:

$$Y_t = \alpha + \beta X_t + \varepsilon_t, \quad t = 1, \dots, n, \quad (1)$$

где Y_t — зависимая переменная, X_t — объясняющая переменная (регрессор), ε_t — случайная ошибка. Параметры α и β — истинные значения коэффициентов, то есть неизвестные константы, которые оцениваются по выборке. Прямую $\alpha + \beta X$ называют истинной линией регрессии. Ошибки $\varepsilon_t = Y_t - \alpha - \beta X_t$ — отклонения наблюдений от неё — не наблюдаются.

Предпосылки классической модели (Магнус, с. 39):

- 1) выполнена спецификация (1);
- 2) X_t — детерминированные величины, не все равные между собой;
- 3а) $\mathbb{E}\varepsilon_t = 0$ и $\mathbb{D}(\varepsilon_t) = \sigma^2$ при всех t ;
- 3б) $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ при $t \neq s$;
- 3с) $\varepsilon_t \sim N(0, \sigma^2)$.

Свойства оценок в п. 1.4–1.5 выводятся из предпосылок 1–3б. Нормальность 3с нужна только для распределений статистик в п. 1.6.

Обозначения. Суммы берутся по $t = 1, \dots, n$.

- $\hat{\alpha}, \hat{\beta}$ — оценки параметров, $\hat{Y}_t = \hat{\alpha} + \hat{\beta}X_t$ — подогнанные значения, $e_t = Y_t - \hat{Y}_t$ — остатки. В отличие от ошибок, остатки отсчитываются от оценённой прямой и вычисляются по данным.
- $\bar{X} = \frac{1}{n} \sum X_t$; так же обозначаются средние $\bar{Y}$ и $\bar{\varepsilon}$.
- $x_t = X_t - \bar{X}$, $y_t = Y_t - \bar{Y}$, $\hat{y}_t = \hat{Y}_t - \bar{Y}$ — отклонения от средних.

Свойства математического ожидания и дисперсии. Пусть $Z, Z_1, \dots, Z_n$ — случайные величины, $c, c_1, \dots, c_n$ — константы. Тогда

$$\mathbb{E}\left(\sum c_t Z_t\right) = \sum c_t \mathbb{E}Z_t, \quad (2)$$

$$\mathbb{D}(Z) = \mathbb{E}[(Z - \mathbb{E}Z)^2] = \mathbb{E}[Z^2] - (\mathbb{E}Z)^2, \quad (3)$$

$$\mathbb{D}(c + Z) = \mathbb{D}(Z), \quad \mathbb{D}(cZ) = c^2 \mathbb{D}(Z), \quad \mathbb{D}\left(\sum c_t Z_t\right) = \sum c_t^2 \mathbb{D}(Z_t), \quad (4)$$

где последнее равенство верно для попарно некоррелированных Z_t .

1.2. Метод наименьших квадратов

МНК-оценки $\hat{\alpha}$, $\hat{\beta}$ минимизируют сумму квадратов отклонений наблюдений от прямой:

$$S(a, b) = \sum (Y_t - a - bX_t)^2 \rightarrow \min_{a, b}.$$

Условия первого порядка

$$\frac{\partial S}{\partial a} = -2 \sum (Y_t - a - bX_t) = 0, \quad \frac{\partial S}{\partial b} = -2 \sum (Y_t - a - bX_t)X_t = 0$$

в точке $(\hat{\alpha}, \hat{\beta})$ записываются через остатки и называются *нормальными уравнениями*:

$$\sum e_t = 0, \quad \sum e_t X_t = 0. \quad (5)$$

В развёрнутом виде это система

$$\begin{cases} n\hat{\alpha} + \hat{\beta} \sum X_t = \sum Y_t, \\ \hat{\alpha} \sum X_t + \hat{\beta} \sum X_t^2 = \sum X_t Y_t. \end{cases}$$

Первое уравнение, делённое на n , даёт $\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}$. Подставив его во второе и учитывая $\sum X_t = n\bar{X}$, получаем

$$\hat{\beta} \left(\sum X_t^2 - n\bar{X}^2 \right) = \sum X_t Y_t - n\bar{X}\bar{Y}.$$

Выражения в скобках — суммы в отклонениях:

$$\sum x_t^2 = \sum (X_t - \bar{X})^2 = \sum X_t^2 - 2\bar{X} \sum X_t + n\bar{X}^2 = \sum X_t^2 - n\bar{X}^2,$$

и аналогично $\sum x_t y_t = \sum X_t Y_t - n\bar{X}\bar{Y}$, $\sum y_t^2 = \sum Y_t^2 - n\bar{Y}^2$. Так как $n\bar{X}^2 = (\sum X_t)^2/n$, через исходные суммы

$$\begin{aligned} \sum x_t^2 &= \sum X_t^2 - \frac{(\sum X_t)^2}{n}, & \sum y_t^2 &= \sum Y_t^2 - \frac{(\sum Y_t)^2}{n}, \\ \sum x_t y_t &= \sum X_t Y_t - \frac{\sum X_t \sum Y_t}{n}. \end{aligned} \quad (6)$$

Отсюда МНК-оценки:

$$\hat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2} = \frac{n \sum X_t Y_t - \sum X_t \sum Y_t}{n \sum X_t^2 - (\sum X_t)^2}, \quad \hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X}. \quad (7)$$

Найденная точка — минимум: матрица вторых производных

$$\begin{pmatrix} \partial^2 S / \partial a^2 & \partial^2 S / \partial a \partial b \\ \partial^2 S / \partial a \partial b & \partial^2 S / \partial b^2 \end{pmatrix} = 2 \begin{pmatrix} n & \sum X_t \\ \sum X_t & \sum X_t^2 \end{pmatrix}$$

положительно определена: угловой минор $2n > 0$, определитель $4(n \sum X_t^2 - (\sum X_t)^2) = 4n \sum x_t^2 > 0$ по предпосылке 2.

Алгебраические свойства МНК-оценок:

$$\sum x_t = 0, \quad \hat{y}_t = \hat{\beta}x_t, \quad e_t = y_t - \hat{\beta}x_t, \quad \sum x_t y_t = \hat{\beta} \sum x_t^2. \quad (8)$$

Действительно, $\sum x_t = \sum X_t - n\bar{X} = 0$. Прямая проходит через точку средних, $\bar{Y} = \hat{\alpha} + \hat{\beta}\bar{X}$, поэтому $\hat{y}_t = (\hat{\alpha} + \hat{\beta}X_t) - (\hat{\alpha} + \hat{\beta}\bar{X}) = \hat{\beta}x_t$ и $e_t = (Y_t - \bar{Y}) - (\hat{Y}_t - \bar{Y}) = y_t - \hat{y}_t$. Последнее равенство — это (7).

Замечание. Вывод не зависит от того, какая из переменных объясняющая: в обратной регрессии X на Y наклон равен $\hat{\gamma} = \sum x_t y_t / \sum y_t^2$.

1.3. Разложение суммы квадратов и коэффициент детерминации

В регрессии со свободным членом полный разброс зависимой переменной раскладывается на объяснённую и остаточную части:

$$\underbrace{\sum (Y_t - \bar{Y})^2}_{\text{TSS}} = \underbrace{\sum (\hat{Y}_t - \bar{Y})^2}_{\text{RSS}} + \underbrace{\sum (Y_t - \hat{Y}_t)^2}_{\text{ESS}}. \quad (9)$$

Здесь TSS (total sum of squares) — полная сумма квадратов, RSS (regression sum of squares) — объяснённая регрессией, ESS (error sum of squares) — остаточная, $\text{ESS} = \sum e_t^2$.

Доказательство. По (8) все три суммы выражаются через отклонения:

$$\begin{aligned} \text{TSS} &= \sum y_t^2, & \text{RSS} &= \sum \hat{y}_t^2 = \hat{\beta}^2 \sum x_t^2, \\ \text{ESS} &= \sum e_t^2 = \sum y_t^2 - \hat{\beta}^2 \sum x_t^2, \end{aligned} \quad (10)$$

где последнее равенство получается раскрытием квадрата:

$$\begin{aligned} \sum (y_t - \hat{\beta} x_t)^2 &= \sum y_t^2 - 2\hat{\beta} \sum x_t y_t + \hat{\beta}^2 \sum x_t^2 \\ &= \sum y_t^2 - 2\hat{\beta}^2 \sum x_t^2 + \hat{\beta}^2 \sum x_t^2 = \sum y_t^2 - \hat{\beta}^2 \sum x_t^2. \end{aligned}$$

Сумма RSS и ESS из (10) равна TSS. Свойства (8), на которые опирается доказательство, следуют из *обоих* нормальных уравнений. В регрессии без свободного члена уравнения $\sum e_t = 0$ нет, и тождество (9), вообще говоря, не выполняется (задача 2.8). ■

Замечание. Обозначения RSS и ESS в литературе не унифицированы. Мы следуем сборнику РАНХиГС: RSS — объяснённая (*regression*), ESS — остаточная (*error*) сумма квадратов. В англоязычных учебниках (*Greene, Wooldridge, Stock–Watson*) те же буквы часто означают обратное: ESS — *explained*, RSS — *residual*. Ориентируйтесь не на аббревиатуру, а на формулу.

Коэффициент детерминации — доля полного разброса, объяснённая регрессией. Так как $\text{RSS}, \text{ESS} \geq 0$,

$$R^2 = \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\text{ESS}}{\text{TSS}}, \quad 0 \leq R^2 \leq 1. \quad (11)$$

Подставив (10) и $\hat{\beta}$ из (7), получаем

$$R^2 = \frac{\hat{\beta}^2 \sum x_t^2}{\sum y_t^2} = \left(\frac{\sum x_t y_t}{\sum x_t^2} \right)^2 \frac{\sum x_t^2}{\sum y_t^2} = \frac{(\sum x_t y_t)^2}{\sum x_t^2 \sum y_t^2}. \quad (12)$$

Выборочные характеристики (Магнус, приложение MC, п. 6):

$$s_X^2 = \frac{\sum x_t^2}{n-1}, \quad s_Y^2 = \frac{\sum y_t^2}{n-1}, \quad c_{XY} = \frac{\sum x_t y_t}{n-1}, \quad r_{XY} = \frac{c_{XY}}{s_X s_Y}. \quad (13)$$

Множители $1/(n-1)$ в r_{XY}^2 сокращаются, и по (12)

$$r_{XY}^2 = \frac{c_{XY}^2}{s_X^2 s_Y^2} = \frac{(\sum x_t y_t)^2}{\sum x_t^2 \sum y_t^2} = R^2.$$

Средняя ошибка аппроксимации — среднее относительное отклонение подогнанных значений от наблюдаемых:

$$\bar{A} = \frac{1}{n} \sum \left| \frac{Y_t - \hat{Y}_t}{Y_t} \right| \cdot 100\%. \quad (14)$$

1.4. Статистические свойства оценки наклона

Вычтем из модели (1) её среднее по наблюдениям, $\bar{Y} = \alpha + \beta \bar{X} + \bar{\varepsilon}$:

$$y_t = (\alpha + \beta X_t + \varepsilon_t) - (\alpha + \beta \bar{X} + \bar{\varepsilon}) = \beta x_t + \varepsilon_t - \bar{\varepsilon}. \quad (15)$$

Подставив это в (7) и учитывая $\sum x_t = 0$, выразим оценку через ошибки:

$$\begin{aligned} \hat{\beta} &= \frac{\sum x_t y_t}{\sum x_t^2} = \frac{\sum x_t (\beta x_t + \varepsilon_t - \bar{\varepsilon})}{\sum x_t^2} = \frac{\beta \sum x_t^2 + \sum x_t \varepsilon_t - \bar{\varepsilon} \sum x_t}{\sum x_t^2} \\ &= \beta + \frac{\sum x_t \varepsilon_t}{\sum x_t^2}. \end{aligned} \quad (16)$$

Веса $x_t / \sum x_t^2$ неслучайны (предпосылка 2). Поэтому по (2) и предпосылке 3а оценка несмещённая:

$$\mathbb{E} \hat{\beta} = \beta + \frac{\sum x_t \mathbb{E} \varepsilon_t}{\sum x_t^2} = \beta, \quad (17)$$

а по (4) и предпосылкам 3а, 3б её дисперсия равна

$$\begin{aligned} \mathbb{D}(\hat{\beta}) &= \mathbb{D}\left(\beta + \frac{\sum x_t \varepsilon_t}{\sum x_t^2}\right) = \mathbb{D}\left(\frac{\sum x_t \varepsilon_t}{\sum x_t^2}\right) = \frac{1}{(\sum x_t^2)^2} \sum x_t^2 \mathbb{D}(\varepsilon_t) \\ &= \frac{\sigma^2 \sum x_t^2}{(\sum x_t^2)^2} = \frac{\sigma^2}{\sum x_t^2}. \end{aligned} \quad (18)$$

Точность оценки наклона тем выше, чем больше разброс регрессора $\sum x_t^2$.

1.5. Оценка дисперсии ошибок

Дисперсия (18) содержит неизвестный параметр σ^2 . Будь ошибки ε_t наблюдаемы, его несмещённой оценкой была бы $\frac{1}{n} \sum \varepsilon_t^2$. Остатки же систематически меньше ошибок: МНК-прямая минимизирует сумму квадратов среди всех прямых и потому даёт не большую сумму, чем истинная прямая $\alpha + \beta X$:

$$\sum e_t^2 = \min_{a,b} \sum (Y_t - a - bX_t)^2 \leq \sum (Y_t - \alpha - \beta X_t)^2 = \sum \varepsilon_t^2.$$

Поэтому делитель n дал бы оценку, смещённую вниз. Найдём смещение точно.

Лемма. При предпосылках 3а, 3б

$$\mathbb{E} \sum (\varepsilon_t - \bar{\varepsilon})^2 = (n-1)\sigma^2. \quad (19)$$

Доказательство. Раскроем квадрат, учитывая $\sum \varepsilon_t = n\bar{\varepsilon}$:

$$\sum (\varepsilon_t - \bar{\varepsilon})^2 = \sum \varepsilon_t^2 - 2\bar{\varepsilon} \sum \varepsilon_t + n\bar{\varepsilon}^2 = \sum \varepsilon_t^2 - 2n\bar{\varepsilon}^2 + n\bar{\varepsilon}^2 = \sum \varepsilon_t^2 - n\bar{\varepsilon}^2.$$

Так как $\mathbb{E}\varepsilon_t = \mathbb{E}\bar{\varepsilon} = 0$, по (3) и (4)

$$\mathbb{E}[\varepsilon_t^2] = \mathbb{D}(\varepsilon_t) = \sigma^2, \quad \mathbb{E}[\bar{\varepsilon}^2] = \mathbb{D}\left(\frac{1}{n} \sum \varepsilon_t\right) = \frac{1}{n^2} \sum \mathbb{D}(\varepsilon_t) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n},$$

откуда

$$\mathbb{E} \sum (\varepsilon_t - \bar{\varepsilon})^2 = \sum \mathbb{E}[\varepsilon_t^2] - n \mathbb{E}[\bar{\varepsilon}^2] = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2. \quad \blacksquare$$

Теорема. При предпосылках 1–3b

$$\mathbb{E} \sum e_t^2 = (n-2)\sigma^2,$$

поэтому несмещёнными оценками σ^2 и $\mathbb{D}(\hat{\beta})$ служат

$$s^2 = \frac{1}{n-2} \sum e_t^2, \quad s_{\hat{\beta}}^2 = \frac{s^2}{\sum x_t^2}. \quad (20)$$

Величина $s_{\hat{\beta}}$ называется стандартной ошибкой оценки $\hat{\beta}$.

Доказательство. Возьмём математическое ожидание от ESS в форме (10); x_t случайны:

$$\mathbb{E} \sum e_t^2 = \mathbb{E} \sum y_t^2 - \mathbb{E}[\hat{\beta}^2] \sum x_t^2.$$

Первое слагаемое найдём по (15). Перекрёстный член равен нулю, так как $\mathbb{E}(\varepsilon_t - \bar{\varepsilon}) = 0$, а последний член даёт лемма (19):

$$\begin{aligned} \mathbb{E} \sum y_t^2 &= \mathbb{E} \sum (\beta x_t + \varepsilon_t - \bar{\varepsilon})^2 = \beta^2 \sum x_t^2 + 2\beta \sum x_t \mathbb{E}(\varepsilon_t - \bar{\varepsilon}) + \mathbb{E} \sum (\varepsilon_t - \bar{\varepsilon})^2 \\ &= \beta^2 \sum x_t^2 + (n-1)\sigma^2. \end{aligned}$$

Второе слагаемое — по (3), (17) и (18):

$$\mathbb{E}[\hat{\beta}^2] \sum x_t^2 = \left(\mathbb{D}(\hat{\beta}) + (\mathbb{E}\hat{\beta})^2 \right) \sum x_t^2 = \left(\frac{\sigma^2}{\sum x_t^2} + \beta^2 \right) \sum x_t^2 = \sigma^2 + \beta^2 \sum x_t^2.$$

Следовательно,

$$\mathbb{E} \sum e_t^2 = \beta^2 \sum x_t^2 + (n-1)\sigma^2 - \sigma^2 - \beta^2 \sum x_t^2 = (n-2)\sigma^2,$$

откуда $\mathbb{E}[s^2] = \sigma^2$ и $\mathbb{E}[s_{\hat{\beta}}^2] = \sigma^2 / \sum x_t^2 = \mathbb{D}(\hat{\beta})$. $\blacksquare$

Число $n-2$ — это число *степеней свободы* остатков: нормальные уравнения (5) накладывают на n остатков две линейные связи, и свободно меняться могут лишь $n-2$ из них. Общее правило: делитель равен n минус число оценённых коэффициентов. Для выборочной дисперсии оценивается одно среднее, и, как показывает лемма, делитель равен $n-1$. В регрессии с k регрессорами и свободным членом он равен $n-k-1$.

Замечание. Проверка формулы для s^2 : при $n = 2$ прямая проходит ровно через две точки, все остатки равны нулю, и делитель n дал бы $s^2 = 0$. Но две точки не несут информации о σ^2 , и формула с $n - 2$ честно даёт $0/0$.

1.6. Проверка гипотез

Распределения Стьюдента и Фишера. Если $Z \sim N(0, 1)$ и $V \sim \chi^2(k)$ независимы, то

$$\frac{Z}{\sqrt{V/k}} \sim t(k), \quad \frac{Z^2}{V/k} \sim F(1, k). \quad (21)$$

Распределение t -статистики. При предпосылке 3с оценка (16) — линейная комбинация нормальных ошибок, поэтому с учётом (17) и (18)

$$\hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum x_t^2}\right), \quad Z = \frac{\hat{\beta} - \beta}{\sigma / \sqrt{\sum x_t^2}} \sim N(0, 1).$$

Кроме того, можно показать, что $V = (n-2)s^2/\sigma^2 \sim \chi^2(n-2)$ и не зависит от $\hat{\beta}$. Подставив Z и V в (21) с $k = n - 2$, получаем статистику, в которой неизвестное σ сокращается:

$$\frac{Z}{\sqrt{V/(n-2)}} = \frac{(\hat{\beta} - \beta)\sqrt{\sum x_t^2}/\sigma}{s/\sigma} = \frac{\hat{\beta} - \beta}{s/\sqrt{\sum x_t^2}} = \frac{\hat{\beta} - \beta}{s_{\hat{\beta}}} \sim t(n-2). \quad (22)$$

Замена σ на s добавляет случайность в знаменатель, поэтому распределение — Стьюдента, а не нормальное, с тем же числом степеней свободы $n - 2$, что и у s^2 .

t -тест. Гипотеза $H_0: \beta = \beta_0$ проверяется статистикой

$$t = \frac{\hat{\beta} - \beta_0}{s_{\hat{\beta}}}, \quad (23)$$

которая при H_0 по (22) имеет распределение $t(n-2)$. Гипотеза отвергается, если $|t| > t_{кр}$; на 5 %-ном уровне значимости $t_{кр} = t_{0,025}(n-2)$.

F -тест значимости регрессии. Гипотеза $H_0: \beta = 0$ проверяется статистикой

$$F = \frac{RSS}{ESS/(n-2)} = \frac{R^2}{1 - R^2} (n-2), \quad (24)$$

где второе равенство получено делением числителя и знаменателя на TSS. По (10) и (20)

$$F = \frac{\hat{\beta}^2 \sum x_t^2}{s^2} = \left(\frac{\hat{\beta}}{s_{\hat{\beta}}}\right)^2 = t^2,$$

где t — статистика (23) при $\beta_0 = 0$. Поэтому при H_0 по (21) $F \sim F(1, n-2)$, и в парной регрессии F -тест равносильен t -тесту гипотезы $\beta = 0$. Гипотеза отвергается, если $F > F_{кр}(1, n-2)$. В регрессии с m регрессорами

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - m - 1}{m} \sim F(m, n - m - 1).$$

1.7. Линеаризация нелинейных моделей

Формулы п. 1.2–1.6 применимы к любой модели, которую заменой переменных и параметров можно привести к виду (1), то есть к модели, *линейной по параметрам* и с *аддитивной* ошибкой. Нелинейность по переменным этому не мешает. Модели с мультипликативной ошибкой $\varepsilon_t > 0$ линеаризуются логарифмированием:

Модель	После логарифмирования	Регрессия
степенная $Y = aX^b\varepsilon$	$\ln Y = \ln a + b \ln X + \ln \varepsilon$	$\ln Y$ на $\ln X$
показательная $Y = ab^X\varepsilon$	$\ln Y = \ln a + X \ln b + \ln \varepsilon$	$\ln Y$ на X
экспоненциальная $Y = ae^{bX}\varepsilon$	$\ln Y = \ln a + bX + \ln \varepsilon$	$\ln Y$ на X

Исходные параметры находят обратным преобразованием оценок: если C — оценка свободного члена, то $a = e^C$, а при десятичных логарифмах $a = 10^C$. Показатель b степенной модели — эластичность: рост X на 1 % меняет Y в среднем на b %.

Если ошибка входит аддитивно, $Y = f(X) + \varepsilon$, логарифм суммы не расщепляется, и модель не линеаризуется, даже когда сама функция f приводится к линейному виду.

Качество нелинейной модели оценивают по исходной переменной: подогнанные значения $\hat{Y}_t$ получают обратным преобразованием, а индекс детерминации $\rho^2 = 1 - \text{ESS}/\text{TSS}$ с $\text{ESS} = \sum (Y_t - \hat{Y}_t)^2$ и ошибку $\bar{A}$ считают по (11) и (14).

2. Задачи

Задача 2.1

Наблюдения 16 пар (X, Y) дали следующие результаты:

$$\begin{aligned} \sum Y^2 &= 526, & \sum X^2 &= 657, & \sum XY &= 492, \\ \sum Y &= 64, & \sum X &= 96. \end{aligned}$$

Оцените регрессию $Y_t = \alpha + \beta X_t + \varepsilon_t$ и проверьте гипотезу, что коэффициент β равен 1,0.

Решение. 1) **Суммы в отклонениях.** Здесь $n = 16$, $\bar{X} = 96/16 = 6$, $\bar{Y} = 64/16 = 4$. По (6)

$$\begin{aligned} \sum x_t^2 &= 657 - \frac{96^2}{16} = 657 - 576 = 81, \\ \sum x_t y_t &= 492 - \frac{96 \cdot 64}{16} = 492 - 384 = 108, \\ \sum y_t^2 &= 526 - \frac{64^2}{16} = 526 - 256 = 270. \end{aligned}$$

2) **Оценки параметров.** По (7)

$$\hat{\beta} = \frac{108}{81} = \frac{4}{3} \approx 1,33, \quad \hat{\alpha} = 4 - \frac{4}{3} \cdot 6 = -4.$$

3) **Оценка дисперсии ошибок.** По (10) и (20)

$$\sum e_t^2 = 270 - \left(\frac{4}{3}\right)^2 \cdot 81 = 270 - 144 = 126, \quad s^2 = \frac{126}{14} = 9,$$

$$s_{\hat{\beta}}^2 = \frac{9}{81} = \frac{1}{9}, \quad s_{\hat{\beta}} = \frac{1}{3}.$$

4) Проверка гипотезы $H_0: \beta = 1$. По (23)

$$t = \frac{4/3 - 1}{1/3} = 1.$$

Критическое значение $t_{0,025}(14) = 2,145$. Так как $|t| = 1 < 2,145$, гипотеза H_0 **не отвергается** на 5 %-ном уровне значимости.

Задача 2.3

Пусть $\hat{\beta}$ — оценка коэффициента наклона в регрессии Y на X , а $\hat{\gamma}$ — оценка коэффициента наклона в регрессии X на Y . Покажите, что $\hat{\beta} = 1/\hat{\gamma}$ тогда и только тогда, когда $R^2 = 1$.

Решение. По (7) и замечанию в п. 1.2

$$\hat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2}, \quad \hat{\gamma} = \frac{\sum x_t y_t}{\sum y_t^2},$$

откуда по (12)

$$\hat{\beta} \hat{\gamma} = \frac{(\sum x_t y_t)^2}{\sum x_t^2 \sum y_t^2} = R^2.$$

Следовательно, $\hat{\beta} = 1/\hat{\gamma} \iff \hat{\beta} \hat{\gamma} = 1 \iff R^2 = 1$.

Геометрический смысл. $R^2 = 1$ означает $ESS = 0$, то есть все точки (X_t, Y_t) лежат на одной прямой. Только в этом случае прямые регрессий Y на X и X на Y совпадают; в остальных случаях $\hat{\beta} \hat{\gamma} = R^2 < 1$.

Задача 2.5

Могут ли следующие уравнения быть преобразованы в уравнения, линейные по параметрам?

- а) $Y_i = \alpha \cdot \exp(\beta X_i) \cdot \varepsilon_i$;
- б) $Y_i = \alpha \cdot \exp(-\beta X_i) + \varepsilon_i$;
- в) $Y_i = \exp(\alpha + \beta X_i + \varepsilon_i)$;
- г) $Y_i = \alpha / (\beta - X_i) + \varepsilon_i$.

Решение. По п. 1.7 модель линеаризуется, если после преобразования она линейна по параметрам и ошибка в ней аддитивна.

а) Да. Логарифмируя (при $\varepsilon_i > 0$), получаем

$$\ln Y_i = \ln \alpha + \beta X_i + \ln \varepsilon_i,$$

то есть $Z_i = \gamma + \beta X_i + u_i$, где $Z_i = \ln Y_i$, $\gamma = \ln \alpha$, $u_i = \ln \varepsilon_i$.

в) Да: $\ln Y_i = \alpha + \beta X_i + \varepsilon_i$, то есть $Z_i = \alpha + \beta X_i + \varepsilon_i$, где $Z_i = \ln Y_i$.

б), г) Нет: ошибка входит аддитивно. Сами функции линеаризуются,

$$\ln(\alpha e^{-\beta X_i}) = \ln \alpha - \beta X_i, \quad \frac{1}{\alpha/(\beta - X_i)} = \frac{\beta}{\alpha} - \frac{1}{\alpha} X_i,$$

но после добавления ε_i эти преобразования не дают модели, линейной по параметрам с аддитивной ошибкой.

Задача 2.6

Зависимая переменная в регрессии $Y_t = \alpha + \beta X_t + \varepsilon_t$ разбивается на две компоненты: $Y_t = Y_{1t} + Y_{2t}$. Рассмотрим две регрессии для компонент:

$$Y_{1t} = \alpha_1 + \beta_1 X_t + \varepsilon_{1t}, \quad Y_{2t} = \alpha_2 + \beta_2 X_t + \varepsilon_{2t}.$$

Докажите следующие соотношения для МНК-оценок параметров трёх регрессий:

$$\hat{\alpha} = \hat{\alpha}_1 + \hat{\alpha}_2, \quad \hat{\beta} = \hat{\beta}_1 + \hat{\beta}_2.$$

Решение. Так как $\bar{Y} = \bar{Y}_1 + \bar{Y}_2$, отклонения тоже складываются: $y_t = y_{1t} + y_{2t}$. По (7)

$$\hat{\beta} = \frac{\sum x_t (y_{1t} + y_{2t})}{\sum x_t^2} = \frac{\sum x_t y_{1t}}{\sum x_t^2} + \frac{\sum x_t y_{2t}}{\sum x_t^2} = \hat{\beta}_1 + \hat{\beta}_2,$$

$$\begin{aligned} \hat{\alpha} &= \bar{Y} - \hat{\beta} \bar{X} = (\bar{Y}_1 + \bar{Y}_2) - (\hat{\beta}_1 + \hat{\beta}_2) \bar{X} \\ &= (\bar{Y}_1 - \hat{\beta}_1 \bar{X}) + (\bar{Y}_2 - \hat{\beta}_2 \bar{X}) = \hat{\alpha}_1 + \hat{\alpha}_2. \end{aligned}$$

Задача 2.12

Рассмотрим модель регрессии на константу

$$Y_t = \alpha + \varepsilon_t, \quad t = 1, \dots, n.$$

а) Найдите оценки метода наименьших квадратов для α и σ^2 .

б) Найдите дисперсию оценки $\hat{\alpha}$.

в) Покажите, что статистика $\frac{\hat{\alpha} - \alpha}{s_{\hat{\alpha}}}$ имеет распределение $t(n-1)$.

г) Чему равен коэффициент детерминации R^2 ?

Решение. а) Минимизируем $S(a) = \sum (Y_t - a)^2$:

$$S'(a) = -2 \sum (Y_t - a) = 0 \implies \hat{\alpha} = \frac{1}{n} \sum Y_t = \bar{Y};$$

это минимум, так как $S''(a) = 2n > 0$. Остатки

$$e_t = Y_t - \bar{Y} = (\alpha + \varepsilon_t) - (\alpha + \bar{\varepsilon}) = \varepsilon_t - \bar{\varepsilon},$$

поэтому по лемме (19) $\mathbb{E} \sum e_t^2 = (n-1)\sigma^2$, и несмещённая оценка σ^2 равна

$$s^2 = \frac{1}{n-1} \sum e_t^2 = \frac{1}{n-1} \sum (Y_t - \bar{Y})^2.$$

б) По (4), так как $\mathbb{D}(Y_t) = \mathbb{D}(\alpha + \varepsilon_t) = \sigma^2$ и Y_t некоррелированы,

$$\mathbb{D}(\hat{\alpha}) = \mathbb{D}\left(\frac{1}{n} \sum Y_t\right) = \frac{1}{n^2} \sum \mathbb{D}(Y_t) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}, \quad s_{\hat{\alpha}}^2 = \frac{s^2}{n}.$$

в) При предпосылке 3с

$$\hat{\alpha} = \alpha + \bar{\varepsilon} \sim N\left(\alpha, \frac{\sigma^2}{n}\right), \quad Z = \frac{(\hat{\alpha} - \alpha)\sqrt{n}}{\sigma} \sim N(0, 1).$$

Для нормальной выборки $V = (n-1)s^2/\sigma^2 \sim \chi^2(n-1)$ и не зависит от $\bar{Y}$ (теорема Фишера). По (21) с $k = n-1$

$$\frac{Z}{\sqrt{V/(n-1)}} = \frac{(\hat{\alpha} - \alpha)\sqrt{n}/\sigma}{s/\sigma} = \frac{\hat{\alpha} - \alpha}{s/\sqrt{n}} = \frac{\hat{\alpha} - \alpha}{s_{\hat{\alpha}}} \sim t(n-1).$$

г) Подогнанные значения постоянны, $\hat{Y}_t = \hat{\alpha} = \bar{Y}$, поэтому $\text{RSS} = \sum (\hat{Y}_t - \bar{Y})^2 = 0$ и по (11) $R^2 = 0$.

Задача 2.2

Покажите, что $\hat{\beta} = r_{XY} \frac{s_Y}{s_X}$, где r_{XY} — выборочный коэффициент корреляции между X и Y , а s_X, s_Y — стандартные отклонения X и Y соответственно.

Решение. По определениям (13) и формуле (7)

$$r_{XY} \frac{s_Y}{s_X} = \frac{c_{XY}}{s_X s_Y} \cdot \frac{s_Y}{s_X} = \frac{c_{XY}}{s_X^2} = \frac{\sum x_t y_t / (n-1)}{\sum x_t^2 / (n-1)} = \frac{\sum x_t y_t}{\sum x_t^2} = \hat{\beta}.$$

Задача 2.8

Выведите непосредственно формулу для оценки коэффициента наклона в регрессии без свободного члена, т. е. найдите оценку параметра β в регрессии

$$Y_t = \beta X_t + \varepsilon_t$$

минимизацией суммы квадратов отклонений $\sum (Y_t - \hat{Y}_t)^2$.

Решение. Минимизируем

$$S(b) = \sum (Y_t - bX_t)^2.$$

Условие первого порядка

$$S'(b) = -2 \sum (Y_t - bX_t) X_t = 0$$

даёт МНК-оценку

$$\hat{\beta} = \frac{\sum X_t Y_t}{\sum X_t^2}$$

Это минимум, так как $S''(b) = 2 \sum X_t^2 > 0$.

Свойства оценки выводятся так же, как в п. 1.4, с X_t вместо x_t . Подставим $Y_t = \beta X_t + \varepsilon_t$:

$$\hat{\beta} = \frac{\sum X_t (\beta X_t + \varepsilon_t)}{\sum X_t^2} = \frac{\beta \sum X_t^2 + \sum X_t \varepsilon_t}{\sum X_t^2} = \beta + \frac{\sum X_t \varepsilon_t}{\sum X_t^2}.$$

Веса $X_t / \sum X_t^2$ неслучайны, поэтому по (2) и предпосылке 3а $\mathbb{E} \hat{\beta} = \beta$, а по (4) и предпосылкам 3а, 3б

$$\begin{aligned} \mathbb{D}(\hat{\beta}) &= \mathbb{D}\left(\beta + \frac{\sum X_t \varepsilon_t}{\sum X_t^2}\right) = \frac{1}{(\sum X_t^2)^2} \mathbb{D}\left(\sum X_t \varepsilon_t\right) = \frac{1}{(\sum X_t^2)^2} \sum X_t^2 \mathbb{D}(\varepsilon_t) \\ &= \frac{\sigma^2 \sum X_t^2}{(\sum X_t^2)^2} = \frac{\sigma^2}{\sum X_t^2}. \end{aligned}$$

Условие первого порядка здесь — единственное нормальное уравнение $\sum \varepsilon_t X_t = 0$. Уравнения $\sum \varepsilon_t = 0$ нет, так как нет свободного члена, поэтому доказательство тождества (9) из п. 1.3 не проходит, и в общем случае $TSS \neq RSS + ESS$. Это понадобится в задаче 2.9 на следующем семинаре.

3. Дополнительная задача

Замечание. Источник отличается от основного сборника:

lib.uni Yar.ac.ru/edocs/iuni/20040802.pdf, «Часть 2. Решение типовых задач», задача 1.

Задача на нелинейные модели

По семи территориям Уральского региона за 2002 год известны значения двух признаков:

- y — расходы на покупку продовольственных товаров в общих расходах, %;
- x — среднедневная заработная плата одного работающего, руб.

Номер	Район	y	x
1	Удмуртская респ.	68,8	45,1
2	Свердловская обл.	61,2	59,0
3	Башкортостан	59,9	57,2
4	Челябинская обл.	56,7	61,8
5	Пермская обл.	55,0	58,8
6	Курганская обл.	54,3	47,2
7	Оренбургская обл.	49,3	55,2

Задание.

- Для характеристики зависимости y от x рассчитать параметры следующих функций:
1) линейной; 2) степенной; 3) показательной.
- Оценить каждую модель через коэффициент детерминации R^2 , среднюю ошибку аппроксимации $\bar{A}$ и F -критерий Фишера.

Решение. Вспомогательные величины:

$$n = 7, \quad \bar{y} = 57,89, \quad \bar{x} = 54,90, \quad \overline{yx} = 3166,05, \quad \sigma_y = 5,74, \quad \sigma_x = 5,86.$$

Здесь $\overline{yx} = \frac{1}{n} \sum y_t x_t$, а σ — стандартные отклонения с делителем n . Промежуточные величины округлены; оценки рассчитаны по неокруглённым данным.

1) Линейная модель $\hat{y} = a + bx$. Формула для b — это (7), в которой числитель и знаменатель поделены на n :

$$b = \frac{\overline{yx} - \bar{y} \cdot \bar{x}}{\sigma_x^2} \approx -0,346, \quad a = \bar{y} - b \bar{x} \approx 76,88,$$

$$\hat{y} = 76,88 - 0,346x.$$

С ростом среднедневной заработной платы на 1 руб. доля расходов на покупку продовольственных товаров снижается в среднем на 0,35 процентного пункта. По задаче 2.2, п. 1.3 и (14)

$$r_{xy} = b \frac{\sigma_x}{\sigma_y} \approx -0,353, \quad R^2 = r_{xy}^2 \approx 0,125, \quad \bar{A} = 8,1\%.$$

Связь умеренная и обратная; вариацией x объясняется 12,5 % вариации y .

2) Степенная модель $\hat{y} = a x^b$. Логарифмируя по п. 1.7, получаем $\lg y = \lg a + b \lg x$, то есть $Y = C + bX$, где $Y = \lg y$, $X = \lg x$, $C = \lg a$. По логарифмам данных ($\bar{Y} = 1,7605$, $\bar{X} = 1,7370$, $\overline{YX} = 3,0572$, $\sigma_X = 0,0484$)

$$b = \frac{\overline{YX} - \bar{Y} \cdot \bar{X}}{\sigma_X^2} \approx -0,298, \quad C = \bar{Y} - b \bar{X} \approx 2,279,$$

$$\hat{y} = 10^{2,279} x^{-0,298} \approx 190,0 x^{-0,298}.$$

Рост заработной платы на 1 % снижает долю расходов на продовольствие в среднем на 0,298 %. По исходной переменной

$$\rho^2 = 1 - \frac{\sigma_{\text{ост}}^2}{\sigma_y^2} = 1 - \frac{28,32}{32,92} \approx 0,140, \quad \bar{A} = 8,0\%,$$

то есть степенная модель описывает связь несколько лучше линейной.

3) Показательная модель $\hat{y} = a b^x$. Логарифмируя по п. 1.7, получаем $\lg y = \lg a + x \lg b$, то есть $Y = C + Bx$, где $Y = \lg y$, $C = \lg a$, $B = \lg b$. По тем же формулам для пар (x_t, Y_t)

$$B \approx -0,00232, \quad C = \bar{Y} - B \bar{x} \approx 1,8878,$$

$$\hat{y} = 10^{1,8878} \cdot (10^{-0,00232})^x \approx 77,24 \cdot 0,9947^x.$$

Рост заработной платы на 1 руб. уменьшает долю расходов на продовольствие в среднем в 0,9947 раза, то есть на 0,53 %. По исходной переменной $\rho^2 \approx 0,125$, $\bar{A} = 8,1\%$.

Сводка и F -критерий. По (24) при $n = 7$ статистика равна $F = 5R^2/(1 - R^2)$, критические значения $F_{\text{кр}}(1, 5) = 6,61$ на уровне 5 % и 16,26 на уровне 1 %.

Модель	R^2 (или ρ^2)	$\bar{A}$	$F_{\text{факт}}$
Линейная	0,125	8,1 %	0,71
Степенная	0,140	8,0 %	0,81
Показательная	0,125	8,1 %	0,71

Во всех трёх случаях $F_{\text{факт}} < F_{\text{кр}} = 6,61$, поэтому гипотеза H_0 о статистической незначимости уравнения **не отвергается**: ни одна из моделей не значима на 5 %-ном уровне. Формально лучшая из трёх — степенная (наибольший ρ^2 , наименьшая $\bar{A}$), но её преимущество в пределах погрешности. Причина — слабая связь и очень малое число наблюдений ($n = 7$).

Замечание. В исходном пособии в разборе линейной модели написано, что $F_{\text{факт}} > F_{\text{кр}}$ при $\alpha = 5\%$ и «гипотеза H_0 не принимается, что говорит о значимости уравнения регрессии в целом». Это ошибка: там же приведено $F_{\text{факт}} = 0,714$, а $F_{\text{кр}} = 6,61$, то есть $F_{\text{факт}} < F_{\text{кр}}$ и уравнение незначимо. Двумя строками ниже пособие само себе противоречит, верно заключая обратное для $\alpha = 1\%$. Хорошее место, чтобы на семинаре разобрать, в какую сторону читается F -тест.