

Семинар 2

Суммы квадратов и R^2 , свойства оценок, теорема Гаусса–Маркова

Условия и решения

1. Основные формулы

1.1. Что используется из семинара 1

Модель и предпосылки классической регрессии те же, что в семинаре 1:

$$Y_t = \alpha + \beta X_t + \varepsilon_t, \quad t = 1, \dots, n, \quad (1)$$

1) выполнена спецификация (1); 2) X_t детерминированы и не все равны между собой; 3а) $\mathbb{E}\varepsilon_t = 0$ и $\mathbb{D}(\varepsilon_t) = \sigma^2$; 3б) $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ при $t \neq s$; 3с) $\varepsilon_t \sim N(0, \sigma^2)$. Обозначения прежние: $\hat{\alpha}, \hat{\beta}$ — МНК-оценки, $\hat{Y}_t = \hat{\alpha} + \hat{\beta}X_t$ — подогнанные значения, $e_t = Y_t - \hat{Y}_t$ — остатки, $x_t = X_t - \bar{X}$, $y_t = Y_t - \bar{Y}$ — отклонения от средних.

Ниже используются как готовые следующие формулы семинара 1 (выводы — там же). МНК-оценки и суммы в отклонениях:

$$\hat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2}, \quad \hat{\alpha} = \bar{Y} - \hat{\beta} \bar{X}, \quad (2)$$

$$\sum x_t^2 = \sum X_t^2 - \frac{(\sum X_t)^2}{n}, \quad \sum x_t y_t = \sum X_t Y_t - \frac{\sum X_t \sum Y_t}{n}. \quad (3)$$

Полная, объяснённая и остаточная суммы квадратов определены подписями в первой строке (4); эти определения годятся для любой регрессии. Само равенство и формулы через отклонения во второй строке верны только для регрессии со свободным членом:

$$\underbrace{\sum (Y_t - \bar{Y})^2}_{\text{TSS}} = \underbrace{\sum (\hat{Y}_t - \bar{Y})^2}_{\text{RSS}} + \underbrace{\sum (Y_t - \hat{Y}_t)^2}_{\text{ESS}}, \quad (4)$$

$$\text{TSS} = \sum y_t^2, \quad \text{RSS} = \hat{\beta}^2 \sum x_t^2, \quad \text{ESS} = \sum e_t^2 = \sum y_t^2 - \hat{\beta}^2 \sum x_t^2.$$

Коэффициент детерминации (последнее равенство — тоже только со свободным членом):

$$R^2 = \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\text{ESS}}{\text{TSS}} = \frac{\hat{\beta}^2 \sum x_t^2}{\sum y_t^2}. \quad (5)$$

Свойства оценки наклона и оценка дисперсии ошибок:

$$\hat{\beta} = \beta + \frac{\sum x_t \varepsilon_t}{\sum x_t^2}, \quad \mathbb{E}\hat{\beta} = \beta, \quad \mathbb{D}(\hat{\beta}) = \frac{\sigma^2}{\sum x_t^2}, \quad (6)$$

$$s^2 = \frac{\sum e_t^2}{n-2}, \quad s_{\hat{\beta}}^2 = \frac{s^2}{\sum x_t^2}, \quad \frac{\hat{\beta} - \beta}{s_{\hat{\beta}}} \sim t(n-2). \quad (7)$$

Тождество (4) и равносильность двух формул (5) опираются на *оба* нормальных уравнения МНК, $\sum e_t = 0$ и $\sum e_t X_t = 0$; это существенно в п. 1.2.

Замечание. Обозначения RSS и ESS не унифицированы. Мы следуем сборнику РАН-ХиГС: RSS (*regression*) — объяснённая сумма квадратов, ESS (*error*) — остаточная. В ряде книг (например, Johnston, DiNardo, 1997) те же буквы означают ровно наоборот.

Понадобятся также свойства дисперсии и ковариации: для неслучайных c_t, d_t и попарно некоррелированных Z_t

$$\mathbb{D}\left(\sum c_t Z_t\right) = \sum c_t^2 \mathbb{D}(Z_t), \quad \text{Cov}\left(\sum c_t Z_t, \sum d_t Z_t\right) = \sum c_t d_t \mathbb{D}(Z_t). \quad (8)$$

1.2. Регрессия без свободного члена

В модели $Y_t = \beta X_t + \varepsilon_t$ минимизация $\sum (Y_t - bX_t)^2$ даёт (вывод — задача 2.8)

$$\hat{\beta} = \frac{\sum X_t Y_t}{\sum X_t^2}, \quad \mathbb{D}(\hat{\beta}) = \frac{\sigma^2}{\sum X_t^2}, \quad (9)$$

а условие первого порядка сводится к единственному нормальному уравнению $\sum e_t X_t = 0$. Уравнения $\sum e_t = 0$ здесь нет: по свободному члену дифференцировать нечего. Отсюда три следствия.

Первое. Разложение (4) перестаёт быть тождеством. Прибавим и вычтем подогнанное значение $\hat{Y}_t = \hat{\beta} X_t$, чтобы разбить отклонение от среднего на остаток и отклонение подогнанного значения:

$$Y_t - \bar{Y} = (Y_t - \hat{\beta} X_t) + (\hat{\beta} X_t - \bar{Y}) = e_t + (\hat{Y}_t - \bar{Y}).$$

Возведём в квадрат и просуммируем:

$$\text{TSS} = \sum (e_t + (\hat{Y}_t - \bar{Y}))^2 = \underbrace{\sum e_t^2}_{\text{ESS}} + 2 \sum e_t (\hat{Y}_t - \bar{Y}) + \underbrace{\sum (\hat{Y}_t - \bar{Y})^2}_{\text{RSS}}.$$

Перекрёстный член распадается на два слагаемых, и первое из них обнуляется нормальным уравнением, так как $\hat{Y}_t = \hat{\beta} X_t$:

$$\sum e_t (\hat{Y}_t - \bar{Y}) = \sum \hat{Y}_t e_t - \bar{Y} \sum e_t = \hat{\beta} \sum X_t e_t - \bar{Y} \sum e_t = -\bar{Y} \sum e_t.$$

Следовательно,

$$\text{TSS} = \text{RSS} + \text{ESS} - 2\bar{Y} \sum e_t, \quad (10)$$

и разложение верно в точности тогда, когда $\bar{Y} \sum e_t = 0$. В регрессии со свободным членом перекрёстный член равен нулю целиком: $\sum \hat{Y}_t e_t = \hat{\alpha} \sum e_t + \hat{\beta} \sum X_t e_t = 0$ по обоим нормальным уравнениям, и остаётся (4).

Второе. Две формулы (5) дают разные числа, и оба могут выходить за пределы отрезка $[0, 1]$: RSS/TSS бывает больше единицы, а $1 - \text{ESS}/\text{TSS}$ — отрицательным. Содержательного коэффициента детерминации в такой модели попросту нет. Причина в том, что TSS — это остаточная сумма прогноза средним, $\hat{Y}_t = \bar{Y}$. Модель со свободным членом содержит такой прогноз: при $\alpha = \bar{Y}$ и $\beta = 0$ она даёт ровно $\hat{Y}_t = \bar{Y}$. МНК выбирает лучшие α и β , поэтому у такой модели $\text{ESS} \leq \text{TSS}$. Модель без свободного члена этот прогноз не содержит и может оказаться хуже: тогда $\text{ESS} > \text{TSS}$ и $1 - \text{ESS}/\text{TSS} < 0$.

Третье. В модели $Y_t = \beta X_t + \varepsilon_t$ свободный член не оценивается, а зафиксирован нулём: $\alpha = 0$ и $\hat{Y}_t = \hat{\beta} X_t$. Поэтому естественная точка отсчёта для неё — не среднее,

а ноль: при $\beta = 0$ модель даёт прогноз $\hat{Y}_t = 0$. Поэтому вместо *центрированных* сумм, то есть отклонений от $\bar{Y}$, берут *нецентрированные* — отклонения от нуля: $\sum Y_t^2$, $\sum \hat{Y}_t^2$ и $\sum e_t^2$. Для них разложение сохраняется. По определению остатка $e_t = Y_t - \hat{Y}_t$, то есть каждое наблюдение раскладывается как $Y_t = \hat{Y}_t + e_t$. Подставим это в $\sum Y_t^2$ и раскроем квадрат:

$$\sum Y_t^2 = \sum (\hat{Y}_t + e_t)^2 = \sum \hat{Y}_t^2 + 2 \sum \hat{Y}_t e_t + \sum e_t^2 = \sum \hat{Y}_t^2 + \sum e_t^2,$$

поскольку $\sum \hat{Y}_t e_t = \hat{\beta} \sum X_t e_t = 0$ по нормальному уравнению. Отдельные слагаемые $\hat{Y}_t e_t$ нулю не равны — обнуляется только их сумма. Это аналог (4), в котором роль TSS играет $\sum Y_t^2$, а роль RSS — $\sum \hat{Y}_t^2$. Отсюда *нецентрированный* коэффициент детерминации

$$R_u^2 = \frac{\sum \hat{Y}_t^2}{\sum Y_t^2} = 1 - \frac{\text{ESS}}{\sum Y_t^2}, \quad (11)$$

который всегда лежит в $[0, 1]$, так как обе суммы в правой части разложения неотрицательны. Он показывает, насколько модель лучше нулевого прогноза, а не прогноза средним, поэтому сравнивать его с обычным R^2 нельзя. Именно его печатают эконометрические пакеты для регрессии без константы.

Замечание. Если данные *центрированы*, то есть $\sum X_t = \sum Y_t = 0$, то $\sum e_t = \sum Y_t - \hat{\beta} \sum X_t = 0$ выполняется автоматически, хотя свободного члена в модели нет. Тогда все формулы п. 1.1 остаются верными, а R^2 совпадает с обычным (задача 2.9, пп. в, г).

1.3. Линейные несмещённые оценки и теорема Гаусса–Маркова

Линейной называется оценка вида $\tilde{\beta} = \sum c_t Y_t$ с неслучайными весами c_t . Матожидание суммы равно сумме матожиданий, и неслучайные c_t выносятся за знак $\mathbb{E}$. По (1) и предпосылкам 2, 3а $\mathbb{E}Y_t = \mathbb{E}(\alpha + \beta X_t + \varepsilon_t) = \alpha + \beta X_t$, поэтому

$$\begin{aligned} \mathbb{E}\tilde{\beta} &= \mathbb{E}\left(\sum c_t Y_t\right) = \sum c_t \mathbb{E}Y_t = \sum c_t (\alpha + \beta X_t) \\ &= \sum (\alpha c_t + \beta c_t X_t) = \alpha \sum c_t + \beta \sum c_t X_t. \end{aligned}$$

Оценка несмещена, если $\alpha \sum c_t + \beta \sum c_t X_t = \beta$ при любых α и β . Это возможно тогда и только тогда, когда коэффициент при α равен нулю, а при β — единице:

$$\sum c_t = 0, \quad \sum c_t X_t = \sum c_t x_t = 1 \quad (12)$$

Второе равенство следует из первого: $X_t = x_t + \bar{X}$, а $\bar{X}$ — константа и выносится за знак суммы, поэтому при $\sum c_t = 0$

$$\sum c_t X_t = \sum c_t (x_t + \bar{X}) = \sum c_t x_t + \bar{X} \sum c_t = \sum c_t x_t.$$

Для дисперсии заметим, что Y_t некоррелированы и $\mathbb{D}(Y_t) = \mathbb{D}(\alpha + \beta X_t + \varepsilon_t) = \mathbb{D}(\varepsilon_t) = \sigma^2$ (предпосылки 2, 3а, 3б), поэтому по (8)

$$\mathbb{D}(\tilde{\beta}) = \mathbb{D}\left(\sum c_t Y_t\right) = \sum c_t^2 \mathbb{D}(Y_t) = \sigma^2 \sum c_t^2. \quad (13)$$

МНК-оценка (2) — частный случай с весами $c_t = x_t / \sum x_t^2$: для них условия (12) выполнены, а (13) даёт уже известную дисперсию $\sigma^2 / \sum x_t^2$.

Теорема Гаусса–Маркова. При предпосылках 1–3b МНК-оценка обладает наименьшей дисперсией в классе линейных несмещённых оценок:

$$\mathbb{D}(\tilde{\beta}) \geq \frac{\sigma^2}{\sum x_t^2} = \mathbb{D}(\hat{\beta}), \quad (14)$$

причём равенство достигается только при $c_t = x_t / \sum x_t^2$, то есть только для МНК-оценки. Такую оценку называют *эффективной*, или BLUE (*best linear unbiased estimator*).

Доказательство. По неравенству Коши–Буняковского и условию (12)

$$1 = \left(\sum c_t x_t \right)^2 \leq \sum c_t^2 \sum x_t^2 \implies \sum c_t^2 \geq \frac{1}{\sum x_t^2},$$

что вместе с (13) даёт (14). Равенство в неравенстве Коши–Буняковского возможно лишь при $c_t = \lambda x_t$, а условие (12) фиксирует $\lambda = 1 / \sum x_t^2$. ■

Объединение независимых оценок. Пусть $\hat{\beta}_1$ и $\hat{\beta}_2$ — независимые несмещённые оценки β с дисперсиями V_1 и V_2 . Оценка $\tilde{\beta}_\theta = \theta \hat{\beta}_1 + (1 - \theta) \hat{\beta}_2$ несмещена при любом θ , а её дисперсия равна $\theta^2 V_1 + (1 - \theta)^2 V_2$. Приравнявая производную к нулю, $2\theta V_1 - 2(1 - \theta)V_2 = 0$, получаем

$$\theta^* = \frac{V_2}{V_1 + V_2}, \quad \mathbb{D}(\tilde{\beta}^*) = \frac{V_1 V_2}{V_1 + V_2} = \left(\frac{1}{V_1} + \frac{1}{V_2} \right)^{-1}. \quad (15)$$

Веса обратно пропорциональны дисперсиям: точнее измеренная оценка получает больший вес, а дисперсия объединённой оценки меньше каждой из исходных.

1.4. Ковариация оценок и центрирование регрессора

Обе величины $\bar{Y}$ и $\hat{\beta}$ — константа плюс линейная комбинация ошибок. Обозначим $S_{xx} = \sum x_t^2$. Усредняя (1) по t и пользуясь (6), получаем

$$\bar{Y} = \alpha + \beta \bar{X} + \sum_t \frac{1}{n} \varepsilon_t, \quad \hat{\beta} = \beta + \sum_s \frac{x_s}{S_{xx}} \varepsilon_s.$$

Константы на ковариацию не влияют, а ковариация двух сумм раскрывается по всем парам (t, s) . По предпосылкам 3a, 3b $\text{Cov}(\varepsilon_t, \varepsilon_s)$ равна σ^2 при $s = t$ и нулю при $s \neq t$, поэтому в двойной сумме остаются только слагаемые с $s = t$ — это и есть вторая формула (8):

$$\begin{aligned} \text{Cov}(\bar{Y}, \hat{\beta}) &= \text{Cov}\left(\sum_t \frac{1}{n} \varepsilon_t, \sum_s \frac{x_s}{S_{xx}} \varepsilon_s\right) = \sum_t \sum_s \frac{1}{n} \cdot \frac{x_s}{S_{xx}} \text{Cov}(\varepsilon_t, \varepsilon_s) \\ &= \sum_t \frac{1}{n} \cdot \frac{x_t}{S_{xx}} \sigma^2 = \frac{\sigma^2}{n S_{xx}} \sum_t x_t = 0, \end{aligned}$$

так как сумма отклонений от среднего равна нулю.

Теперь подставим $\hat{\alpha} = \bar{Y} - \bar{X} \hat{\beta}$, где $\bar{X}$ — константа. Ковариация линейна по каждому аргументу, для дисперсии разности $\mathbb{D}(U - cV) = \mathbb{D}(U) + c^2 \mathbb{D}(V) - 2c \text{Cov}(U, V)$, а $\mathbb{D}(\bar{Y}) = \mathbb{D}(\sum_t \varepsilon_t / n) = \sigma^2 / n$ по первой формуле (8). Поэтому

$$\text{Cov}(\hat{\alpha}, \hat{\beta}) = \text{Cov}(\bar{Y}, \hat{\beta}) - \bar{X} \text{Cov}(\hat{\beta}, \hat{\beta}) = 0 - \bar{X} \mathbb{D}(\hat{\beta}),$$

$$\mathbb{D}(\hat{\alpha}) = \mathbb{D}(\bar{Y}) + \bar{X}^2 \mathbb{D}(\hat{\beta}) - 2\bar{X} \text{Cov}(\bar{Y}, \hat{\beta}) = \frac{\sigma^2}{n} + \bar{X}^2 \mathbb{D}(\hat{\beta}) - 0.$$

Итак,

$$\text{Cov}(\hat{\alpha}, \hat{\beta}) = -\bar{X} \mathbb{D}(\hat{\beta}) = -\frac{\bar{X} \sigma^2}{\sum x_t^2}, \quad \mathbb{D}(\hat{\alpha}) = \frac{\sigma^2}{n} + \bar{X}^2 \mathbb{D}(\hat{\beta}). \quad (16)$$

Обе формулы объясняют, зачем центрируют регрессор: при $\bar{X} = 0$ оценки свободного члена и наклона *некоррелированы*, а дисперсия $\hat{\alpha}$ минимальна. Сама подгонка при этом не меняется — остатки и R^2 у исходной и центрированной регрессий совпадают (задача 2.21).

1.5. Доверительные интервалы и значимость коэффициентов

Из (7) при предпосылке 3с доверительный интервал уровня 95 % имеет вид

$$\hat{\beta} \pm t_{\text{кр}} s_{\hat{\beta}}, \quad t_{\text{кр}} = t_{0,025}(n-2); \quad (17)$$

для α он строится так же с $s_{\hat{\alpha}}$. Коэффициент называют *значимым* на уровне 5 %, если отвергается гипотеза $H_0: \beta = 0$, то есть $|t| = |\hat{\beta}/s_{\hat{\beta}}| > t_{\text{кр}}$. Три формулировки равносильны: $|t| > t_{\text{кр}}$; P -значение $P = \Pr\{|t(n-2)| > |\hat{\beta}/s_{\hat{\beta}}|\}$ меньше 0,05; интервал (17) не содержит нуля.

1.6. Другие критерии подгонки

МНК минимизирует $S(a, b) = \sum (Y_t - a - bX_t)^2$ — строго выпуклую функцию (семинар 1), поэтому при условии, что не все X_t равны, решение существует и единственно. Метод наименьших модулей (МНМ) минимизирует

$$F(a, b) = \sum |Y_t - a - bX_t|. \quad (18)$$

Эта функция выпукла, но кусочно-линейна и *не строго* выпукла: там, где ни одно слагаемое не меняет знак, она линейна по параметрам. Поэтому минимум может достигаться не в одной точке, а на целом множестве (задача 2.11).

2. Задачи

Задача 2.8

Выведите непосредственно формулу для оценки коэффициента наклона в регрессии **без свободного члена**, т. е. найдите оценку параметра β в регрессии

$$Y_t = \beta X_t + \varepsilon_t$$

минимизацией суммы квадратов отклонений $\sum (Y_t - \hat{Y}_t)^2$.

Решение. Минимизируем

$$S(b) = \sum (Y_t - bX_t)^2.$$

Условие первого порядка

$$S'(b) = -2 \sum (Y_t - bX_t) X_t = 0$$

— это и есть единственное нормальное уравнение $\sum e_t X_t = 0$. Решая его относительно b , получаем МНК-оценку

$$\hat{\beta} = \frac{\sum X_t Y_t}{\sum X_t^2}$$

Это минимум, так как $S''(b) = 2 \sum X_t^2 > 0$.

Свойства оценки выводятся так же, как в семинаре 1, только с X_t вместо x_t . Подставим $Y_t = \beta X_t + \varepsilon_t$:

$$\hat{\beta} = \frac{\sum X_t (\beta X_t + \varepsilon_t)}{\sum X_t^2} = \frac{\beta \sum X_t^2 + \sum X_t \varepsilon_t}{\sum X_t^2} = \beta + \frac{\sum X_t \varepsilon_t}{\sum X_t^2}.$$

Веса $X_t / \sum X_t^2$ неслучайны (предпосылка 2), поэтому по предпосылке 3а $\mathbb{E} \hat{\beta} = \beta$. В дисперсии константа β пропадает, а по (8) и предпосылкам 3а, 3б множитель $1 / \sum X_t^2$ выносится в квадрате и дисперсия суммы равна сумме дисперсий:

$$\begin{aligned} \mathbb{D}(\hat{\beta}) &= \mathbb{D}\left(\beta + \frac{\sum X_t \varepsilon_t}{\sum X_t^2}\right) = \frac{1}{(\sum X_t^2)^2} \mathbb{D}\left(\sum X_t \varepsilon_t\right) = \frac{1}{(\sum X_t^2)^2} \sum X_t^2 \mathbb{D}(\varepsilon_t) \\ &= \frac{\sigma^2 \sum X_t^2}{(\sum X_t^2)^2} = \frac{\sigma^2}{\sum X_t^2}. \end{aligned}$$

Это и есть формулы (9).

Второго нормального уравнения, $\sum e_t = 0$, здесь нет: по свободному члену дифференцировать нечего. Все следствия этого разобраны в п. 1.2 — разложение (4) нарушается на величину $2\bar{Y} \sum e_t$, две формулы (5) перестают быть эквивалентными, и осмысленным остаётся только нецентрированный коэффициент (11). Численно это видно в следующей задаче.

Задача 2.9

Для наблюдений

t	1	2	3	4	5	6	7	8	9	10
Y_t	70	65	55	60	50	35	40	30	25	32
X_t	5	11	15	17	20	22	25	27	30	35

вычислите следующие величины:

- коэффициент детерминации R^2 в регрессии Y_t на X_t **при наличии** свободного члена;
- коэффициент детерминации R^2 в регрессии Y_t на X_t **при отсутствии** свободного члена;
- коэффициент детерминации R^2 в регрессии y_t на x_t **при наличии** свободного члена, где y_t и x_t — отклонения переменных Y_t и X_t от их средних значений;
- коэффициент детерминации R^2 в регрессии y_t на x_t **при отсутствии** свободного члена.

В Excel. Надстройка подключается один раз: Файл → Параметры → Надстройки → Пакет анализа.

Занесите данные двумя столбцами. **Внимательно с порядком:** в таблице второй столбец — это Y (70, 65, ...), третий — X (5, 11, ...), а не наоборот.

а) Данные → Анализ данных → Регрессия. Входной интервал Y — столбец Y , Входной интервал X — столбец X . В отчёте: Y -пересечение = 79,95, коэффициент при X = -1,63, R -квадрат = 0,8607.

б) Тот же диалог, но включите флажок Константа — ноль. Коэффициент станет 1,66.

в) Добавьте два столбца отклонений и повторите п. а) для них:
 $=B2-CPЗНАЧ(\$B\$2:\$B\$11)$ и $=C2-CPЗНАЧ(\$C\$2:\$C\$11)$

г) То же, что в), но с флажком Константа — ноль.

Сравните R -квадрат из четырёх отчётов между собой и с ответами ниже. В пункте б) Excel покажет **не** то, что даёт формула $R^2 = \text{RSS}/\text{TSS}$, — разберитесь, почему.

Решение. Подготовительные суммы ($n = 10$):

$\sum X_t = 207$, $\sum Y_t = 462$, $\sum X_t^2 = 5023$, $\sum Y_t^2 = 23\,624$, $\sum X_t Y_t = 8360$,
откуда $\bar{X} = 20,7$, $\bar{Y} = 46,2$ и, по (3),

$$\begin{aligned}\sum x_t^2 &= 5023 - \frac{207^2}{10} = 738,1, \\ \sum x_t y_t &= 8360 - \frac{207 \cdot 462}{10} = -1203,4, \\ \sum y_t^2 &= 23\,624 - \frac{462^2}{10} = 2279,6.\end{aligned}$$

а) По (2), второй строке (4) и (5)

$$\hat{\beta} = \frac{-1203,4}{738,1} = -1,63, \quad \hat{\alpha} = 46,2 + 1,63 \cdot 20,7 = 79,95, \quad \hat{Y}_t = 79,95 - 1,63 X_t,$$

$$\text{RSS} = \hat{\beta}^2 \sum x_t^2 = 1962,0, \quad \text{TSS} = 2279,6, \quad R^2 = \frac{1962,0}{2279,6} = 0,8607.$$

б) Теперь модель $Y_t = \beta X_t + \varepsilon_t$, и по (9)

$$\hat{\beta} = \frac{8360}{5023} = 1,66, \quad \hat{Y}_t = 1,66 X_t.$$

Суммы квадратов считаем по определениям из первой строки (4): формулы через отклонения из второй строки здесь неприменимы (например, $\hat{\beta}^2 \sum x_t^2 = 2044,6$ — это не RSS этой модели). Получаем

$$\text{RSS} = \sum (\hat{Y}_t - \bar{Y})^2 = 3424,7, \quad \text{ESS} = \sum e_t^2 = 9710,1, \quad \sum e_t = 117,5 \neq 0.$$

Сумма $\text{RSS} + \text{ESS} = 13\,134,8$ не равна $\text{TSS} = 2279,6$; расхождение в точности описывается формулой (10): $2\bar{Y} \sum e_t = 2 \cdot 46,2 \cdot 117,5 = 10\,855,2$. Поэтому две формулы (5) дают разные и бессмысленные значения:

$$\frac{\text{RSS}}{\text{TSS}} = \frac{3424,7}{2279,6} = 1,50 > 1, \quad 1 - \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{9710,1}{2279,6} = -3,26 < 0.$$

Корректной характеристикой здесь служит нецентрированный коэффициент (11):

$$R_u^2 = 1 - \frac{9710,1}{23\,624} = 0,5890,$$

и именно это число печатает Excel с флажком Константа — ноль: ни 1,50, ни −3,26. Пакет молча подменяет TSS на $\sum Y_t^2$; сравнивать такой R^2 с R^2 из пункта а) нельзя.

в), г) Для центрированных данных $\bar{x} = \bar{y} = 0$, поэтому по (2) $\hat{\alpha}' = \bar{y} - \hat{\beta}\bar{x} = 0$: свободный член оценивается точно нулём, и пункты в) и г) описывают одну и ту же прямую $\hat{y}_t = \hat{\beta}x_t$. По замечанию к п. 1.2 равенство $\sum e_t = 0$ здесь выполняется и без константы, так что (4) и (5) остаются в силе. Наклон и суммы квадратов те же, что в п. а):

$$\hat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2} = -1,63, \quad R^2 = \frac{\hat{\beta}^2 \sum x_t^2}{\sum y_t^2} = 0,8607.$$

Вывод.

Пункт	Регрессия	$\hat{\beta}$	R^2
а)	Y на X со свободным членом	−1,63	0,8607
б)	Y на X без свободного члена	1,66	1,50 или −3,26
в)	y на x со свободным членом	−1,63	0,8607
г)	y на x без свободного члена	−1,63	0,8607

Центрирование делает свободный член излишним: он и так равен нулю. А отбрасывание константы у нецентрированных данных (пункт б) меняет модель по существу и разрушает само понятие R^2 .

Задача 2.16 (кривая Филлипса)

Так называемая кривая Филлипса описывает связь темпа роста зарплаты и уровня безработицы. А именно,

$$\delta w_t = \beta_1 + \beta_2 \frac{1}{u_t} + \varepsilon_t,$$

где w_t — уровень заработной платы, $\delta w_t = 100(w_t - w_{t-1})/w_{t-1}$ — темп роста зарплаты (в процентах), u_t — процент безработных в год t . Теория предполагает, что $\beta_1 < 0$ и $\beta_2 > 0$.

t	1	2	3	4	5	6	7	8	9
w_t	1,62	1,65	1,79	1,94	2,03	2,12	2,26	2,44	2,57
u_t	1,0	1,4	1,1	1,5	1,5	1,2	1,0	1,1	1,3

t	10	11	12	13	14	15	16	17	18
w_t	2,66	2,73	2,80	2,92	3,02	3,13	3,28	3,43	3,58
u_t	1,8	1,9	1,5	1,4	1,8	1,1	1,5	1,3	1,4

Используя данные для некоторой страны:

- а) Найдите оценки коэффициентов уравнения и проверьте наличие значимой связи между δw и u .
- б) Найдите «естественный уровень безработицы», т. е. такой уровень безработицы, при котором $\delta w = 0$.
- в) Когда изменения в уровне безработицы оказывали наибольшее (наименьшее) влияние на темп изменения зарплаты?
- г) Найдите 95 %-доверительные интервалы для β_1 и β_2 .

В Excel. Столбцы w_t и u_t вводятся как есть, ещё два считаются формулами (первая строка остаётся пустой — темп роста для $t = 1$ не определён):

$$=100*(A3-A2)/A2 \quad \text{и} \quad =1/B3$$

Множитель 100 и вид регрессора важны. Если считать δw долей (без 100*) или брать $100/u$ вместо $1/u$, то R^2 , t -статистики и P -значения останутся верными — они не зависят от масштаба, — а вот коэффициенты выйдут в других единицах и с ответом не сойдутся.

Дальше Данные → Анализ данных → Регрессия по 17 строкам, с флажком Остатки. В отчёте сразу есть всё для пунктов а) и г): коэффициенты, стандартные ошибки, P -значения и границы Нижние 95% / Верхние 95%.

Проверьте отчёт вручную. Стандартную ошибку наклона

$$s_{\hat{\beta}} = \sqrt{\frac{\text{ESS}/(n-2)}{\sum (x_t - \bar{x})^2}}$$

можно собрать из тех же остатков в три шага:

Величина	Формула	Значение
$s^2 = \text{ESS}/(n-2)$	=СУММКВ(остатки)/15	3,0098
$\sum (x_t - \bar{x})^2$	=ДИСП.Г(столбец 1/u)*17	0,3009
$s_{\hat{\beta}}$	=КОРЕНЬ(первое/второе)	3,1626

Последнее число — ровно то, что Excel напечатал в графе Стандартная ошибка. Здесь $\text{ДИСП.Г} \cdot n$ — это и есть $\sum (x_t - \bar{x})^2$, поскольку ДИСП.Г делит на n , а не на $n-1$.

Решение. Темп роста δw_t определён начиная с $t = 2$, поэтому в регрессии участвуют $n = 17$ наблюдений, а число степеней свободы равно $n - 2 = 15$. Регрессор — величина $1/u_t$; модель линейна по параметрам, поэтому все формулы п. 1.1 применимы без изменений.

а) Оценка параметров даёт следующий результат.

Зависимая переменная: δw ; $n = 17$				
Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	-1,034	2,3716	-0,4362	0,6689
$1/u$	7,896	3,1626	2,4966	0,0247
$R^2 = 0,294$; ESS = 45,15; TSS = 63,91; $F(1, 15) = 6,23$				

Итоговое уравнение: $\widehat{\delta w} = -1,034 + 7,896/u$.

По критерию п. 1.5 коэффициент при $1/u$ значим ($P = 0,0247 < 0,05$), а свободный член от нуля достоверно не отличается ($P = 0,6689$). Связь между δw и u есть: с ростом безработицы темп роста зарплаты падает. Знаки обоих коэффициентов согласуются с теорией ($\beta_1 < 0$, $\beta_2 > 0$).

б) «Естественный уровень безработицы» — корень уравнения $\widehat{\delta w} = 0$:

$$-1,034 + 7,896 \frac{1}{u} = 0 \implies \boxed{u_0 = \frac{7,896}{1,034} = 7,63 \%}$$

в) Модель нелинейна по u , поэтому эффект зависит от уровня безработицы:

$$\frac{\partial \delta w}{\partial u} = -\frac{7,896}{u^2}.$$

По модулю он тем больше, чем меньше u . Наибольшее влияние — в годы с наименьшей безработицей ($u = 1,0$: 1-й и 7-й годы, $\partial \delta w / \partial u = -7,90$), наименьшее — в год с наибольшей ($u = 1,9$: 11-й год, $-2,19$). Первый год при этом выпадает из выборки: для него δw не определён.

г) По (17) при 15 степенях свободы $t_{0,025}(15) = 2,131$:

$$\beta_1 = -1,034 \pm 2,131 \cdot 2,372 = -1,034 \pm 5,055 \implies [-6,09; 4,02],$$

$$\beta_2 = 7,896 \pm 2,131 \cdot 3,163 = 7,896 \pm 6,741 \implies [1,15; 14,64].$$

Первый интервал покрывает ноль, второй — нет; это согласуется с P -значениями из пункта а) и с критерием значимости п. 1.5.

Замечание. В решебнике в этом пункте взято $t_{0,025}(16) = 2,12$, что даёт $-1,03 \pm 5,03$ и $7,90 \pm 6,70$. Это опечатка в числе степеней свободы: наблюдений 17 (первое теряется при переходе к темпу роста), оцениваемых параметров 2, значит $df = 15$, а не 16. На выводы расхождение не влияет.

3. Дополнительные задачи

Задачи этого раздела не входят в основной ход семинара: они разбираются, если остаётся время, или предлагаются для самостоятельной работы.

Задача 2.23

Два исследователя, работая независимо друг от друга, изучают одну и ту же регрессионную модель

$$Y_t = \alpha + \beta X_t + \varepsilon_t,$$

для которой выполнены все условия классической модели. В таблице приведены результаты, полученные ими на основе независимых выборок.

Выборка I	Выборка II
$n = 20$	$n = 20$
$\sum X_t = 100$	$\sum X_t = 200$
$\sum X_t^2 = 600$	$\sum X_t^2 = 2400$
$\sum Y_t = 500$	$\sum Y_t = 500$
$\hat{\beta}_I = 2$	$\hat{\beta}_{II} = 2,5$

Узнав о работе друг друга, они решают вывести единую оценку параметра β . Первый исследователь предлагает взять

$$\tilde{\beta} = \frac{1}{2}(\hat{\beta}_I + \hat{\beta}_{II}).$$

Второй исследователь считает, что весовые коэффициенты первой и второй оценок выбраны неэффективно, и можно построить несмещённую оценку с меньшей дисперсией. Научный руководитель этих исследователей утверждает, что он знает способ ещё улучшить общую оценку.

- Какую оценку предлагает использовать второй исследователь?
- Какую оценку предлагает использовать научный руководитель?

Оцените улучшение точности оценок пп. а), б) по сравнению с оценкой $\tilde{\beta}$.

Решение. Исследователи используют МНК-оценки, поэтому по (3) и (6)

$$\sum_I x_t^2 = 600 - \frac{100^2}{20} = 100, \quad \sum_{II} x_t^2 = 2400 - \frac{200^2}{20} = 400,$$

$$V_1 = \mathbb{D}(\hat{\beta}_I) = \frac{\sigma^2}{100}, \quad V_2 = \mathbb{D}(\hat{\beta}_{II}) = \frac{\sigma^2}{400}.$$

а) Второй исследователь предлагает взвесить оценки оптимально. По (15)

$$\theta^* = \frac{V_2}{V_1 + V_2} = \frac{\sigma^2/400}{\sigma^2/100 + \sigma^2/400} = \frac{1}{5}, \quad \boxed{\tilde{\beta}^* = \frac{1}{5} \cdot 2 + \frac{4}{5} \cdot 2,5 = 2,4}$$

Вторая выборка даёт вчетверо больший разброс регрессора, её оценка вчетверо точнее и получает вес 4/5. Дисперсия по (15) равна $V_1 V_2 / (V_1 + V_2) = \sigma^2 / 500 = 0,002 \sigma^2$.

б) Научный руководитель предлагает объединить не оценки, а *данные*: по теореме Гаусса–Маркова (14) эффективна МНК-оценка по всем $n = 40$ наблюдениям. Недостающие суммы $\sum X_t Y_t$ восстанавливаются из (2) и (3): $\sum X_t Y_t = \hat{\beta} \sum x_t^2 + \frac{1}{n} \sum X_t \sum Y_t$, то есть

$$\sum_I X_t Y_t = 2 \cdot 100 + \frac{100 \cdot 500}{20} = 2700, \quad \sum_{II} X_t Y_t = 2,5 \cdot 400 + \frac{200 \cdot 500}{20} = 6000.$$

Для объединённой выборки $n = 40$, $\sum X_t = 300$, $\sum Y_t = 1000$, $\sum X_t^2 = 3000$, $\sum X_t Y_t = 8700$, поэтому

$$\sum x_t^2 = 3000 - \frac{300^2}{40} = 750, \quad \sum x_t y_t = 8700 - \frac{300 \cdot 1000}{40} = 1200,$$

$$\hat{\beta} = \frac{1200}{750} = 1,6$$

и $\mathbb{D}(\hat{\beta}) = \sigma^2 / 750 \approx 0,001333 \sigma^2$.

Сравнение точности. Для оценки с равными весами по (13) $\mathbb{D}(\tilde{\beta}) = \frac{1}{4} V_1 + \frac{1}{4} V_2 = 0,003125 \sigma^2$.

Оценка	Дисперсия	Выигрыш против $\tilde{\beta}$
$\tilde{\beta} = 2,25$ (равные веса)	$0,003125 \sigma^2$	—
$\tilde{\beta}^* = 2,4$ (оптимальные веса)	$0,002000 \sigma^2$	−36 %
$\hat{\beta} = 1,6$ (объединённая выборка)	$0,001333 \sigma^2$	−57 %

Замечание. Оценка $\hat{\beta} = 1,6$ лежит вне отрезка между 2 и 2,5, то есть не является никакой выпуклой комбинацией исходных оценок. Объединение данных — это не усреднение оценок: объединённая регрессия использует ещё и различие средних $\bar{X}$ между выборками, которого взвешивание оценок «не видит».

Задача 2.10

Предположим, что модель

$$Y_t = \alpha + \beta X_t + \varepsilon_t, \quad t = 1, \dots, n$$

удовлетворяет условиям классической регрессии. Рассматривается следующая оценка коэффициента β :

$$\tilde{\beta} = \frac{1}{n} \sum_{t=1}^n \frac{Y_t - \bar{Y}}{X_t - \bar{X}}.$$

- Является ли оценка $\tilde{\beta}$ несмещённой? Является ли она линейной?
- Вычислите дисперсию оценки $\tilde{\beta}$.
- Проверьте теорему Гаусса–Маркова, сравнив полученную дисперсию оценки $\tilde{\beta}$ с дисперсией МНК-оценки $\sigma^2 / \sum_{t=1}^n (X_t - \bar{X})^2$.

Решение. Всюду предполагается $x_t = X_t - \bar{X} \neq 0$, иначе оценка не определена.

а) Раскроем $\bar{Y} = \frac{1}{n} \sum_s Y_s$ и соберём коэффициенты при Y_t :

$$\tilde{\beta} = \frac{1}{n} \sum_t \frac{Y_t}{x_t} - \frac{1}{n^2} \left(\sum_s Y_s \right) \left(\sum_t \frac{1}{x_t} \right) = \sum_t c_t Y_t, \quad c_t = \frac{1}{n} \left(\frac{1}{x_t} - \frac{1}{n} \sum_s \frac{1}{x_s} \right).$$

Веса c_t неслучайны (предпосылка 2), значит оценка **линейна**. Проверим условия несмещённости (12):

$$\sum_t c_t = \frac{1}{n} \left(\sum_t \frac{1}{x_t} - \sum_s \frac{1}{x_s} \right) = 0, \quad \sum_t c_t x_t = \frac{1}{n} \left(n - \frac{1}{n} \left(\sum_s \frac{1}{x_s} \right) \sum_t x_t \right) = 1,$$

поскольку $\sum_t x_t = 0$. Оба условия выполнены, поэтому оценка **несмещённая**: $\mathbb{E}\tilde{\beta} = \beta$.

б) По (13)

$$\mathbb{D}(\tilde{\beta}) = \sigma^2 \sum_t c_t^2 = \frac{\sigma^2}{n^2} \sum_{t=1}^n \left(\frac{1}{x_t} - \frac{1}{n} \sum_{s=1}^n \frac{1}{x_s} \right)^2.$$

в) Оценка линейна и несмещённа, поэтому к ней применима теорема Гаусса–Маркова (14):

$$\mathbb{D}(\tilde{\beta}) = \sigma^2 \sum_t c_t^2 \geq \frac{\sigma^2}{\sum_t x_t^2} = \mathbb{D}(\hat{\beta}).$$

Равенство было бы возможно только при $c_t \propto x_t$, тогда как здесь c_t пропорциональны $1/x_t$ с точностью до сдвига. Значит, МНК-оценка строго эффективнее (кроме вырожденных наборов данных), и теорема подтверждается.

Задача 2.11

Приведите пример набора данных (X_t, Y_t) , для которого решение задачи поиска параметров α, β , минимизирующих функционал

$$F = \sum_{t=1}^n |Y_t - (\alpha + \beta X_t)|,$$

не единственно.

Решение. Возьмём $n = 3$ и вершины равностороннего треугольника со стороной 2: $(X_1, Y_1) = (0, 0)$, $(X_2, Y_2) = (0, 2)$, $(X_3, Y_3) = (\sqrt{3}, 1)$. Тогда функционал (18) равен

$$F = |\alpha| + |2 - \alpha| + |1 - \alpha - \sqrt{3}\beta|.$$

Первые два слагаемых оцениваются снизу как $|\alpha| + |2 - \alpha| \geq 2$, причём равенство достигается при любом $\alpha \in [0, 2]$; третье слагаемое неотрицательно и обращается в нуль при $\alpha + \sqrt{3}\beta = 1$. Следовательно, $F_{\min} = 2$ и достигается на всём множестве

$$\alpha \in [0, 2], \quad \beta = \frac{1 - \alpha}{\sqrt{3}},$$

то есть на всех прямых, проходящих через точку $(\sqrt{3}, 1)$ и пересекающих ось Y между 0 и 2. Например, $\alpha = 0, \beta = 1/\sqrt{3}$ и $\alpha = 2, \beta = -1/\sqrt{3}$. Решений **бесконечно много**:

сумма модулей «плоская» на отрезке, и это в точности та неединственность, о которой сказано в п. 1.6.

Задача 2.21

Проведены две регрессии:

$$Y_t = \alpha + \beta X_t + \varepsilon_t \quad \text{и} \quad Y_t = \alpha' + \beta' x_t + \varepsilon'_t, \quad t = 1, \dots, T,$$

где $x_t = X_t - \bar{X}$.

- По известным МНК-оценкам $\hat{\alpha}, \hat{\beta}$ параметров α, β в первой регрессии найдите МНК-оценки $\hat{\alpha}', \hat{\beta}'$ параметров α', β' во второй регрессии.
- Найдите $\text{Cov}(\hat{\alpha}', \hat{\beta}')$.

Решение. а) Регрессор второй регрессии центрирован: $\bar{x} = 0$. По (2)

$$\hat{\beta}' = \frac{\sum (x_t - \bar{x})(Y_t - \bar{Y})}{\sum (x_t - \bar{x})^2} = \frac{\sum x_t y_t}{\sum x_t^2} = \hat{\beta},$$

$$\hat{\alpha}' = \bar{Y} - \hat{\beta}' \bar{x} = \bar{Y} = (\bar{Y} - \hat{\beta} \bar{X}) + \hat{\beta} \bar{X} = \hat{\alpha} + \hat{\beta} \bar{X}.$$

Наклон не меняется, а свободный член становится равен $\bar{Y}$: точка отсчёта переносится в $\bar{X}$.

б) По формуле (16), применённой ко второй регрессии, у которой среднее регрессора равно нулю,

$$\text{Cov}(\hat{\alpha}', \hat{\beta}') = -\bar{x} \mathbb{D}(\hat{\beta}') = 0.$$

Это и есть причина, по которой регрессоры центрируют (п. 1.4).

Задача 2.13

Рассмотрим модель регрессии без константы

$$Y_t = \beta X_t + \varepsilon_t, \quad t = 1, \dots, n.$$

- Найдите оценки метода наименьших квадратов для β и σ^2 .
- Найдите дисперсию оценки $\hat{\beta}$.
- Покажите, что статистика $\frac{\hat{\beta} - \beta}{s_{\hat{\beta}}}$ имеет распределение $t(n-1)$.
- Приведите примеры данных, для которых: значение коэффициента R^2 , рассчитанное по формуле $R^2 = \text{RSS}/\text{TSS}$, отличается от значения R^2 , рассчитанного по формуле $R^2 = 1 - \text{ESS}/\text{TSS}$; значение R^2 , рассчитанное по формуле $R^2 = \text{RSS}/\text{TSS}$, больше 1; значение R^2 , рассчитанное по формуле $R^2 = 1 - \text{ESS}/\text{TSS}$, меньше 0.

Решение. а) Оценка наклона дана формулой (9): $\hat{\beta} = \sum X_t Y_t / \sum X_t^2$. Для оценки σ^2 выразим сумму квадратов остатков, пользуясь нормальным уравнением $\sum X_t Y_t = \hat{\beta} \sum X_t^2$:

$$\sum e_t^2 = \sum (Y_t - \hat{\beta} X_t)^2 = \sum Y_t^2 - 2\hat{\beta} \sum X_t Y_t + \hat{\beta}^2 \sum X_t^2 = \sum Y_t^2 - \hat{\beta}^2 \sum X_t^2.$$

Оба слагаемых усредняем по (8) и правилу $\mathbb{E}[Z^2] = \mathbb{D}(Z) + (\mathbb{E}Z)^2$:

$$\mathbb{E} \sum Y_t^2 = \sum (\mathbb{D}(Y_t) + (\mathbb{E}Y_t)^2) = n\sigma^2 + \beta^2 \sum X_t^2, \quad \mathbb{E}[\hat{\beta}^2] \sum X_t^2 = \sigma^2 + \beta^2 \sum X_t^2,$$

где использованы $\mathbb{E}\hat{\beta} = \beta$ и $\mathbb{D}(\hat{\beta}) = \sigma^2 / \sum X_t^2$ из (9). Вычитая, получаем $\mathbb{E} \sum e_t^2 = (n-1)\sigma^2$, поэтому несмещённая оценка дисперсии ошибок равна

$$s^2 = \frac{1}{n-1} \sum e_t^2.$$

Делитель $n-1$: оценивается один параметр.

б) По (9) $\mathbb{D}(\hat{\beta}) = \sigma^2 / \sum X_t^2$, а её оценка равна $s_{\hat{\beta}}^2 = s^2 / \sum X_t^2$.

в) При предпосылке 3с оценка $\hat{\beta} = \beta + \sum X_t \varepsilon_t / \sum X_t^2$ нормальна, поэтому

$$Z = \frac{\hat{\beta} - \beta}{\sigma / \sqrt{\sum X_t^2}} \sim N(0, 1).$$

Кроме того, можно показать, что $V = (n-1)s^2/\sigma^2 \sim \chi^2(n-1)$ и не зависит от $\hat{\beta}$ (степеней свободы на единицу меньше, чем наблюдений, так как оценён один параметр).
Отношение

$$\frac{Z}{\sqrt{V/(n-1)}} = \frac{(\hat{\beta} - \beta) \sqrt{\sum X_t^2} / \sigma}{s/\sigma} = \frac{\hat{\beta} - \beta}{s_{\hat{\beta}}}$$

по определению распределения Стьюдента имеет распределение $t(n-1)$.

г) Подходит набор данных из задачи 2.9, пункт б): там $RSS/TSS = 1,50 > 1$, а $1 - ESS/TSS = -3,26 < 0$. Все три патологии — расхождение двух формул, значение больше единицы и значение меньше нуля — возникают по одной причине: без свободного члена $\sum e_t \neq 0$, разложение (4) нарушается на величину $2\bar{Y} \sum e_t$ согласно (10), и формулы (5) перестают быть эквивалентными.