

Семинар 3

Множественная регрессия: тесты, фиктивные переменные, мультиколлинеарность

Условия и решения

1. Основные формулы

1.1. Модель множественной регрессии

В матричной форме модель записывается как

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad (1)$$

где $\mathbf{y}$ — вектор наблюдений размера $n \times 1$, $\mathbf{X}$ — матрица регрессоров размера $n \times k$ (первый столбец — единицы, если в модели есть свободный член), $\boldsymbol{\beta}$ — вектор k оцениваемых коэффициентов, $\boldsymbol{\varepsilon}$ — вектор ошибок. Число k считается вместе со свободным членом.

Предпосылки классической модели:


- 1) выполнена спецификация (1);
- 2) $\mathbf{X}$ детерминирована и имеет полный ранг k : столбцы линейно независимы и $n > k$;
- 3a) $\mathbb{E}\boldsymbol{\varepsilon} = \mathbf{0}$;
- 3b) $\mathbb{D}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ — ошибки гомоскедастичны и некоррелированы;
- 3c) $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$; нужна только для распределений тестовых статистик.

Геометрический вывод МНК-оценки. Прогноз $\mathbf{X}\mathbf{b}$ при всевозможных $\mathbf{b} \in \mathbb{R}^k$ пробегает линейную оболочку столбцов матрицы $\mathbf{X}$ — подпространство $L(\mathbf{X}) \subset \mathbb{R}^n$ размерности k (столбцы линейно независимы по предпосылке 2). МНК минимизирует

$$S(\mathbf{b}) = (\mathbf{y} - \mathbf{X}\mathbf{b})^\top (\mathbf{y} - \mathbf{X}\mathbf{b}) = \|\mathbf{y} - \mathbf{X}\mathbf{b}\|^2,$$

то есть *квадрат расстояния* от точки $\mathbf{y}$ до этого подпространства. Ближайшая к $\mathbf{y}$ точка подпространства — ортогональная проекция $\mathbf{y}$ на него, а это значит, что вектор остатков должен быть перпендикулярен подпространству, то есть каждому столбцу $\mathbf{X}$:

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}, \quad \mathbf{e} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}. \quad (2)$$



Проекция $\hat{\mathbf{y}}$ — ближайшая к $\mathbf{y}$ точка подпространства $L(\mathbf{X})$; остаток $\mathbf{e}$ перпендикулярен ему. Для любой другой точки $\mathbf{X}\mathbf{b}$ отрезок до $\mathbf{y}$ — гипотенуза прямоугольного треугольника, поэтому он длиннее.

Почему ортогональность даёт минимум. Возьмём произвольное $\mathbf{b}$ и обозначим $\mathbf{d} = \hat{\beta} - \mathbf{b}$. Тогда

$$\mathbf{y} - \mathbf{Xb} = (\mathbf{y} - \mathbf{X}\hat{\beta}) + \mathbf{X}(\hat{\beta} - \mathbf{b}) = \mathbf{e} + \mathbf{Xd},$$

причём слагаемые ортогональны: $(\mathbf{Xd})^\top \mathbf{e} = \mathbf{d}^\top (\mathbf{X}^\top \mathbf{e}) = 0$ по (2). По теореме Пифагора

$$\|\mathbf{y} - \mathbf{Xb}\|^2 = \|\mathbf{e}\|^2 + \|\mathbf{Xd}\|^2 \geq \|\mathbf{e}\|^2,$$

и равенство достигается только при $\mathbf{Xd} = \mathbf{0}$, то есть (снова по предпосылке 2) при $\mathbf{d} = \mathbf{0}$. Значит, минимум единственный и достигается в точке, задаваемой условием (2).

Осталось раскрыть (2). Подставив $\mathbf{e} = \mathbf{y} - \mathbf{X}\hat{\beta}$, получаем *нормальные уравнения*:

$$\mathbf{X}^\top (\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X}^\top \mathbf{X}\hat{\beta} = \mathbf{X}^\top \mathbf{y}.$$

Матрица $\mathbf{X}^\top \mathbf{X}$ обратима, поскольку $\mathbf{X}$ имеет полный ранг, — умножая на $(\mathbf{X}^\top \mathbf{X})^{-1}$, получаем **МНК-оценку вектора коэффициентов**:

$$\boxed{\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}} \quad (3)$$

Никакого дифференцирования по вектору здесь не понадобилось: всё свелось к тому, что кратчайшее расстояние до подпространства даёт перпендикуляр.

Два следствия. Во-первых, если первый столбец $\mathbf{X}$ состоит из единиц, то одно из равенств (2) — это в точности $\sum e_t = 0$: остатки в сумме дают нуль. Во-вторых, разложение $\text{TSS} = \text{RSS} + \text{ESS}$ — та же теорема Пифагора, только применённая к отклонениям от среднего: вектор с координатами $Y_t - \bar{Y}$ раскладывается на подогнанную часть с координатами $\hat{Y}_t - \bar{Y}$ и перпендикулярный ей остаток e .

Математическое ожидание и дисперсия оценки. Подставив (1) в (3), выразим оценку через истинные коэффициенты и ошибки модели:

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{X}\beta + \varepsilon) = \beta + \mathbf{A}\varepsilon, \quad \mathbf{A} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top. \quad (4)$$

Матрица $\mathbf{A}$ детерминирована (предпосылка 2), поэтому её выносят за знак математического ожидания как постоянный множитель. Отсюда сразу несмещённость:

$$\mathbb{E}\hat{\beta} = \beta + \mathbf{A} \mathbb{E}\varepsilon = \beta \quad (\text{предпосылка 3a}).$$

Для вектора дисперсия — это матрица ковариаций: на диагонали стоят дисперсии координат, вне диагонали — их попарные ковариации,

$$\mathbb{D}(\mathbf{z}) = \mathbb{E}[(\mathbf{z} - \mathbb{E}\mathbf{z})(\mathbf{z} - \mathbb{E}\mathbf{z})^\top], \quad \text{в частности} \quad \mathbb{E}[\varepsilon\varepsilon^\top] = \mathbb{D}(\varepsilon) = \sigma^2 \mathbf{I}_n$$

по предпосылкам 3a и 3b. Подставляя (4) и учитывая, что при транспонировании произведения порядок сомножителей меняется, $(\mathbf{A}\varepsilon)^\top = \varepsilon^\top \mathbf{A}^\top$, а $(\mathbf{X}^\top \mathbf{X})^{-1}$ симметрична, а значит $\mathbf{A}^\top = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$:

$$\begin{aligned} \mathbb{D}(\hat{\beta}) &= \mathbb{E}[(\hat{\beta} - \mathbb{E}\hat{\beta})(\hat{\beta} - \mathbb{E}\hat{\beta})^\top] = \mathbb{E}[(\hat{\beta} - \beta)(\hat{\beta} - \beta)^\top] \\ &= \mathbb{E}[(\mathbf{A}\varepsilon)(\mathbf{A}\varepsilon)^\top] = \mathbb{E}[\mathbf{A}\varepsilon\varepsilon^\top \mathbf{A}^\top] = \mathbf{A} \mathbb{E}[\varepsilon\varepsilon^\top] \mathbf{A}^\top = \sigma^2 \mathbf{A} \mathbf{A}^\top \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \end{aligned}$$

Итого при предпосылках 1–3b

$$\begin{aligned} \mathbb{E}\hat{\beta} &= \beta, & \mathbb{D}(\hat{\beta}) &= \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}, \\ s^2 &= \frac{\text{ESS}}{n-k} = \frac{\sum e_t^2}{n-k} = \frac{\mathbf{e}^\top \mathbf{e}}{n-k}, & \mathbb{E}s^2 &= \sigma^2. \end{aligned} \quad (5)$$

На диагонали матрицы $\mathbb{D}(\hat{\beta})$ стоят дисперсии отдельных коэффициентов:

$$\mathbb{D}(\hat{\beta}_j) = \sigma^2 [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj},$$

так что, заменив неизвестную σ^2 её несмещённой оценкой s^2 , получаем стандартные ошибки коэффициентов. По теореме Гаусса–Маркова МНК-оценка эффективна в классе линейных несмещённых оценок (семинар 2 — парный случай). Стандартная ошибка j -го коэффициента и t -статистика:

$$s_{\hat{\beta}_j} = s \sqrt{[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}}, \quad t = \frac{\hat{\beta}_j - \beta_j^0}{s_{\hat{\beta}_j}} \sim t(n-k) \quad \text{при } H_0: \beta_j = \beta_j^0. \quad (6)$$

Степеней свободы $n - k$: из n наблюдений вычитается k оценённых коэффициентов.

1.2. Качество подгонки и сравнение моделей

При наличии свободного члена сохраняется разложение сумм квадратов

$$\underbrace{\sum (Y_t - \bar{Y})^2}_{\text{TSS}} = \underbrace{\sum (\hat{Y}_t - \bar{Y})^2}_{\text{RSS}} + \underbrace{\sum (Y_t - \hat{Y}_t)^2}_{\text{ESS}}, \quad \text{ESS} = \sum e_t^2 = \mathbf{e}^\top \mathbf{e}, \quad (7)$$

и на нём построен коэффициент детерминации

$$R^2 = \frac{\text{RSS}}{\text{TSS}} = 1 - \frac{\text{ESS}}{\text{TSS}}. \quad (8)$$

Здесь TSS зависит только от $\mathbf{y}$, то есть от данных, а не от модели, — при добавлении регрессора он не меняется. А ESS — это минимум квадрата расстояния от $\mathbf{y}$ до $L(\mathbf{X})$, и добавление столбца $\mathbf{x}_{k+1}$ расширяет подпространство, так что минимум берётся по более широкому множеству:

$$\text{ESS}_{k+1} = \min_{\mathbf{b}, c} \|\mathbf{y} - \mathbf{X}\mathbf{b} - c\mathbf{x}_{k+1}\|^2 \leq \|\mathbf{y} - \mathbf{X}\hat{\beta} - 0 \cdot \mathbf{x}_{k+1}\|^2 = \|\mathbf{y} - \mathbf{X}\hat{\beta}\|^2 = \text{ESS}_k :$$

старая подгонка по-прежнему доступна — она получается при $c = 0$, — поэтому новый минимум не может быть больше. Отсюда

$$R_{k+1}^2 = 1 - \frac{\text{ESS}_{k+1}}{\text{TSS}} \geq 1 - \frac{\text{ESS}_k}{\text{TSS}} = R_k^2,$$

причём равенство лишь в вырожденном случае $\hat{c} = 0$. Значит, R^2 не убывает от добавления *любого* регрессора, даже бессмысленного, и сравнивать по нему модели с разным числом регрессоров нельзя. Для сравнения используют скорректированный коэффициент детерминации и информационные критерии:

$$R_{\text{adj}}^2 = 1 - \frac{\text{ESS}/(n-k)}{\text{TSS}/(n-1)} = 1 - \frac{n-1}{n-k} (1 - R^2) = R^2 - \frac{k-1}{n-k} (1 - R^2), \quad (9)$$

$$\text{AIC} = \frac{2k}{n} + \ln \frac{\text{ESS}}{n}, \quad \text{BIC} = \frac{k \ln n}{n} + \ln \frac{\text{ESS}}{n}. \quad (10)$$

В (9) каждая сумма квадратов делится на свои степени свободы, так что добавление регрессора увеличивает R_{adj}^2 только тогда, когда выигрыш в ESS перевешивает потерю степени свободы. Критерии AIC и BIC устроены так же: первое слагаемое — штраф за число параметров, второе — качество подгонки; лучше та модель, у которой критерий *меньше*. У BIC штраф строже, поэтому он выбирает более экономные модели.

1.3. Проверка гипотез: t - и F -тесты

Отдельный коэффициент проверяется t -статистикой (6): гипотеза $H_0: \beta_j = 0$ отвергается на уровне 5 %, если $|t| > t_{0,025}(n - k)$.

Значимость регрессии *в целом* — это гипотеза $H_0: \beta_2 = \dots = \beta_k = 0$ (все коэффициенты, кроме свободного члена, равны нулю). Её проверяют статистикой

$$F = \frac{\text{RSS}/(k - 1)}{\text{ESS}/(n - k)} = \frac{R^2}{1 - R^2} \cdot \frac{n - k}{k - 1} \sim F(k - 1, n - k), \quad (11)$$

второе равенство получается делением числителя и знаменателя на TSS. Гипотеза отвергается при $F > F_{0,05}(k - 1, n - k)$. В парной регрессии ($k = 2$) $F = t^2$, и оба теста совпадают.

P -значение. Это вероятность получить статистику не менее экстремальную, чем наблюдаённая, *при верной H_0* :

$$P = \Pr\{|t(n - k)| > |t_{\text{набл}}|\}, \quad P = \Pr\{F(k - 1, n - k) > F_{\text{набл}}\}$$

для t - и F -теста соответственно (t -тест двусторонний, поэтому берётся модуль; для F -теста против H_0 говорят только большие значения). Правило решения:

$$P < 0,05 \implies H_0 \text{ отвергается на 5\%-ном уровне}, \quad P \geq 0,05 \implies \text{не отвергается},$$

и так же для любого другого уровня значимости: гипотеза отвергается, если P меньше него. Это то же самое сравнение, что и с критическим значением, только записанное с другой стороны: вместо «на сколько статистика превысила порог» смотрят, «насколько редким был бы такой результат при H_0 ». Удобство в том, что одно число сразу даёт ответ для всех уровней: при $P = 0,03$ гипотеза отвергается на 5 %-ном уровне и не отвергается на 1 %-ном. Именно P -значения печатают эконометрические пакеты — столбец *Probability* в таблицах решений ниже.

Замечание. P -значение — это не вероятность того, что H_0 верна, и не мера силы связи. Малое P означает лишь, что при верной H_0 такие данные встречались бы редко. Коэффициент может быть значим (P мало) и при этом ничтожно мал по величине: статистическая значимость и содержательная важность — разные вещи.

1.4. Тест на линейные ограничения

Пусть на коэффициенты наложено q линейных ограничений (например, часть коэффициентов равна нулю). Оценим модель дважды: без ограничений (UR) и с ограничениями (R). Так как ограничение сужает множество допустимых коэффициентов, всегда $\text{ESS}_R \geq \text{ESS}_{UR}$. Вопрос в том, велик ли прирост:

$$F = \frac{(\text{ESS}_R - \text{ESS}_{UR})/q}{\text{ESS}_{UR}/(n - k)} \sim F(q, n - k), \quad (12)$$

где k — число параметров модели без ограничений. Если обе модели оценены по одним и тем же данным, TSS у них одинакова, и (12) можно записать через коэффициенты детерминации:

$$F = \frac{(R_{UR}^2 - R_R^2)/q}{(1 - R_{UR}^2)/(n - k)}.$$

Частные случаи: при $q = k - 1$ (все коэффициенты, кроме константы, равны нулю) формула (12) превращается в (11); при $q = 1$ получается $F = t^2$.

1.5. Тест Чоу на структурный сдвиг

Пусть выборка разбита на две части объёмом n_1 и n_2 ($n_1 + n_2 = n$), и проверяется гипотеза H_0 о том, что коэффициенты в обеих частях одинаковы. Оценим регрессию трижды: по всей выборке (ESS_R) и отдельно по каждой части (ESS_1 и ESS_2). Тогда

$$F = \frac{(ESS_R - (ESS_1 + ESS_2))/k}{(ESS_1 + ESS_2)/(n - 2k)} \sim F(k, n - 2k). \quad (13)$$

Замечание. Тест Чоу — частный случай (12). Введём фиктивную переменную D , равную единице для второй подвыборки, и оценим модель со всеми регрессорами, умноженными на D : $y = X\beta + (D \cdot X)\gamma + \varepsilon$. Такая модель подгоняет обе подвыборки независимо, поэтому её ESS равна $ESS_1 + ESS_2$, а гипотеза $H_0: \gamma = 0$ — это $q = k$ ограничений. Подстановка в (12) даёт в точности (13).

1.6. Фиктивные переменные

Фиктивная (дамми) переменная d принимает значения 0 и 1 и позволяет включить в регрессию качественный признак:

$$y_t = \alpha + \beta x_t + \gamma d_t + \varepsilon_t \quad \text{и} \quad y_t = \alpha + \beta x_t + \gamma d_t + \delta (d_t x_t) + \varepsilon_t. \quad (14)$$

В первой модели признак сдвигает свободный член: при $d = 1$ прямая поднимается на γ , наклон общий. Во второй добавлено взаимодействие $d \cdot x$, поэтому меняется и наклон: он равен β при $d = 0$ и $\beta + \delta$ при $d = 1$. Гипотеза «признак ничего не меняет» — это $H_0: \gamma = \delta = 0$, то есть $q = 2$ ограничения в (12).

Ловушка фиктивных переменных. Если признак принимает m значений, в модель со свободным членом включают только $m - 1$ фиктивную переменную. Иначе их сумма равна столбцу единиц, столбцы X линейно зависимы, предпосылка 2 нарушена и оценка (3) не существует. Пропущенная категория становится базовой, а коэффициенты показывают отклонение от неё.

Сезонность. Для квартальных данных вводят три фиктивные переменные $QRT1$, $QRT2$, $QRT3$ (четвёртый квартал — база). Проверка наличия сезонности — это F -тест (12) совместной значимости всех трёх коэффициентов, а не три отдельных t -теста.

Перелом наклона в точке. Если наклон меняется при переходе через пороговое значение x^* , берут переменную $(x_t - x^*)s_t$, где $s_t = 1$ при $x_t > x^*$ и $s_t = 0$ иначе. Тогда наклон равен β слева от порога и $\beta + \gamma$ справа, а сама функция в точке x^* не разрывается.

1.7. Тест Рамсея (RESET)

Тест проверяет, не потеряна ли нелинейность, то есть верна ли функциональная форма. Оценивают исходную регрессию, сохраняют подогнанные значения $\hat{y}_t$ и оценивают расширенную модель

$$y_t = \mathbf{x}_t^\top \boldsymbol{\beta} + \gamma_1 \hat{y}_t^2 + \dots + \gamma_p \hat{y}_t^{p+1} + \varepsilon_t, \quad (15)$$

после чего проверяют $H_0: \gamma_1 = \dots = \gamma_p = 0$ по (12) со статистикой $F(p, n - k - p)$. Отвержение H_0 означает, что линейная спецификация неадекватна: степени $\hat{y}_t$ подхватывают пропущенную нелинейность.

1.8. Мультиколлинеарность и VIF

Точная мультиколлинеарность — линейная зависимость столбцов $\mathbf{X}$ — нарушает предпосылку 2: матрица $\mathbf{X}^\top \mathbf{X}$ вырождена и оценка (3) не существует. На практике опаснее сильная, но не точная связь регрессоров: оценки существуют, но

- дисперсии (5) велики, оценки неустойчивы — небольшое изменение данных сильно меняет коэффициенты;
- отдельные t -статистики малы, хотя F -тест (11) уверенно отвергает незначимость регрессии в целом;
- знаки коэффициентов могут противоречить содержательному смыслу.

Диагностика — *фактор инфляции дисперсии*. Для j -го регрессора оценивают вспомогательную регрессию этого регрессора на все остальные и берут её коэффициент детерминации R_j^2 :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad \mathbb{D}(\hat{\beta}_j) = \text{VIF}_j \cdot \frac{\sigma^2}{\sum_t (x_{tj} - \bar{x}_j)^2}. \quad (16)$$

Вторая формула объясняет название: VIF_j показывает, во сколько раз дисперсия оценки больше, чем была бы при регрессорах, не связанных друг с другом. Обычное эмпирическое правило: $\text{VIF}_j > 10$, то есть $R_j^2 > 0,9$, — признак серьёзной мультиколлинеарности.

2. Задачи

Задача 4.4


Предположим, что вы оцениваете линейную функцию потребления $c_t = \alpha + \beta y_t + \varepsilon_t$ среди n индивидуумов. Как учесть возможный сдвиг этой функции при переходе от городского к сельскому потребителю, если вы считаете, что предельная (маржинальная) склонность к потреблению постоянна, в то время как средняя склонность к потреблению может меняться? Как проверить гипотезу о том, что предельные склонности к потреблению индивидуумов с доходом выше и ниже уровня y^* отличаются?

Решение. 1) Сдвиг при переходе от города к селу. Предельная склонность к потреблению — это прирост потребления на единицу дохода, то есть $\partial c / \partial y = \beta$. Средняя склонность — доля дохода, идущая на потребление:

$$\frac{c}{y} = \frac{\alpha}{y} + \beta,$$

она зависит не только от β , но и от α . Значит, требование « β постоянна, а средняя склонность может меняться» означает, что при переходе от города к селу меняется только свободный член. По (14) вводим фиктивную переменную $r_t = 0$ для городского потребителя и $r_t = 1$ для сельского:

$$c_t = \alpha + \beta y_t + \gamma r_t + \varepsilon_t.$$



Сплошные линии — функции потребления. Наклон у них общий, β : предельная склонность одинакова (треугольники приращений равны). Сельская прямая сдвинута на γ . Пунктирные лучи из начала координат к точкам при одном и том же доходе y_0 имеют наклоны c/y , то есть это средние склонности к потреблению. Из-за сдвига они различаются: $(\alpha + \gamma)/y_0 + \beta$ против $\alpha/y_0 + \beta$.

Наличие сдвига — это гипотеза $H_0: \gamma = 0$, которая проверяется t -статистикой (6) с $n - 3$ степенями свободы.

2) Разные предельные склонности выше и ниже уровня y^* . Теперь меняться должен наклон, причём только для индивидуумов с доходом выше y^* . По п. 1.6 вводим $s_t = 0$ при $y_t \leq y^*$ и $s_t = 1$ при $y_t > y^*$ и оцениваем

$$c_t = \alpha + \beta y_t + \gamma (y_t - y^*) s_t + \varepsilon_t.$$

Предельная склонность к потреблению равна

$$\frac{\partial c}{\partial y} = \begin{cases} \beta, & y \leq y^*, \\ \beta + \gamma, & y > y^*, \end{cases}$$

поэтому проверяемая гипотеза — снова $H_0: \gamma = 0$. Множитель $(y_t - y^*)$ вместо просто y_t выбран для того, чтобы функция потребления не имела разрыва в точке y^* : при $y_t = y^*$ добавка обращается в нуль.

Задача 4.6

На основе квартальных данных с 1971 по 1976 г. с помощью метода наименьших квадратов получено следующее уравнение:

$$y_t = 1,12 - 0,0098 x_{t1} - 5,62 x_{t2} + 0,044 x_{t3},$$

(2,14)
(0,0034)
(3,42)
(0,009)

в скобках указаны стандартные ошибки, $RSS = 110,32$, $ESS = 21,43$.

- а) Проверьте значимость каждого из коэффициентов.
- б) Найдите коэффициент детерминации.
- в) Протестируйте значимость регрессии в целом.
- г) Когда в уравнение были добавлены три фиктивные переменные, соответствующие трём первым кварталам года, величина RSS выросла до 118,20. Проверьте гипотезу о наличии сезонности, сформулировав необходимые предположения о виде этой сезонности.
- д) Для той же исходной модели были отдельно проведены две регрессии на основе данных: 1-й квартал 1971 г. — 1-й квартал 1975 г. и 2-й квартал 1975 г. — 4-й квартал 1976 г. соответственно, и получены следующие значения сумм квадратов остатков: $ESS_1 = 12,25$, $ESS_2 = 2,32$. Проверьте гипотезу о том, что между 1-м и 2-м кварталами 1975 г. произошло структурное изменение.

Решение. Здесь $n = 24$ (шесть лет по четыре квартала) и $k = 4$, поэтому $n - k = 20$.

а) Для каждого коэффициента проверяем $H_0: \beta_i = 0$ по (6), сравнивая $|t_i| = |\hat{\beta}_i|/s_{\hat{\beta}_i}$ с $t_{0,025}(20) = 2,086$:

$$|t_1| = \frac{1,12}{2,14} = 0,523, \quad |t_2| = \frac{0,0098}{0,0034} = 2,882,$$

$$|t_3| = \frac{5,62}{3,42} = 1,643, \quad |t_4| = \frac{0,044}{0,009} = 4,889.$$

Значимы второй и четвёртый коэффициенты (при x_{t1} и x_{t3}); свободный член и коэффициент при x_{t2} на 5 %-ном уровне незначимы.

б) По (8), учитывая $TSS = RSS + ESS = 110,32 + 21,43 = 131,75$:

$$R^2 = \frac{RSS}{TSS} = \frac{110,32}{131,75} = 0,837.$$

в) Гипотеза $H_0: \beta_2 = \beta_3 = \beta_4 = 0$ проверяется по (11):

$$F = \frac{RSS}{ESS} \cdot \frac{n - k}{k - 1} = \frac{110,32}{21,43} \cdot \frac{20}{3} = 34,319 > 3,098 = F_{0,05}(3, 20),$$

то есть регрессия в целом значима.

г) Три фиктивные переменные для первых трёх кварталов (четвёртый — базовый) означают, что сезонность сдвигает среднее значение y , а наклоны при x_{t1} , x_{t2} , x_{t3} одинаковы во всех кварталах:

$$y_t = \beta_1 + \beta_2 x_{t1} + \beta_3 x_{t2} + \beta_4 x_{t3} + \beta_5 d_{t1} + \beta_6 d_{t2} + \beta_7 d_{t3} + \varepsilon_t.$$

Отсутствие сезонности — это $H_0: \beta_5 = \beta_6 = \beta_7 = 0$, то есть $q = 3$ ограничения; в модели без ограничений $k = 7$ и $n - k = 17$. Так как TSS у обеих моделей одна и та же,

$$ESS_R - ESS_{UR} = RSS_{UR} - RSS_R = 118,20 - 110,32 = 7,88,$$

$$ESS_{UR} = TSS - RSS_{UR} = 131,75 - 118,20 = 13,55,$$

и по (12)

$$F = \frac{7,88/3}{13,55/17} = 3,295 > 3,197 = F_{0,05}(3, 17).$$

Гипотезу об отсутствии сезонности отвергаем: сезонность есть.

д) Это тест Чоу (13) с $k = 4$ и $n = 24$:

$$ESS_R = 21,43, \quad ESS_1 + ESS_2 = 12,25 + 2,32 = 14,57,$$

$$F = \frac{(21,43 - 14,57)/4}{14,57/16} = 1,883 < 3,007 = F_{0,05}(4, 16).$$

Гипотеза об отсутствии структурного изменения не отвергается: данные не дают оснований утверждать, что между 1-м и 2-м кварталами 1975 г. произошёл перелом.

Задача 4.14

В таблице представлены совокупный объём внутренних инвестиций y и валовой внутренний продукт США (млрд долл.) за период с 1939 по 1954 г.

Год	y	x	Год	y	x
1939	9,3	90,8	1947	34,0	232,8
1940	13,1	100,0	1948	45,9	259,1
1941	17,9	124,9	1949	35,3	258,0
1942	9,9	158,3	1950	53,8	286,2
1943	5,8	192,0	1951	59,2	330,2
1944	7,2	210,5	1952	52,1	347,2
1945	10,6	212,3	1953	53,3	366,1
1946	30,7	209,3	1954	52,7	366,3

Напишите и оцените уравнения, позволяющие ответить на вопрос, изменилась ли зависимость инвестиций от валового внутреннего продукта во время войны (1942–1945 гг.) по сравнению с мирным временем.

В Excel. Данные вводятся двумя столбцами, y и x . Для модели с фиктивной переменной добавьте ещё два столбца: =ЕСЛИ(И(A2>=1942;A2<=1945);1;0) для D и произведение =D2*C2 для $D \cdot x$ (здесь A — год, C — x).

Дальше Данные → Анализ данных → Регрессия. Чтобы получить тест Чоу вручную, проведите три регрессии: по всем 16 наблюдениям, по 12 мирным годам и по 4 военным, и возьмите из отчётов строку Остаток столбца SS — это ESS.

Решение. Военные годы заметно выпадают из общей картины: при растущем ВВП инвестиции в 1942–1945 гг. падают. Проверим это формально.

1) Регрессия по всем наблюдениям ($n = 16$, $k = 2$):

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	-14,362	7,543	-1,904	0,0777
x	0,192	0,030	6,368	0,0000
$R^2 = 0,7434$; $ESS_R = 1540,33$				

2) Та же регрессия без военных лет ($n = 12$):

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	-3,335	4,086	-0,816	0,4334
x	0,167	0,015	10,872	0,0000
$R^2 = 0,9220$; $ESS_1 = 260,12$				

Во второй регрессии и t -статистика наклона, и коэффициент детерминации заметно выше: без военных лет зависимость гораздо теснее.

3) Регрессия только по военным годам ($n = 4$):

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	11,244	12,220	0,920	0,4546
x	-0,015	0,063	-0,236	0,8352
$R^2 = 0,0272$; $ESS_2 = 14,87$				

Четыре наблюдения при двух оцениваемых параметрах оставляют $n - k = 2$ степени свободы, поэтому оценки крайне неточны: наклон меняет знак, но незначим ($P = 0,84$), а R^2 практически нулевой. Сама по себе эта регрессия ничего не доказывает — она нужна, чтобы получить ESS_2 для теста Чоу. Заодно видно, чем именно различаются периоды: в мирные годы инвестиции растут вместе с ВВП, в военные связь пропадает.

4) Тест Чоу. Разобьём выборку на мирное время (1939–1941, 1946–1954; $n_1 = 12$) и военное (1942–1945; $n_2 = 4$). Остаточные суммы уже посчитаны: ESS_R из п. 1), ESS_1 из п. 2), ESS_2 из п. 3). По (13) при $k = 2$, $n = 16$

$$F = \frac{(ESS_R - (ESS_1 + ESS_2))/k}{(ESS_1 + ESS_2)/(n - 2k)} = \frac{(ESS_R - (ESS_1 + ESS_2))/2}{(ESS_1 + ESS_2)/12},$$

$$F = \frac{(1540,33 - (260,12 + 14,87))/2}{(260,12 + 14,87)/12} = \frac{1265,34/2}{274,99/12} = 27,608 > 3,885 = F_{0,05}(2, 12).$$

Гипотеза о совпадении моделей уверенно отвергается (P -значение практически нулевое): во время войны зависимость инвестиций от ВВП была иной.

5) То же через фиктивную переменную. Введём $D_t = 1$ для 1942–1945 гг. и $D_t = 0$ иначе и оценим по всем 16 наблюдениям модель с взаимодействием (14):

$$y_t = \beta_1 + \beta_2 x_t + \beta_3 D_t + \beta_4 (D_t x_t) + \varepsilon_t.$$

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	-3,335	3,836	-0,870	0,4016
x	0,167	0,014	11,583	0,0000
D	14,579	21,793	0,669	0,5162
$D \cdot x$	-0,182	0,111	-1,638	0,1273
$R^2 = 0,9542$; $ESS_{UR} = 274,99$				

Коэффициенты при x и при константе в точности совпали с мирной регрессией: базовая группа — мирное время, — а суммы $\hat{\beta}_1 + \hat{\beta}_3 = -3,335 + 14,579 = 11,244$ и $\hat{\beta}_2 + \hat{\beta}_4 = 0,167 - 0,182 = -0,015$ воспроизводят военную регрессию из п. 3). Остаточная сумма этой модели равна $260,12 + 14,87 = 274,99$, то есть сумме остаточных сумм двух отдельных регрессий, как и сказано в замечании к п. 1.5. Поэтому F -тест гипотезы $H_0: \beta_3 = \beta_4 = 0$ по (12) даёт то же значение $F = 27,608$.

Замечание. По отдельности ни D ($P = 0,52$), ни $D \cdot x$ ($P = 0,13$) не значимы, а вместе они значимы с P -значением порядка 10^{-5} . Это типичная картина при коррелированных регрессорах (п. 1.8): D и $D \cdot x$ связаны почти функционально, поэтому каждый по отдельности оценивается неточно. Вывод о структурном сдвиге нужно делать по совместному F -тесту, а не по отдельным t -статистикам.

Задача 4.15

В таблице представлены квартальные данные об объёмах продаж и доходах текстильных корпораций США с первого квартала 1974 г. по третий квартал 1979 г. Введите сезонные фиктивные переменные и с помощью регрессии дохода на объём продаж исследуйте наличие или отсутствие сезонных колебаний.

Год	Кв.	Продажи	Доход	Год	Кв.	Продажи	Доход
1974	I	242,0	13,5	1977	I	311,5	15,6
	II	269,4	16,3		II	338,6	19,7
	III	272,1	15,5		III	331,7	16,7
	IV	277,0	13,4		IV	346,2	18,4
1975	I	247,1	9,3	1978	I	340,2	16,0
	II	265,8	12,4		II	377,5	22,1
	III	271,0	13,2		III	376,9	20,4
	IV	281,3	14,2		IV	401,8	22,6
1976	I	284,2	14,8	1979	I	406,2	22,6
	II	307,6	18,1		II	436,4	26,8
	III	301,6	16,0		III	437,5	24,8
	IV	309,8	15,6				

В Excel. Столбцы VOL (продажи) и INC (доход) вводятся как есть. Квартальные фиктивные переменные удобно получить формулой по номеру квартала: если номер квартала стоит в столбце B, то =ЕСЛИ(\$B2=1;1;0) для QRT1 и так далее.

Включайте только три фиктивные переменные из четырёх. Если добавить все четыре, их сумма совпадёт со столбцом единиц, и Excel выдаст ошибку или нулевые коэффициенты — это ловушка фиктивных переменных.

Решение. Обозначим через VOL объём продаж, через INC — доход; $n = 23$ наблюдения.

1) Регрессия без сезонности.

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	−5,056	1,682	−3,006	0,0067
VOL	0,069	0,005	13,503	0,0000

$R^2 = 0,8967$; $ESS_R = 42,04$; $n - k = 21$

2) Добавляем сезонные фиктивные переменные. Вводим $QRT_i = 1$, если наблюдение относится к i -му кварталу, и 0 иначе. В регрессию включаем только QRT_1 , QRT_2 , QRT_3 : четвёртый квартал — базовый (п. 1.6).

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	−4,874	1,568	−3,109	0,0061
VOL	0,067	0,005	14,791	0,0000
QRT_1	−0,329	0,749	−0,440	0,6655
QRT_2	1,767	0,746	2,368	0,0293
QRT_3	0,350	0,746	0,470	0,6443

$R^2 = 0,9331$; $ESS_{UR} = 27,23$; $n - k = 18$

По отдельности значим лишь коэффициент при QRT_2 ($P = 0,029$). Но вопрос «есть ли сезонность» — это совместная гипотеза $H_0: \gamma_1 = \gamma_2 = \gamma_3 = 0$, то есть $q = 3$ ограничения в (12). Модель с ограничениями — регрессия из п. 1) ($ESS_R = 42,04$), без ограничений — из п. 2) ($ESS_{UR} = 27,23$, $n - k = 23 - 5 = 18$):

$$F = \frac{(ESS_R - ESS_{UR})/q}{ESS_{UR}/(n - k)} = \frac{(ESS_R - ESS_{UR})/3}{ESS_{UR}/18},$$

$$F = \frac{(42,04 - 27,23)/3}{27,23/18} = 3,262 > 3,160 = F_{0,05}(3, 18), \quad P = 0,046.$$

Гипотезу об отсутствии сезонности отвергаем, хотя и на грани.

3) Какие кварталы отличаются. Проверим, можно ли убрать QRT_1 и QRT_3 , то есть $H_0: \gamma_1 = \gamma_3 = 0$ ($q = 2$). Модель с ограничением — регрессия на VOL и QRT_2 , теперь для неё $ESS_R = 28,58$; модель без ограничений та же, что в п. 2), $ESS_{UR} = 27,23$. По (12)

$$F = \frac{(ESS_R - ESS_{UR})/q}{ESS_{UR}/(n - k)} = \frac{(ESS_R - ESS_{UR})/2}{ESS_{UR}/18},$$

$$F = \frac{(28,58 - 27,23)/2}{27,23/18} = 0,445 < 3,555 = F_{0,05}(2, 18).$$

Гипотеза не отвергается: первый и третий кварталы от базового четвёртого не отличаются. Итоговая модель:

Переменная	Коэффициент	Ст. ошибка	<i>t</i> -статистика	<i>P</i> -значение
const	−5,096	1,421	−3,585	0,0018
<i>VOL</i>	0,068	0,004	15,610	0,0000
<i>QRT2</i>	1,750	0,570	3,069	0,0061
$R^2 = 0,9298; \quad R^2_{\text{adj}} = 0,9228$				

Вывод. Сезонность есть, но сводится к одному кварталу: при одном и том же объёме продаж доход во втором квартале в среднем выше на 1,75 млн долл., чем в остальных. Заметим, что R^2 при переходе от модели с тремя фиктивными переменными к модели с одной снизился (0,9331 против 0,9298), а скорректированный коэффициент (9) вырос (0,9182 против 0,9228): по критерию (9) экономная модель лучше.