

Семинар 4

Структурные сдвиги и мультиколлинеарность

Условия и решения

1. Основные формулы

1.1. Модель и основные тесты

Модель множественной регрессии в матричной форме:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}, \quad \mathbb{D}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}, \quad (1)$$

где $\mathbf{X}$ — матрица регрессоров размера $n \times k$, k — число параметров *вместе* со свободным членом. Оценка существует только тогда, когда столбцы $\mathbf{X}$ линейно независимы: иначе матрица $\mathbf{X}^\top \mathbf{X}$ вырождена.

Отдельный коэффициент проверяется t -тестом, а значимость регрессии в целом — F -тестом:

$$t = \frac{\hat{\beta}_j}{s_{\hat{\beta}_j}} \sim t(n - k), \quad F = \frac{\text{RSS}/(k - 1)}{\text{ESS}/(n - k)} = \frac{R^2}{1 - R^2} \cdot \frac{n - k}{k - 1} \sim F(k - 1, n - k). \quad (2)$$

Как и раньше, RSS — объяснённая сумма квадратов, $\text{ESS} = \sum e_t^2$ — остаточная, $R^2 = \text{RSS}/\text{TSS} = 1 - \text{ESS}/\text{TSS}$. Модели с разным числом регрессоров сравнивают по скорректированному коэффициенту детерминации

$$R_{\text{adj}}^2 = 1 - \frac{\text{ESS}/(n - k)}{\text{TSS}/(n - 1)} = 1 - \frac{n - 1}{n - k} (1 - R^2) = R^2 - \frac{k - 1}{n - k} (1 - R^2). \quad (3)$$

Первая запись — определение: каждая сумма квадратов делится на свои степени свободы. Вторая получается из неё, если учесть $\text{ESS}/\text{TSS} = 1 - R^2$. Третья — раскрытием скобок: она показывает, что $R_{\text{adj}}^2 \leq R^2$ (равенство только при $k = 1$ или $R^2 = 1$), что поправка тем больше, чем больше параметров k при том же n , и что R_{adj}^2 может быть отрицательным.

1.2. Тест на линейные ограничения

Пусть на коэффициенты наложено q линейных ограничений. Модель оценивают без ограничений (UR) и с ограничениями (R); во второй ограничения подставлены в уравнение, так что оцениваемых параметров становится меньше. Всегда $\text{ESS}_R \geq \text{ESS}_{\text{UR}}$, и вопрос в том, велик ли прирост:

$$F = \frac{(\text{ESS}_R - \text{ESS}_{\text{UR}})/q}{\text{ESS}_{\text{UR}}/(n - k)} \sim F(q, n - k), \quad (4)$$

где k — число параметров модели *без* ограничений. Если у обеих моделей одна и та же зависимая переменная, то и TSS одна и та же, и формулу можно переписать через R^2 :

$$F = \frac{(R_{\text{UR}}^2 - R_R^2)/q}{(1 - R_{\text{UR}}^2)/(n - k)}.$$

Замечание. Форма через R^2 верна только при общей зависимой переменной. Если после подстановки ограничения в левой части стоит другая величина (например, $\ln(Q/K)$ вместо $\ln Q$, задача 4.18), то TSS у моделей разные, их R^2 несравнимы, и пользоваться надо только формой (4) через ESS: остатки у обеих моделей измеряют ошибку в одной и той же величине.

1.3. Фиктивные переменные и структурные сдвиги

Фиктивная переменная $D_t \in \{0, 1\}$ позволяет сдвинуть свободный член и изменить наклон:

$$y_t = \alpha + \beta x_t + \gamma D_t + \delta (D_t x_t) + \varepsilon_t : \quad \begin{cases} y = \alpha + \beta x, & D_t = 0, \\ y = (\alpha + \gamma) + (\beta + \delta) x, & D_t = 1. \end{cases} \quad (5)$$

Если структурный сдвиг произошёл в момент t_0 , берут $D_t = 1$ при $t > t_0$ и $D_t = 0$ иначе. Отсутствие сдвига — гипотеза $H_0: \gamma = \delta = 0$, $q = 2$ ограничения в (4).

Несколько сдвигов. Для каждого момента t_j вводится своя пара «фиктивная переменная и её произведение на x ». Если выборка разбита на p частей и в каждой оцениваются все k параметров, модель с фиктивными переменными подгоняет части независимо, поэтому $ESS_{UR} = ESS_1 + \dots + ESS_p$. Тест Чоу для p частей:

$$F = \frac{(ESS_R - (ESS_1 + \dots + ESS_p)) / ((p-1)k)}{(ESS_1 + \dots + ESS_p) / (n - pk)} \sim F((p-1)k, n - pk), \quad (6)$$

где ESS_R — остаточная сумма одной регрессии по всей выборке. При $p = 2$ это обычный тест Чоу.

Излом без скачка. Если функция должна оставаться непрерывной, а меняется только наклон, используют переменную $(x_t - x^*)D_t$: в точке x^* добавка обращается в нуль, и скачка нет.

1.4. Мультиколлинеарность

Строгая (точная) мультиколлинеарность — линейная зависимость столбцов $\mathbf{X}$: найдутся числа $c_1, \dots, c_k$, не все нулевые, такие что $c_1 \mathbf{x}_1 + \dots + c_k \mathbf{x}_k = \mathbf{0}$. Тогда $\text{rank } \mathbf{X} < k$, $\det(\mathbf{X}^T \mathbf{X}) = 0$, и оценка (1) не существует: разные наборы коэффициентов дают один и тот же прогноз, и данные не могут выбрать между ними.

Нестрогая мультиколлинеарность — сильная, но не точная связь регрессоров. Оценки существуют и остаются несмещёнными и эффективными (теорема Гаусса–Маркова не нарушена), но:

- дисперсии оценок велики, и отдельные t -статистики малы, хотя R^2 высокий и F -тест (2) уверенно отвергает незначимость регрессии в целом;
- оценки неустойчивы: добавление или удаление нескольких наблюдений сильно меняет коэффициенты;
- знаки коэффициентов могут противоречить содержательному смыслу.

Причина в том, что коэффициент β_j показывает эффект изменения x_j при неизменных остальных регрессорах, а в данных такие изменения почти не встречаются: регрессоры движутся вместе. Информации для разделения их вкладов мало.

Диагностика.

- 1) Парные коэффициенты корреляции регрессоров: $|r| > 0,8$ — тревожный признак. Но при трёх и более регрессорах линейная связь может быть сильной и при умеренных парных корреляциях.
- 2) *Фактор инфляции дисперсии*. Для j -го регрессора оценивают вспомогательную регрессию x_j на все остальные регрессоры (с константой) и берут её коэффициент детерминации R_j^2 :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad \mathbb{D}(\hat{\beta}_j) = \text{VIF}_j \cdot \frac{\sigma^2}{\sum_t (x_{tj} - \bar{x}_j)^2}. \quad (7)$$

VIF_j показывает, во сколько раз дисперсия оценки больше, чем была бы при регрессоре, не связанном с остальными. Правило: $\text{VIF}_j > 10$ (то есть $R_j^2 > 0,9$) — серьёзная мультиколлинеарность. VIF зависит только от матрицы $\mathbf{X}$, но не от $\mathbf{y}$. При двух регрессорах $R_j^2 = r^2(x_1, x_2)$ и оба VIF одинаковы.

- 3) *F-тест вспомогательной регрессии*. Если в модели m объясняющих переменных (без константы), то во вспомогательной регрессии x_j на остальные $m - 1$ переменных и константу m параметров, и её значимость в целом проверяется по (2):

$$F_j = \frac{R_j^2}{1 - R_j^2} \cdot \frac{n - m}{m - 1} \sim F(m - 1, n - m). \quad (8)$$

Если $F_j > F_{0,05}(m - 1, n - m)$, регрессор x_j значимо линейно связан с остальными.

1.5. Короткая и длинная регрессии

Пусть оценены «длинная» регрессия y на x_1 и x_2 и «короткая» — y только на x_1 (обе с константой), а $\hat{\delta}$ — наклон вспомогательной регрессии x_2 на x_1 . Тогда для МНК-оценок выполняется алгебраическое тождество

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \hat{\delta}, \quad (9)$$

где $\tilde{\beta}_1$ — наклон короткой регрессии, $\hat{\beta}_1, \hat{\beta}_2$ — оценки длинной. Смысл: в короткой регрессии рост x_1 на единицу сопровождается в среднем ростом x_2 на $\hat{\delta}$, и коэффициент $\tilde{\beta}_1$ собирает *оба* эффекта — прямой $\hat{\beta}_1$ и косвенный $\hat{\beta}_2 \hat{\delta}$. Поэтому при сильно связанных регрессорах короткая регрессия хорошо прогнозирует, но её коэффициент нельзя толковать как эффект одного x_1 .

1.6. Способы борьбы с мультиколлинеарностью

- 1) *Ничего не делать*, если цель — прогноз: при сохранении той же связи регрессоров прогноз остаётся точным.
- 2) *Исключить* одну из связанных переменных. Цена — смещение оставшихся коэффициентов (9), если исключённая переменная на самом деле влияет на y .
- 3) *Использовать априорную информацию*: наложить на коэффициенты ограничение, известное из теории (например, $\beta_1 + \beta_2 = 1$), и подставить его в модель. Число оцениваемых параметров уменьшается. Ограничение стоит предварительно проверить по (4).

- 4) *Преобразовать переменные*: перейти к разностям, отношениям (на душу населения, к ВВП), к комбинациям с экономическим смыслом.
- 5) *Увеличить выборку* или найти данные, где регрессоры меняются независимо друг от друга.

1.7. Производственная функция Кобба–Дугласа

Функция $Q = \alpha L^{\beta_1} K^{\beta_2}$ нелинейна, но после логарифмирования становится линейной по параметрам:

$$\ln Q = \ln \alpha + \beta_1 \ln L + \beta_2 \ln K + \varepsilon. \quad (10)$$

Коэффициенты — эластичности: $\beta_1 = \partial \ln Q / \partial \ln L$ — на сколько процентов растёт выпуск при росте труда на 1 %. Сумма $\beta_1 + \beta_2$ — отдача от масштаба: при увеличении обоих факторов в λ раз выпуск растёт в $\lambda^{\beta_1 + \beta_2}$ раз. Постоянная отдача — $\beta_1 + \beta_2 = 1$.

2. Задачи

Задача 4.1

С помощью бинарных переменных напишите уравнение, соответствующее наличию двух структурных изменений в моменты времени t_0 и t_1 (предполагается, что $t_0 < t_1$).

Решение. Пусть y_t — зависимая переменная, x_t — регрессор, наблюдения — временные ряды, $t = 1, \dots, n$. Два структурных изменения делят выборку на три промежутка: $t \leq t_0$, $t_0 < t \leq t_1$ и $t > t_1$.

1) Модель. Вводим по фиктивной переменной на каждый сдвиг:

$$R_t = \begin{cases} 0, & t \leq t_0, \\ 1, & t > t_0, \end{cases} \quad S_t = \begin{cases} 0, & t \leq t_1, \\ 1, & t > t_1, \end{cases}$$

и включаем в регрессию сами переменные и их произведения на x_t (5):

$$y_t = \beta_0 + \beta_1 x_t + \gamma_1 R_t + \delta_1 (R_t x_t) + \gamma_2 S_t + \delta_2 (S_t x_t) + \varepsilon_t.$$

Здесь γ_1, γ_2 сдвигают свободный член, а δ_1, δ_2 меняют наклон. Переменная S_t включается *поверх* R_t , поэтому γ_2 и δ_2 — изменения в момент t_1 по сравнению со вторым промежутком, а не с первым.


2) Уравнения на промежутках. Подставляем значения R_t и S_t :

Промежуток	R_t	S_t	Уравнение на промежутке	Наклон
$t \leq t_0$	0	0	$y = \beta_0 + \beta_1 x$	β_1
$t_0 < t \leq t_1$	1	0	$y = (\beta_0 + \gamma_1) + (\beta_1 + \delta_1) x$	$\beta_1 + \delta_1$
$t > t_1$	1	1	$y = (\beta_0 + \gamma_1 + \gamma_2) + (\beta_1 + \delta_1 + \delta_2) x$	$\beta_1 + \delta_1 + \delta_2$

Скачки. Скачок — разность значений *новой* и *старой* прямой в момент сдвига. Обе прямые берём из таблицы выше и подставляем в них одно и то же значение регрессора — то, что было в момент сдвига:

Сдвиг	Старая прямая в точке сдвига	Новая прямая в точке сдвига	Скачок
t_0	$\beta_0 + \beta_1 x_{t_0}$	$(\beta_0 + \gamma_1) + (\beta_1 + \delta_1) x_{t_0}$	$\gamma_1 + \delta_1 x_{t_0}$
t_1	$(\beta_0 + \gamma_1) + (\beta_1 + \delta_1) x_{t_1}$	$(\beta_0 + \gamma_1 + \gamma_2) + (\beta_1 + \delta_1 + \delta_2) x_{t_1}$	$\gamma_2 + \delta_2 x_{t_1}$

При вычитании всё общее у двух прямых сокращается, и остаётся добавка нового промежутка $\gamma_j + \delta_j x$ в точке сдвига. Здесь γ_j — расстояние между прямыми при $x = 0$, а δ_j — на сколько оно меняется при росте x на единицу. Поэтому скачок не равен γ_j : даже при $\gamma_j = 0$ одна лишь смена наклона даёт скачок $\delta_j x_{t_j}$.



На рисунке $x_t = t$ (линейный тренд). Цвет отрезка — промежуток; пунктир — продолжение прямой предыдущего промежутка, стрелка — скачок в момент сдвига.

3) Проверка гипотез — по (4), в модели $k = 6$ параметров:

Что проверяем	H_0	q
нет сдвига в момент t_0	$\gamma_1 = \delta_1 = 0$	2
нет сдвига в момент t_1	$\gamma_2 = \delta_2 = 0$	2
нет ни одного сдвига	$\gamma_1 = \delta_1 = \gamma_2 = \delta_2 = 0$	4

Последняя гипотеза — тест Чоу (6) для $p = 3$ частей: модель с фиктивными переменными подгоняет три промежутка независимо, так что $ESS_{UR} = ESS_1 + ESS_2 + ESS_3$, а ESS_R — остаточная сумма одной регрессии по всей выборке:

$$F = \frac{(ESS_R - ESS_{UR})/q}{ESS_{UR}/(n - k)} = \frac{(ESS_R - (ESS_1 + ESS_2 + ESS_3))/4}{(ESS_1 + ESS_2 + ESS_3)/(n - 6)} \sim F(4, n - 6).$$

Задача 10.4 (Бородич)

В следующей таблице приведены данные по реальному валовому национальному продукту (*GNP*), реальному объёму потребления (*CONS*) и объёму инвестиций (*INV*) для некоторой вымышленной страны.

<i>GNP</i>	240	248	261	274	273	269	283	296	312	319
<i>CONS</i>	149	154	162	169	167	171	180	188	196	200
<i>INV</i>	38,2	41,9	46,5	52,1	48,1	38,3	45,4	52,1	56,8	57,5

<i>GNP</i>	318	325	317	327	350	361	372	385	402	412
<i>CONS</i>	200	202	205	215	225	235	245	252	261	266
<i>INV</i>	50,9	54,5	44,7	50,4	65,8	63,7	64,0	76,4	71,6	71,8

- Постройте уравнение регрессии $INV = b_0 + b_1 GNP + b_2 CONS + e$.
- Оцените качество построенного уравнения.
- Можно ли было ожидать при построении данного уравнения наличия мультиколлинеарности? Ответ поясните.
- Имеет ли место мультиколлинеарность для построенного вами уравнения? Как вы это определили?
- Постройте уравнения регрессии *INV* на *GNP* и *INV* на *CONS*. Какие выводы можно сделать по построенным моделям?
- Постройте уравнение регрессии *CONS* на *GNP*. Что обнаруживает построенная модель?
- Как можно решить проблему мультиколлинеарности для первоначальной модели?

В Excel. Введите данные тремя столбцами *GNP*, *CONS*, *INV* (20 строк). Регрессию с двумя регрессорами даёт Данные → Анализ данных → Регрессия: входной интервал *Y* — столбец *INV*, входной интервал *X* — оба столбца *GNP* и *CONS* (они должны стоять рядом). Матрицу корреляций строит Анализ данных → Корреляция, отдельный коэффициент — =КОРРЕЛ(...). Коэффициент детерминации парной регрессии — =КВПИРСОН(*y*; *x*), отсюда $VIF = 1/(1 - \text{КВПИРСОН}(\text{CONS}; \text{GNP}))$.

Решение. Здесь $n = 20$. Критические значения: $t_{0,025}(17) = 2,110$, $t_{0,025}(18) = 2,101$, $F_{0,05}(2, 17) = 3,592$, $F_{0,05}(1, 18) = 4,414$.

а) Регрессия на оба регрессора ($k = 3$, $n - k = 17$):

Переменная	Коэффициент	Ст. ошибка	<i>t</i> -статистика	<i>P</i> -значение
const	−22,593	9,524	−2,372	0,0297
<i>GNP</i>	0,602	0,231	2,602	0,0186
<i>CONS</i>	−0,563	0,326	−1,725	0,1026

$R^2 = 0,8681$; $R^2_{\text{adj}} = 0,8525$; ESS = 316,65; TSS = 2400,15
--

$$\widehat{INV} = -22,59 + 0,602 GNP - 0,563 CONS.$$

б) Качество уравнения. Регрессия в целом значима: по (2)

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - k}{k - 1} = \frac{0,8681}{0,1319} \cdot \frac{17}{2} = 55,93 > 3,592 = F_{0,05}(2, 17), \quad P = 3,3 \cdot 10^{-8}.$$

Уравнение объясняет 87 % разброса инвестиций. Но по отдельности картина хуже: коэффициент при GNP значим ($|t| = 2,60 > 2,110$), а при $CONS$ — нет ($|t| = 1,73 < 2,110$, $P = 0,10$). Знак при $CONS$ отрицательный. Формально это можно истолковать: при неизменном ВВП рост потребления означает меньшие сбережения, а значит, и меньшие инвестиции. Но такой «эксперимент» — $CONS$ меняется, а GNP стоит на месте — в данных почти не встречается, поэтому оценка опирается на очень малую вариацию и неточна.

в) Можно ли было ожидать мультиколлинеарности? Да. Потребление — основная часть ВВП ($GNP = CONS + INV + \dots$), а по кейнсианской функции потребления $CONS$ линейно зависит от дохода. Кроме того, обе переменные — растущие во времени макроэкономические ряды. Всё это заранее говорит о тесной линейной связи двух регрессоров.

г) Есть ли мультиколлинеарность? Да, по всем признакам п. 1.4.

- Корреляционная матрица:

	INV	GNP	$CONS$
INV	1	0,919	0,903
GNP	0,919	1	0,996
$CONS$	0,903	0,996	1

Корреляция регрессоров $r(GNP, CONS) = 0,996$ выше, чем корреляция каждого из них с INV .

- VIF. Регрессоров два, поэтому вспомогательная регрессия одна — это регрессия $CONS$ на GNP из п. е), её $R_j^2 = 0,9928$. По (7)

$$VIF = \frac{1}{1 - R_j^2} = \frac{1}{1 - 0,9928} = 139,7 \gg 10.$$

- F -тест вспомогательной регрессии (8) при $m = 2$ объясняющих переменных:

$$F_j = \frac{R_j^2}{1 - R_j^2} \cdot \frac{n - m}{m - 1} = \frac{0,9928}{0,0072} \cdot \frac{18}{1} = 2496 \gg 4,414 = F_{0,05}(1, 18).$$

- Типичный симптом: высокий R^2 и значимый F при незначимом отдельном коэффициенте. Стандартная ошибка при GNP в регрессии на оба регрессора (0,231) в 11 раз больше, чем в парной регрессии из п. д) (0,021), — это почти ровно $\sqrt{VIF} = 11,8$.

д) Парные регрессии ($k = 2$, $n - k = 18$):

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
<i>INV на GNP</i>				
const	-10,242	6,619	-1,548	0,1391
<i>GNP</i>	0,204	0,021	9,905	0,0000
$R^2 = 0,8450$; $R^2_{\text{adj}} = 0,8364$; $\text{ESS} = 372,11$				
<i>INV на CONS</i>				
const	-2,667	6,508	-0,410	0,6868
<i>CONS</i>	0,283	0,032	8,920	0,0000
$R^2 = 0,8155$; $R^2_{\text{adj}} = 0,8053$; $\text{ESS} = 442,78$				

Выводы:

- По отдельности каждый регрессор высоко значим ($t \approx 9-10$), и знак у обоих положительный, как и подсказывает экономика.
- R^2 почти не отличается от R^2 регрессии на оба регрессора (0,845 против 0,868): второй регрессор несёт мало новой информации — почти всё, что он знает об *INV*, уже содержится в первом.
- Добавление *CONS* к регрессии на *GNP* — это одно ограничение $b_2 = 0$. По (4) с $\text{ESS}_R = 372,11$ (парная) и $\text{ESS}_{UR} = 316,65$ (из п. а):

$$F = \frac{(\text{ESS}_R - \text{ESS}_{UR})/q}{\text{ESS}_{UR}/(n-k)} = \frac{(372,11 - 316,65)/1}{316,65/17} = 2,98 < 4,451 = F_{0,05}(1, 17),$$

и это в точности $t^2 = 1,725^2$ для *CONS* из п. а). Добавлять *CONS* смысла нет.

- Почему наклон при *GNP* в парной регрессии (0,204) так отличается от 0,602 в п. а)? По тождеству (9) с $\hat{\delta} = 0,706$ из п. е):

$$\tilde{b}_1 = \hat{b}_1 + \hat{b}_2 \hat{\delta} = 0,602 + (-0,563) \cdot 0,706 = 0,204.$$


Парная регрессия показывает *суммарный* эффект роста ВВП вместе с сопутствующим ростом потребления, а 0,602 — эффект при неизменном потреблении.

е) Регрессия *CONS* на *GNP*:

$$\widehat{CONS} = -21,94 + 0,706 GNP, \quad t = 49,96, \quad R^2 = 0,9928.$$

(4,538) (0,014)

Модель обнаруживает почти точную линейную зависимость между регрессорами исходного уравнения: *GNP* объясняет 99,3 % разброса *CONS*. Экономически это функция потребления с предельной склонностью к потреблению 0,706. Для задачи о мультиколлинеарности это и есть вспомогательная регрессия, по которой в п. г) посчитан VIF.



Все 20 точек лежат почти на одной прямой ($R^2 = 0,993$): у данных нет наблюдений, где $CONS$ заметно меняется при том же GNP . Именно такие наблюдения нужны, чтобы разделить влияние двух регрессоров.

ж) Как устранить мультиколлинеарность. Проблема в том, что GNP и $CONS$ почти пропорциональны ($r = 0,996$), и модель не может разделить их влияние. Рассмотрим два способа из п. 1.6.

Способ 1: исключить $CONS$. Остаётся регрессия INV на GNP из п. д): коэффициент значим, знак правильный, R^2_{adj} снизился лишь с 0,853 до 0,836. Минус в том, что её коэффициент 0,204 — суммарный эффект роста ВВП вместе с сопутствующим ростом потребления (п. д), а не эффект ВВП при прочих равных.

Способ 2: заменить два регрессора одним осмысленным.

Шаг 1. Наблюдение. В п. а) $\hat{b}_1 = 0,602$ и $\hat{b}_2 = -0,563$ — почти одинаковы по модулю и противоположны по знаку. Если бы было в точности $b_2 = -b_1$, то

$$b_1 GNP + b_2 CONS = b_1 (GNP - CONS) = b_1 S, \quad S = GNP - CONS,$$

то есть инвестиции зависели бы не от GNP и $CONS$ по отдельности, а только от их разности S — сбережений. Это и есть одна переменная вместо двух. Но сначала надо проверить, что данные не противоречат ограничению $H_0: b_1 + b_2 = 0$.

Шаг 2. Проверка ограничения. Перепишем исходную модель, ничего в ней не меняя, — прибавим и вычтем $b_2 GNP$:

$$b_1 GNP + b_2 CONS = (b_1 + b_2) GNP - b_2 (GNP - CONS) = (b_1 + b_2) GNP - b_2 S.$$

Значит, регрессия INV на GNP и S — та же самая модель: подгонка и $ESS = 316,65$ совпадают с п. а). Зато коэффициент при GNP в ней равен ровно $b_1 + b_2$, и гипотеза $H_0: b_1 + b_2 = 0$ проверяется обычным t -тестом этого коэффициента:

$$\widehat{b_1 + b_2} = 0,039, \quad s = 0,098, \quad t = \frac{0,039}{0,098} = 0,40 < 2,110 = t_{0,025}(17), \quad P = 0,70.$$

То же даёт F -тест (4) с $q = 1$: модель с ограничением — регрессия на одно S (шаг 3), $ESS_R = 319,59$, без ограничения — модель из п. а), $ESS_{UR} = 316,65$:

$$F = \frac{(ESS_R - ESS_{UR})/q}{ESS_{UR}/(n - k)} = \frac{(319,59 - 316,65)/1}{316,65/17} = 0,16 = t^2 < 4,451 = F_{0,05}(1, 17).$$

Ограничение не отвергается: данные согласуются с тем, что важна только разность $GNP - CONS$.

Шаг 3. Новая модель. Подставляем ограничение $b_2 = -b_1$: $INV = b_0 + b_1 S + e$.
Оценка:

$$\widehat{INV} = -24,89 + 0,690 S, \quad t = 10,83, \quad R^2 = 0,8668, \quad R^2_{adj} = 0,8594.$$

(7,397) (0,064)

Регрессор один, так что мультиколлинеарности нет, и коэффициент оценён точно. Сравнение всех моделей задачи:

Модель	R^2_{adj}	Проблема
INV на GNP и $CONS$	0,8525	мультиколлинеарность
INV на GNP	0,8364	коэффициент — суммарный эффект то же
INV на $CONS$	0,8053	
INV на S	0,8594	—

Модель с S лучшая по R^2_{adj} .

Замечание. Сбережения — экономически осмысленная переменная: инвестиции финансируются из сбережений. Но $S = GNP - CONS$ содержит INV как слагаемое ($S = INV + \text{госрасходы} + \text{чистый экспорт}$), поэтому связь INV с S отчасти следует из того, как устроены сами переменные, и высокий R^2 здесь не открытие.

Другие способы: увеличить выборку; перейти к приростам (ΔINV на ΔGNP и $\Delta CONS$) — приросты связаны слабее, чем уровни растущих рядов; перейти к относительным величинам (INV/GNP на $CONS/GNP$).

Задача 4.17

В таблице представлены выпуск Q , трудозатраты L и капиталовложения K 15 фирм некоторой отрасли.

Фирма	Q	L	K	Фирма	Q	L	K
1	2350	2334	1570	9	2550	2446	1880
2	2470	2425	1850	10	2450	2403	1790
3	2110	2230	1150	11	2290	2301	1480
4	2560	2463	1940	12	2160	2253	1240
5	2650	2565	2450	13	2400	2367	1660
6	2240	2278	1340	14	2490	2430	1850
7	2430	2380	1700	15	2590	2470	2000
8	2530	2437	1860				

а) Оцените по этим данным производственную функцию Кобба–Дугласа $Q = \alpha L^{\beta_1} K^{\beta_2}$, вычислите коэффициент детерминации, скорректированный коэффициент детерминации и выборочный коэффициент корреляции между $\ln L$ и $\ln K$.

б) Проведите регрессию $\ln Q$ только на $\ln K$.

Как можно проинтерпретировать полученные результаты?

В Excel. Добавьте три столбца логарифмов: =LN(B2) и т. д. Регрессия $\ln Q$ на $\ln L$ и $\ln K$ — Анализ данных → Регрессия с входным интервалом X из двух соседних столбцов $\ln L$, $\ln K$. Корреляция — =КОРРЕЛ(lnL; lnK).

Решение. Здесь $n = 15$. Критические значения: $t_{0,025}(12) = 2,179$, $t_{0,025}(13) = 2,160$, $F_{0,05}(2, 12) = 3,885$.

а) Функция Кобба–Дугласа. Функция $Q = \alpha L^{\beta_1} K^{\beta_2}$ нелинейна по параметрам, поэтому сначала её логарифмируем. Логарифм произведения — сумма логарифмов, а логарифм степени — показатель, умноженный на логарифм основания:

$$\ln Q = \ln(\alpha L^{\beta_1} K^{\beta_2}) = \ln \alpha + \ln L^{\beta_1} + \ln K^{\beta_2} = \ln \alpha + \beta_1 \ln L + \beta_2 \ln K.$$

Добавив случайную ошибку, получаем линейную регрессию (10)

$$\ln Q_i = \beta_0 + \beta_1 \ln L_i + \beta_2 \ln K_i + \varepsilon_i, \quad \beta_0 = \ln \alpha.$$

Зависимая переменная — $\ln Q$, регрессоры — $\ln L$ и $\ln K$. Модель линейна по параметрам β_0 , β_1 , β_2 , и её оценивает обычный МНК ($k = 3$, $n - k = 12$). Сам параметр α восстанавливается как $\hat{\alpha} = e^{\hat{\beta}_0}$.

Регрессор	Параметр	Оценка	Ст. ошибка	t -статистика	P -значение
константа	$\beta_0 = \ln \alpha$	0,501	4,480	0,112	0,9129
$\ln L$	β_1	0,758	0,707	1,071	0,3052
$\ln K$	β_2	0,188	0,139	1,356	0,2001
$R^2 = 0,9689$					

$$\widehat{Q} = e^{0,501} L^{0,758} K^{0,188} = 1,65 L^{0,758} K^{0,188}.$$

Скорректированный коэффициент детерминации по (3):

$$R_{\text{adj}}^2 = 1 - \frac{n-1}{n-k} (1 - R^2) = 1 - \frac{14}{12} \cdot (1 - 0,9689) = 0,9637.$$

То же через суммы квадратов ($ESS = 0,001981$, $TSS = 0,06366$) и через третью запись (3):

$$R_{\text{adj}}^2 = 1 - \frac{ESS/(n-k)}{TSS/(n-1)} = 1 - \frac{0,001981/12}{0,06366/14} = 0,9637,$$

$$R_{\text{adj}}^2 = R^2 - \frac{k-1}{n-k} (1 - R^2) = 0,9689 - \frac{2}{12} \cdot 0,0311 = 0,9637.$$

Выборочный коэффициент корреляции $r(\ln L, \ln K) = 0,992$.

Интерпретация. Классическая картина мультиколлинеарности:

- регрессия в целом значима и объясняет почти 97 % разброса $\ln Q$: $F = \frac{0,9689}{0,0311} \cdot \frac{12}{2} = 186,8 \gg 3,885$;
- при этом *ни одна* эластичность не значима: $|t| = 1,07$ и $1,36$ меньше $2,179$;
- причина — почти линейная связь $\ln L$ и $\ln K$: фирмы с большим капиталом нанимают и больше труда. По (7)

$$VIF = \frac{1}{1 - r^2} = \frac{1}{1 - 0,992^2} = 63,7,$$

то есть дисперсии оценок в 64 раза больше, чем при несвязанных факторах.

Данные хорошо описывают выпуск в целом, но не позволяют разделить вклады труда и капитала.

б) Регрессия $\ln Q$ только на $\ln K$ ($n - k = 13$):

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	5,297	0,130	40,778	0,0000
$\ln K$	0,335	0,017	19,192	0,0000
$R^2 = 0,9659$				

Коэффициент стал высоко значимым, а R^2 почти не изменился (0,9659 против 0,9689): $\ln L$ добавлял к $\ln K$ очень мало информации.

Как это понимать.

- Для *прогноза* выпуска короткой регрессии достаточно: она почти так же точна и гораздо проще.
- Но 0,335 — *не* эластичность выпуска по капиталу. По (9), где $\widehat{\delta} = 0,195$ — наклон регрессии $\ln L$ на $\ln K$,

$$0,188 + 0,758 \cdot 0,195 = 0,335 :$$

коэффициент включает и эффект труда, который растёт вместе с капиталом. Чтобы оценить эластичности по труду и капиталу по отдельности, нужна регрессия на оба фактора, а она из-за мультиколлинеарности даёт их с большими ошибками. Один из выходов — следующая задача.

Задача 4.18

Можно ли преодолеть проблему мультиколлинеарности, возникающую в задаче 4.17, если известно, что производственная функция обладает постоянной отдачей на масштаб ($\beta_1 + \beta_2 = 1$)?

В Excel. В той же книге, что и для задачи 4.17, добавьте столбцы $\ln(Q/K)$ и $\ln(L/K)$ и оцените парную регрессию первого на второй. Остаточные суммы для F -теста — строка Остаток, столбец SS в обоих отчётах.

Решение. Да. Ограничение — это внешняя информация, которой нет в данных, и она заменяет недостающую вариацию регрессоров (п. 1.6, способ 3).

1) Проверка ограничения. Сначала убедимся, что данные не противоречат гипотезе $H_0: \beta_1 + \beta_2 = 1$ ($q = 1$). Точечная оценка суммы из задачи 4.17: $0,758 + 0,188 = 0,946$ — близко к единице.

Модель с ограничением получаем подстановкой $\beta_2 = 1 - \beta_1$ в (10):

$$\ln Q = \ln \alpha + \beta_1 \ln L + (1 - \beta_1) \ln K + \varepsilon \implies \ln \frac{Q}{K} = \ln \alpha + \beta_1 \ln \frac{L}{K} + \varepsilon.$$

Выпуск на единицу капитала объясняется трудом на единицу капитала. Оценка:

Переменная	Коэффициент	Ст. ошибка	t -статистика	P -значение
const	0,073	0,008	9,261	0,0000
$\ln(L/K)$	0,825	0,021	39,812	0,0000
$R^2 = 0,9919$; $ESS_R = 1,9826 \cdot 10^{-3}$				

Модель без ограничений — регрессия из задачи 4.17, а), $ESS_{UR} = 1,9811 \cdot 10^{-3}$, $n - k = 15 - 3 = 12$. По (4)

$$F = \frac{(ESS_R - ESS_{UR})/q}{ESS_{UR}/(n - k)} = \frac{(ESS_R - ESS_{UR})/1}{ESS_{UR}/12},$$

$$F = \frac{(1,9826 - 1,9811) \cdot 10^{-3}}{1,9811 \cdot 10^{-3}/12} = 0,009 < 4,747 = F_{0,05}(1, 12), \quad P = 0,926.$$

(Разность остаточных сумм в числителе точнее равна $1,51 \cdot 10^{-6}$: при четырёх знаках после запятой она почти теряется.) Гипотеза о постоянной отдаче на масштаб уверенно не отвергается.

Замечание. Коэффициент детерминации модели с ограничением (0,9919) больше, чем у модели без ограничений (0,9689), хотя ограничение не может улучшить подгонку. Противоречия нет: у моделей разные зависимые переменные, $\ln(Q/K)$ и $\ln Q$, поэтому и TSS разные (0,2437 против 0,0637), и их R^2 несравнимы. Сравнивать надо остаточные суммы, как в формуле выше.

2) Результат. Оценки параметров:

$$\hat{\beta}_1 = 0,825, \quad \hat{\beta}_2 = 1 - \hat{\beta}_1 = 0,175, \quad \hat{\alpha} = e^{0,073} = 1,075,$$

$$\hat{Q} = 1,075 L^{0,825} K^{0,175}.$$

Стандартная ошибка эластичности по труду упала с 0,707 до 0,021, в 34 раза, а t -статистика выросла с 1,07 до 39,8. У $\hat{\beta}_2$ та же стандартная ошибка 0,021, так как $\hat{\beta}_2 = 1 - \hat{\beta}_1$. В модели остался один регрессор $\ln(L/K)$, так что мультиколлинеарности нет.

Вывод. Введение ограничения $\beta_1 + \beta_2 = 1$ решило проблему мультиколлинеарности: обе эластичности оценены точно. Цена — предположение о постоянной отдаче на масштаб. Если бы оно было неверным, оценки были бы смещены, поэтому ограничение и нужно было сначала проверить.

Задача 4.1.1 (задачник ВШЭ)

Дана матрица

$$X = \begin{pmatrix} 1 & 10 & 3 \\ 1 & 6 & 1 \\ 1 & 12 & a \\ 1 & 8 & 2 \end{pmatrix}.$$

Каким должно быть число a , чтобы между столбцами матрицы была строгая мультиколлинеарность? Допустим, $a = 2$. Рассчитайте значения VIF для оценок коэффициентов регрессии $y = X\beta + \varepsilon$, где y — любая величина.

Решение. Обозначим столбцы $\mathbf{1}$, $\mathbf{x}_2$, $\mathbf{x}_3$.

1) Строгая мультиколлинеарность — линейная зависимость столбцов (п. 1.4). Столбцы $\mathbf{1}$ и $\mathbf{x}_2$ не пропорциональны, поэтому зависимость возможна только в виде $\mathbf{x}_3 = c_1\mathbf{1} + c_2\mathbf{x}_2$. Коэффициенты находим по строкам, где $\mathbf{x}_3$ известен. Из первых двух строк

$$\begin{cases} c_1 + 10c_2 = 3, \\ c_1 + 6c_2 = 1 \end{cases} \implies c_2 = \frac{1}{2}, \quad c_1 = -2.$$

Проверка по четвёртой строке: $-2 + \frac{1}{2} \cdot 8 = 2$ — верно. Значит, при $x_3 = -2 + \frac{1}{2}x_2$ третья строка даёт

$$a = -2 + \frac{1}{2} \cdot 12 = 4.$$

При $a = 4$ ранг X равен 2, $\det(X^\top X) = 0$, и МНК-оценка не существует. При любом другом a столбцы независимы.

2) VIF при $a = 2$. VIF зависит только от матрицы регрессоров, а не от y , — поэтому y в условии и может быть любым. Регрессоров (кроме константы) два, поэтому вспомогательная регрессия $\mathbf{x}_2$ на константу и $\mathbf{x}_3$ — парная, и её R^2 равен квадрату коэффициента корреляции (п. 1.4). Средние: $\bar{x}_2 = 9$, $\bar{x}_3 = 2$. Отклонения:

	1	2	3	4
$x_2 - \bar{x}_2$	1	-3	3	-1
$x_3 - \bar{x}_3$	1	-1	0	0

$$\sum (x_2 - \bar{x}_2)^2 = 20, \quad \sum (x_3 - \bar{x}_3)^2 = 2, \quad \sum (x_2 - \bar{x}_2)(x_3 - \bar{x}_3) = 1 + 3 = 4,$$

$$R_2^2 = R_3^2 = r^2(x_2, x_3) = \frac{4^2}{20 \cdot 2} = 0,4.$$

По (7)

$$\text{VIF}_2 = \text{VIF}_3 = \frac{1}{1 - 0,4} = \frac{5}{3} \approx 1,67.$$

Это далеко от порога 10: при $a = 2$ мультиколлинеарность слабая. Для свободного члена VIF обычно не считают: вспомогательная регрессия «константы на остальные регрессоры с константой» не имеет смысла.