Семинар 5

Свойства оценок, мультиколлинеарность
и выбор модели

Условия и решения

1. Основные формулы

1.1. Свойства оценок

Пусть $\widehat{\beta}_n$ — оценка параметра β по выборке объёма n.

$$\operatorname{bias}(\widehat{\beta}_n) = \mathbb{E}\widehat{\beta}_n - \beta, \qquad \operatorname*{plim}_{n\to\infty} \widehat{\beta}_n = \beta \iff \lim_{n\to\infty} \Pr\bigl\{|\widehat{\beta}_n - \beta| > \varepsilon\bigr\} = 0 \ \ \forall \varepsilon > 0. \tag{1}$$

Оценка *несмещённая*, если смещение равно нулю при любом n; *состоятельная*, если она сходится по вероятности к β. Достаточное условие состоятельности: $\mathbb{E}\widehat{\beta}_n \to \beta$ и $\mathbb{D}(\widehat{\beta}_n) \to 0$ при $n \to \infty$.

1.2. Мультиколлинеарность и VIF

Мультиколлинеарность — тесная линейная связь между регрессорами. Диагностика — вспомогательная регрессия j-го регрессора на все остальные (с константой), её коэффициент детерминации R_j^2:

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}. \tag{2}$$

Вывод делается и для каждого коэффициента, и для модели в целом: при $\mathrm{VIF}_j > 5$ мультиколлинеарность заметная, при $\mathrm{VIF}_j > 10$ ($R_j^2 > 0{,}9$) — серьёзная.

Стандартная ошибка через вспомогательную регрессию. Пусть ESS_j — остаточная сумма квадратов вспомогательной регрессии x_j на остальные регрессоры (с константой). Тогда

$$s_{\widehat{\beta}_j} = \sqrt{\widehat{\mathbb{D}}(\widehat{\beta}_j)} = \frac{\widehat{\sigma}}{\sqrt{\mathrm{ESS}_j}}, \qquad \mathrm{ESS}_j = (1 - R_j^2)\sum_t (x_{tj} - \overline{x}_j)^2, \tag{3}$$

поэтому $s^2_{\widehat{\beta}_j} = \mathrm{VIF}_j \cdot \widehat{\sigma}^2 / \sum_t (x_{tj} - \overline{x}_j)^2$: чем сильнее x_j объясняется остальными регрессорами, тем меньше у него «собственной» вариации ESS_j и тем больше ошибка коэффициента. В парной регрессии вспомогательная регрессия — это регрессия x на одну константу, и $\mathrm{ESS}_x = \sum (x_t - \overline{x})^2$.

1.3. Качество подгонки и выбор модели

$\mathrm{TSS} = \sum (y_t - \overline{y})^2$, $\mathrm{RSS} = \sum (\widehat{y}_t - \overline{y})^2$ — объяснённая, $\mathrm{ESS} = \sum (y_t - \widehat{y}_t)^2$ — остаточная сумма квадратов, n — число наблюдений, k — число параметров вместе с константой.

$$R^2 = \frac{\mathrm{RSS}}{\mathrm{TSS}} = 1 - \frac{\mathrm{ESS}}{\mathrm{TSS}}, \qquad R^2_{\text{adj}} = 1 - \frac{\mathrm{ESS}/(n-k)}{\mathrm{TSS}/(n-1)} = 1 - \frac{n-1}{n-k}\bigl(1 - R^2\bigr), \tag{4}$$

$$\mathrm{AIC} = \frac{2k}{n} + \ln \frac{\mathrm{ESS}}{n}, \qquad \mathrm{BIC} = \frac{k \ln n}{n} + \ln \frac{\mathrm{ESS}}{n}. \tag{5}$$

1.4. Парная регрессия

Модель $Y_t = \alpha + \beta X_t + \varepsilon_t$; $x_t = X_t - \overline{X}$, $y_t = Y_t - \overline{Y}$.

$$\widehat{\beta} = \frac{\sum x_t y_t}{\sum x_t^2}, \qquad \widehat{\alpha} = \overline{Y} - \widehat{\beta}\,\overline{X}, \qquad \mathrm{RSS} = \widehat{\beta}^2 \sum x_t^2, \qquad \mathrm{ESS} = \sum y_t^2 - \mathrm{RSS}, \tag{6}$$

$$s^2 = \frac{\mathrm{ESS}}{n-2}, \qquad s^2_{\widehat{\beta}} = \frac{s^2}{\sum x_t^2}, \qquad s^2_{\widehat{\alpha}} = s^2\Big(\frac{1}{n} + \frac{\overline{X}^2}{\sum x_t^2}\Big), \tag{7}$$

$$t = \frac{\widehat{\beta} - \beta^0}{s_{\widehat{\beta}}} \sim t(n-2), \qquad \widehat{\beta} \pm t_{0{,}025}(n-2)\, s_{\widehat{\beta}}. \tag{8}$$

2. Задачи

Задача 1

Напишите величину смещения смещённой оценки $\widehat{\beta}$ параметра β. Какая оценка $\widehat{\beta}$ параметра β называется состоятельной?

Решение. **Смещение** — разность между математическим ожиданием оценки и истинным значением параметра:

$$\mathrm{bias}(\widehat{\beta}) = \mathbb{E}\widehat{\beta} - \beta.$$

Оценка несмещённая, если $\mathbb{E}\widehat{\beta} = \beta$: в среднем по многим выборкам она попадает в истинное значение.

Состоятельность. Оценка $\widehat{\beta}_n$ состоятельна, если она сходится по вероятности к истинному значению (1):

$$\lim_{n\to\infty} \Pr\big\{|\widehat{\beta}_n - \beta| > \varepsilon\big\} = 0 \quad \text{для любого } \varepsilon > 0.$$

По мере роста выборки оценка всё ближе к истинному значению: вероятность ошибиться больше чем на любое заданное ε стремится к нулю. Обычно состоятельность требуют в дополнение к несмещённости.

Замечание. *Несмещённость и состоятельность — разные свойства. Оценка дисперсии ошибок $\widehat{\sigma}^2 = \mathrm{ESS}/n$ смещена ($\mathbb{E}\widehat{\sigma}^2 = \frac{n-k}{n}\sigma^2$), но состоятельна: смещение $-\frac{k}{n}\sigma^2$ исчезает при $n \to \infty$. Несмещённая оценка — $s^2 = \mathrm{ESS}/(n-k)$. Наоборот, оценка $\widehat{\beta} = Y_1/X_1$ по одному наблюдению в модели $Y_t = \beta X_t + \varepsilon_t$ несмещённая, но не состоятельна: она вообще не использует остальные наблюдения, и её дисперсия не убывает с ростом n.*

Задача 2

Пусть есть модель $Y_t = \alpha + \beta_1 X_{1t} + \beta_2 X_{2t} + \beta_3 X_{3t} + \varepsilon_t$. Исследователь пытается проверить мультиколлинеарность и оценивает вспомогательные регрессии: X_1 на X_2, X_3 (коэффициент детерминации R_1^2), X_2 на X_1, X_3 (R_2^2), X_3 на X_1, X_2 (R_3^2). Напишите, что такое мультиколлинеарность, и сделайте вывод о её наличии или отсутствии в каждом варианте:

	Вариант 1	Вариант 2	Вариант 3	Вариант 4
R_1^2	0,80	0,10	0,73	0,90
R_2^2	0,25	0,65	0,60	0,65
R_3^2	0,35	0,85	0,20	0,15

Решение. **Что такое мультиколлинеарность.** Это тесная линейная связь между регрессорами. *Строгая* мультиколлинеарность — точная линейная зависимость столбцов матрицы $\mathbf{X}$: тогда $\mathbf{X}^\top\mathbf{X}$ вырождена и МНК-оценки не существует. *Нестрогая* — сильная, но не точная связь: оценки существуют и остаются несмещёнными, но их дисперсии велики. Признаки: высокий R^2 и значимый F-тест при незначимых отдельных коэффициентах, неустойчивость оценок, «неправильные» знаки.

Вспомогательный R_j^2 показывает, какая доля разброса X_j объясняется остальными регрессорами. По (2) переводим его в VIF — во сколько раз из-за этой связи выросла дисперсия $\widehat{\beta}_j$:

	Вариант 1	Вариант 2	Вариант 3	Вариант 4
$\mathrm{VIF}_1 = 1/(1-R_1^2)$	5,00	1,11	3,70	**10,00**
$\mathrm{VIF}_2 = 1/(1-R_2^2)$	1,33	2,86	2,50	2,86
$\mathrm{VIF}_3 = 1/(1-R_3^2)$	1,54	**6,67**	1,25	1,18

Например, в варианте 1: $\mathrm{VIF}_1 = 1/(1-0{,}8) = 1/0{,}2 = 5$.

Выводы (порог $\mathrm{VIF} > 5$):

- *Вариант 1.* $\mathrm{VIF}_1 = 5$ — ровно на пороге: X_1 на 80 % объясняется остальными регрессорами. Умеренная мультиколлинеарность, связанная с X_1; по строгому порогу 10 её нет.
- *Вариант 2.* $\mathrm{VIF}_3 = 6{,}67 > 5$ — мультиколлинеарность есть: X_3 тесно связан с X_1 и X_2. До серьёзной (> 10) не дотягивает.
- *Вариант 3.* Все VIF меньше 5 — мультиколлинеарности нет.
- *Вариант 4.* $\mathrm{VIF}_1 = 10$ — серьёзная мультиколлинеарность: дисперсия $\widehat{\beta}_1$ в 10 раз больше, чем была бы при регрессоре, не связанном с остальными, а стандартная ошибка — в $\sqrt{10} \approx 3{,}2$ раза.

Задача 3

а) Какие есть способы решить проблему мультиколлинеарности?

б) Напишите формулу скорректированного R^2. Объясните смысловое отличие от нескорректированного R^2.

в) Сформулируйте байесовский информационный критерий (BIC): напишите формулу и объясните, зачем он используется.

г) Сформулируйте информационный критерий Акаике (AIC): напишите формулу и объясните, зачем он используется.

Решение. **а) Способы решения проблемы мультиколлинеарности.**

1) *Исключить переменную (переменные) из модели.* Исключается одна из коррелирующих объясняющих переменных — та, у которой хуже показатели в однофакторном анализе (меньше R^2 парной регрессии Y на неё). Цена — смещение оставшихся коэффициентов, если исключённая переменная на самом деле влияет на Y.

2) *Получить дополнительные данные или новую выборку.* Например, заменить годовые данные квартальными: при большем числе наблюдений дисперсии оценок меньше, а связь регрессоров может оказаться слабее.

3) *Использовать предварительную информацию о параметрах.* Например, известное из теории ограничение на коэффициенты ($\beta_1 + \beta_2 = 1$) или объединение коррелирующих объясняющих переменных в одну.

4) *Преобразовать данные.* Например, разделить на одну из коррелирующих объясняющих переменных (перейти к относительным величинам) или перейти к приростам.

б) Скорректированный R^2. По (4)

$$R^2 = 1 - \frac{\sum(y_t - \widehat{y}_t)^2}{\sum(y_t - \overline{y})^2}, \qquad R^2_{\text{adj}} = 1 - \frac{\sum(y_t - \widehat{y}_t)^2/(n-k)}{\sum(y_t - \overline{y})^2/(n-1)} = 1 - \frac{n-1}{n-k}\big(1 - R^2\big).$$

Обычный R^2 показывает долю разброса y, объяснённую моделью, но не убывает при добавлении *любого* регрессора, даже бессмысленного: остаточная сумма от этого может только уменьшиться. Поэтому сравнивать по R^2 модели с разным числом регрессоров нельзя. В R^2_{adj} каждая сумма квадратов делится на своё число степеней свободы, то есть сравниваются *несмещённые оценки* дисперсии ошибок и дисперсии y. Добавление регрессора увеличивает R^2_{adj}, только если выигрыш в остаточной сумме перевешивает потерю степени свободы. Всегда $R^2_{\text{adj}} \le R^2$, и R^2_{adj} может быть отрицательным.

в) Критерий BIC (Шварца). По (5)

$$\text{BIC} = \frac{k \ln n}{n} + \ln \frac{\sum(y_t - \widehat{y}_t)^2}{n} = \frac{k \ln n}{n} + \ln \frac{\text{ESS}}{n}.$$

г) Критерий AIC (Акаике).

$$\text{AIC} = \frac{2k}{n} + \ln \frac{\sum(y_t - \widehat{y}_t)^2}{n} = \frac{2k}{n} + \ln \frac{\text{ESS}}{n}.$$

В обоих случаях n — число наблюдений, k — число параметров (регрессоров, включая константу).

Зачем. Оба критерия используют для выбора между несколькими моделями, оценёнными по одним и тем же данным, в том числе когда модели не вложены друг в друга и F-тест на ограничения неприменим. Второе слагаемое — качество подгонки (меньше остатки — меньше критерий), первое — штраф за число параметров. Лучше модель с *меньшим* значением критерия. Штраф BIC $k \ln n/n$ больше штрафа AIC $2k/n$ при $\ln n > 2$, то есть уже при $n \ge 8$, поэтому BIC строже наказывает за лишние параметры и выбирает более экономные модели.

Задача 4 (Магнус, упр. 2.22)

В таблице приведены ежегодные значения денежной массы и национального дохода некоторой гипотетической страны (в миллиардах денежных единиц).

Год	Денежная масса	Нац. доход	Год	Денежная масса	Нац. доход
1981	2,0	5,0	1986	4,0	7,7
1982	2,5	5,5	1987	4,2	8,4
1983	3,2	6,0	1988	4,6	9,0
1984	3,6	7,0	1989	4,8	9,7
1985	3,3	7,2	1990	5,0	10,0

а) Проведите регрессию национального дохода (Y) на денежную массу (X) и константу. Обоснуйте вывод основных формул.

б) Рассчитайте R^2 модели.

в) Постройте 95 %-ные доверительные интервалы для оцениваемых параметров. Можете ли вы отвергнуть гипотезу $\beta = 0$? $\beta = 1$?

В Excel. Введите данные двумя столбцами X и Y. Суммы для ручного расчёта: `=СУММ(…)`, `=СУММПРОИЗВ(X; X)`, `=СУММПРОИЗВ(X; Y)`; суммы квадратов отклонений — `=КВАДРОТКЛ(…)`. Проверка: Данные → Анализ данных → Регрессия, входной интервал Y — национальный доход, X — денежная масса; галочка Уровень надёжности 95 % даёт доверительные интервалы.

Решение. **а) Вывод формул МНК.** МНК выбирает α и β, при которых сумма квадратов отклонений наблюдений от прямой минимальна:

$$S(\alpha, \beta) = \sum_{t=1}^{n} \big(Y_t - \alpha - \beta X_t\big)^2 \to \min_{\alpha,\,\beta}.$$

Необходимое условие минимума — равенство нулю частных производных:

$$\frac{\partial S}{\partial \alpha} = -2\sum \big(Y_t - \alpha - \beta X_t\big) = 0, \qquad \frac{\partial S}{\partial \beta} = -2\sum X_t\big(Y_t - \alpha - \beta X_t\big) = 0.$$

Отсюда система нормальных уравнений:

$$\begin{cases} n\alpha + \beta \sum X_t = \sum Y_t, \\ \alpha \sum X_t + \beta \sum X_t^2 = \sum X_t Y_t. \end{cases}$$

Из первого уравнения (после деления на n) $\alpha = \overline{Y} - \beta \overline{X}$: прямая проходит через точку средних. Подставляем во второе:

$$\big(\overline{Y} - \beta \overline{X}\big)\sum X_t + \beta \sum X_t^2 = \sum X_t Y_t \quad \Longrightarrow$$

$$\widehat{\beta} = \frac{\sum X_t Y_t - n\overline{X}\,\overline{Y}}{\sum X_t^2 - n\overline{X}^2} = \frac{\sum x_t y_t}{\sum x_t^2}, \qquad \widehat{\alpha} = \overline{Y} - \widehat{\beta}\,\overline{X}.$$

Это действительно минимум: S — выпуклая квадратичная функция, $\partial^2 S/\partial\alpha^2 = 2n > 0$, а определитель матрицы вторых производных $4\big(n\sum X_t^2 - (\sum X_t)^2\big) = 4n\sum x_t^2 > 0$, если не все X_t равны.

Расчёт. $n = 10$. Суммы по таблице:

$$\sum X_t = 37{,}2, \quad \sum Y_t = 75{,}5, \quad \sum X_t^2 = 147{,}18,$$

$$\sum Y_t^2 = 597{,}03, \quad \sum X_t Y_t = 295{,}95.$$

Средние $\overline{X} = 3{,}72$, $\overline{Y} = 7{,}55$. Суммы в отклонениях:

$$\sum x_t^2 = \sum X_t^2 - \frac{(\sum X_t)^2}{n} = 147{,}18 - \frac{37{,}2^2}{10} = 8{,}796,$$
$$\sum x_t y_t = \sum X_t Y_t - \frac{\sum X_t \sum Y_t}{n} = 295{,}95 - \frac{37{,}2 \cdot 75{,}5}{10} = 15{,}09,$$
$$\sum y_t^2 = \sum Y_t^2 - \frac{(\sum Y_t)^2}{n} = 597{,}03 - \frac{75{,}5^2}{10} = 27{,}005.$$

По (6)

$$\widehat{\beta} = \frac{15{,}09}{8{,}796} = 1{,}716, \qquad \widehat{\alpha} = 7{,}55 - 1{,}716 \cdot 3{,}72 = 1{,}168,$$

$$\widehat{Y} = 1{,}168 + 1{,}716\,X.$$

Рост денежной массы на 1 млрд сопровождается в среднем ростом национального дохода на 1,72 млрд.

б) Коэффициент детерминации. По (6), (4)

$$\mathrm{RSS} = \widehat{\beta}^2 \sum x_t^2 = 1{,}716^2 \cdot 8{,}796 = 25{,}888, \qquad R^2 = \frac{\mathrm{RSS}}{\mathrm{TSS}} = \frac{25{,}888}{27{,}005} = 0{,}959.$$

Денежная масса объясняет 95,9 % разброса национального дохода.

в) Доверительные интервалы и гипотезы. Остаточная сумма и оценка дисперсии ошибок по (7):

$$\mathrm{ESS} = \mathrm{TSS} - \mathrm{RSS} = 27{,}005 - 25{,}888 = 1{,}117, \qquad s^2 = \frac{\mathrm{ESS}}{n-2} = \frac{1{,}117}{8} = 0{,}1397.$$

Стандартные ошибки:

$$s_{\widehat{\beta}} = \sqrt{\frac{s^2}{\sum x_t^2}} = \sqrt{\frac{0{,}1397}{8{,}796}} = 0{,}126,$$

$$s_{\widehat{\alpha}} = \sqrt{s^2\Big(\frac{1}{n} + \frac{\overline{X}^2}{\sum x_t^2}\Big)} = \sqrt{0{,}1397\Big(\frac{1}{10} + \frac{3{,}72^2}{8{,}796}\Big)} = 0{,}483.$$

С $t_{0{,}025}(8) = 2{,}306$ по (8):

$$\beta\colon\ 1{,}716 \pm 2{,}306 \cdot 0{,}126 = (1{,}425;\ 2{,}006), \qquad \alpha\colon\ 1{,}168 \pm 2{,}306 \cdot 0{,}483 = (0{,}053;\ 2{,}283).$$

Гипотезы о наклоне:

$$H_0\colon \beta = 0\colon \quad t = \frac{1{,}716 - 0}{0{,}126} = 13{,}6 > 2{,}306,$$

$$H_0\colon \beta = 1\colon \quad t = \frac{1{,}716 - 1}{0{,}126} = 5{,}68 > 2{,}306.$$

Обе гипотезы отвергаются на 5 %-ном уровне. То же видно по доверительному интервалу: ни 0, ни 1 в интервал $(1{,}425;\ 2{,}006)$ не попадают.

Замечание. *Стандартная ошибка наклона — частный случай формулы* (3)*: в парной регрессии вспомогательная регрессия X на константу имеет остаточную сумму* $\mathrm{ESS}_X = \sum x_t^2 = 8{,}796$*, и* $s_{\widehat{\beta}} = s/\sqrt{\mathrm{ESS}_X} = \sqrt{0{,}1397}/\sqrt{8{,}796} = 0{,}126$.