Семинар 6

Гетероскедастичность и автокорреляция ошибок

Условия и решения

Напоминание: МНК и его предпосылки

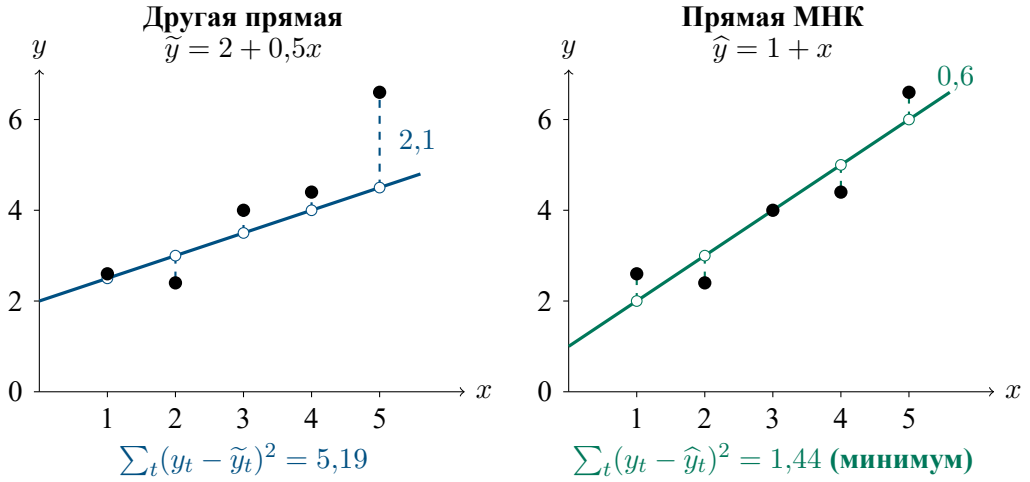
Модель и МНК. Парная регрессия

$$y_t = \alpha + \beta x_t + \varepsilon_t, \qquad t = 1, \dots, n,$$

где y_t — зависимая переменная, x_t — регрессор, α и β — неизвестные параметры, ε_t — ненаблюдаемая случайная ошибка, n — число наблюдений. МНК выбирает оценки $\widehat{\alpha}$, $\widehat{\beta}$, при которых сумма квадратов отклонений наблюдений от прямой наименьшая:

$$(\widehat{\alpha}, \widehat{\beta}) = \arg\min_{a,\,b} \sum_{t=1}^{n} (y_t - a - b x_t)^2, \qquad e_t = y_t - \widehat{\alpha} - \widehat{\beta} x_t,$$

где a, b — пробные значения свободного члена и наклона, e_t — *остаток*: отклонение наблюдения от оценённой прямой. Остаток вычисляется по данным и служит оценкой ненаблюдаемой ошибки ε_t.



Учебный пример: на обоих рисунках одни и те же пять наблюдений (чёрные точки). Пустые кружки — прогнозы при тех же x_t; пунктирные вертикальные отрезки соединяют наблюдение с прогнозом.

Отклонения измеряются по вертикали, при том же x_t. Например, справа для пятой точки $e_5 = 6{,}6 - 6 = 0{,}6$, и её вклад в сумму равен $0{,}36$. У прямой МНК сумма квадратов меньше, чем у любой другой прямой ($1{,}44$ против $5{,}19$ слева).

Суммы квадратов. $\mathrm{TSS} = \sum (y_t - \overline{y})^2$ — полная, $\mathrm{RSS} = \sum (\widehat{y}_t - \overline{y})^2$ — объяснённая регрессией, $\mathrm{ESS} = \sum e_t^2$ — остаточная сумма квадратов; $\overline{y}$ — среднее y_t, $\widehat{y}_t = \widehat{\alpha} + \widehat{\beta} x_t$ — подогнанные значения. $\mathrm{TSS} = \mathrm{RSS} + \mathrm{ESS}$, коэффициент детерминации $R^2 = \mathrm{RSS}/\mathrm{TSS}$.

Обозначения. $\mathbb{E}$ — математическое ожидание, $\mathbb{D}$ — дисперсия, Cov — ковариация; k — число оцениваемых параметров вместе с константой (в парной регрессии $k = 2$); F_α, χ^2_α, t_α — критические значения распределений для уровня значимости α.

Предпосылки (значения регрессоров считаем фиксированными):

1) модель линейна по параметрам, и не все x_t одинаковы (в множественной регрессии — ни один регрессор не является точной линейной комбинацией остальных);
2) $\mathbb{E}(\varepsilon_t) = 0$ — в среднем ошибка равна нулю;
3) $\mathbb{D}(\varepsilon_t) = \sigma^2$ для всех t (*гомоскедастичность*) и $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = 0$ при $t \neq s$ (нет *автокорреляции*); σ^2 — общая для всех наблюдений дисперсия ошибки;
4) ошибки нормально распределены — нужна только для точных t- и F-тестов в малых выборках.

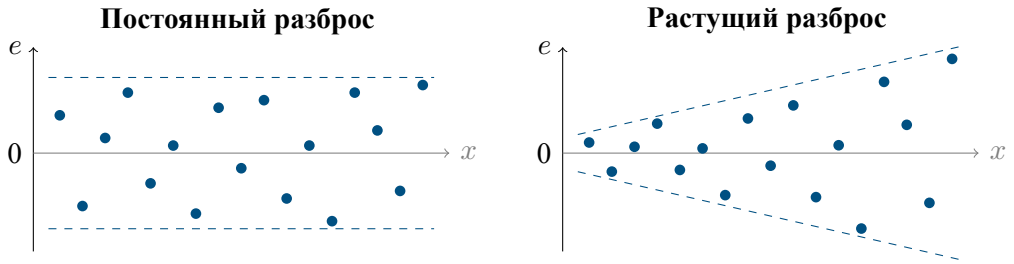
Свойство МНК	Предпосылки	Смысл
Несмещённость	1–2	В среднем по многим выборкам оценки равны истинным параметрам.
Эффективность (BLUE)	1–3	Наименьшая дисперсия среди линейных несмещённых оценок (теорема Гаусса–Маркова).
Верные ст. ошибки, t- и F-тесты	1–3; точные — 1–4	Интервалы и тесты имеют заявленный уровень.

Что в этом семинаре. Нарушается предпосылка 3: гетероскедастичность — её первая часть, автокорреляция — вторая. Предпосылки 1–2 сохраняются, поэтому МНК-оценки остаются несмещёнными, но перестают быть эффективными, а обычные стандартные ошибки, t- и F-тесты и интервалы становятся неверными. План: обнаружить нарушение по остаткам, затем преобразовать модель так, чтобы предпосылка 3 снова выполнялась.

1. Основные формулы

1.1. Гетероскедастичность

Гетероскедастичность — дисперсия ошибки различна в разных наблюдениях: $\mathbb{D}(\varepsilon_t) = \sigma_t^2$, где σ_t^2 — дисперсия ошибки в наблюдении t, а σ_t — её стандартное отклонение. Обычно разброс растёт с масштабом: например, расходы богатых семей колеблются сильнее, чем бедных.



Схематический пример: важна ширина облака вокруг нуля, а не наклон линии регрессии. Пунктир показывает изменение масштаба; это не доверительные границы.

Как обнаружить. Ошибки не наблюдаются, поэтому все методы работают с остатками МНК: e_t^2 и $|e_t|$ — грубые оценки дисперсии σ_t^2 и стандартного отклонения σ_t. Во всех тестах H_0 — гомоскедастичность (все σ_t^2 равны).

1) *График* e_t^2 (или $|e_t|$) против регрессора x_t. Расширяющийся «веер» — признак гетероскедастичности. Это подсказка, а не тест.

2) *Тест Голдфелда–Квандта* — когда дисперсия, предположительно, растёт с x_t. Упорядочиваем наблюдения по возрастанию x_t, выбрасываем c средних и оцениваем регрессию отдельно по первым m и по последним m наблюдениям, $m = (n-c)/2$:

$$F = \frac{\text{ESS}_2/(m-k)}{\text{ESS}_1/(m-k)} = \frac{\text{ESS}_2}{\text{ESS}_1} \sim F(m-k,\ m-k), \tag{1}$$

где ESS_1 и ESS_2 — остаточные суммы квадратов регрессий по группе с малыми и с большими x_t, $m-k$ — число степеней свободы в каждой. Альтернатива H_1: в группе с большими x_t дисперсия больше. H_0 отвергаем, если $F > F_\alpha(m-k,\ m-k)$. Средние наблюдения выбрасываем, чтобы группы сильнее различались.

3) *Тест Бройша–Пагана.* Предполагаем, что дисперсия может линейно зависеть от наблюдаемых переменных $z_{1t}, \dots, z_{pt}$ (обычно это регрессоры модели):

$$\sigma_t^2 = \sigma^2\big(\gamma_0 + \gamma_1 z_{1t} + \dots + \gamma_p z_{pt}\big), \qquad H_0\colon \gamma_1 = \dots = \gamma_p = 0,$$

где γ_j — неизвестные коэффициенты, p — число переменных z. При H_0 дисперсия постоянна. Так как $\mathbb{E}\varepsilon_t^2 = \sigma_t^2$, проверяем, объясняют ли z разброс квадратов остатков. Расчёт:

   а) оцениваем исходную модель МНК, получаем остатки e_t;

   б) $\widehat{\sigma}^2 = \text{ESS}/n$ — средний квадрат остатка (делим именно на n);

   в) $g_t = e_t^2/\widehat{\sigma}^2$ — нормированные квадраты остатков, их среднее $\overline{g} = 1$;

   г) оцениваем вспомогательную регрессию $g_t = a_0 + a_1 z_{1t} + \dots + a_p z_{pt} + v_t$ (v_t — её ошибка) и берём её *объяснённую* сумму квадратов $\text{RSS}_{\text{aux}} = \sum(\widehat{g}_t - \overline{g})^2$, где $\widehat{g}_t$ — подогнанные значения;

д) вычисляем

$$\text{BP} = \frac{\text{RSS}_{\text{aux}}}{2} \overset{a}{\sim} \chi^2(p) \tag{2}$$

и отвергаем H_0, если BP $> \chi^2_\alpha(p)$.

Знак $\overset{a}{\sim}$ означает, что распределение приближённое (точное лишь при $n \to \infty$). Деление на 2 нужно потому, что при H_0 и нормальных ошибках $\varepsilon_t^2/\sigma^2 \sim \chi^2(1)$, а у $\chi^2(1)$ дисперсия равна 2: без деления статистика была бы вдвое больше, чем $\chi^2(p)$.

4) *Тест Уайта.* Для модели с двумя регрессорами $y_t = \beta_1 + \beta_2 x_{2t} + \beta_3 x_{3t} + \varepsilon_t$ оцениваем вспомогательную регрессию квадратов остатков на регрессоры, их квадраты и произведение:

$$e_t^2 = a_0 + a_1 x_{2t} + a_2 x_{3t} + a_3 x_{2t}^2 + a_4 x_{3t}^2 + a_5 x_{2t} x_{3t} + v_t, \qquad H_0\colon a_1 = \dots = a_5 = 0,$$

и вычисляем

$$W = nR^2_{\text{aux}} \overset{a}{\sim} \chi^2(p), \qquad R^2_{\text{aux}} = 1 - \frac{\sum_t \widehat{v}_t^2}{\sum_t \left(e_t^2 - \overline{e^2}\right)^2}, \tag{3}$$

где R^2_{aux} — коэффициент детерминации *вспомогательной* регрессии (доля разброса e_t^2, объяснённая её регрессорами), $\widehat{v}_t$ — её остатки, $\overline{e^2}$ — среднее e_t^2, p — число её регрессоров без константы (здесь $p = 5$; в парной регрессии остаются x_t и x_t^2, $p = 2$). H_0 отвергаем, если $W > \chi^2_\alpha(p)$. Квадраты и произведения приближают любую гладкую зависимость σ_t^2 от регрессоров, поэтому форму гетероскедастичности знать не нужно; цена — много степеней свободы и меньшая мощность при малом n. Если вместо них взять те же z_t, что в тесте Бройша–Пагана, получится его вариант Кёнкера $nR^2_{\text{aux}} \overset{a}{\sim} \chi^2(p)$, не требующий нормальности ошибок.

5) *Тест Глейзера* — ищет форму зависимости σ_t от x_t. Для нескольких значений показателя γ (например, $1/2$, 1, 2) оцениваем регрессию

$$|e_t| = a_0 + a_1 x_t^\gamma + v_t, \qquad H_0\colon a_1 = 0, \qquad t = \frac{\widehat{a}_1}{s_{\widehat{a}_1}} \overset{a}{\sim} t(n-2),$$

где $\widehat{a}_1$ — оценка наклона, $s_{\widehat{a}_1}$ — её стандартная ошибка. Значимый положительный наклон означает, что разброс ошибок растёт с x_t. Лучше всего подогнанная форма подсказывает веса для взвешенного МНК: например, если лучше всех подходит $\gamma = 1$, то $\sigma_t \propto x_t$ и веса равны $1/x_t$.

6) *Ранговая корреляция Спирмена* между $|e_t|$ и x_t:

$$r_S = 1 - \frac{6\sum d_t^2}{n(n^2-1)}, \qquad t = \frac{r_S\sqrt{n-2}}{\sqrt{1-r_S^2}} \overset{a}{\sim} t(n-2), \tag{4}$$

где d_t — разность рангов $|e_t|$ и x_t в наблюдении t (ранг — номер значения в ряду, упорядоченном по возрастанию). При совпадающих значениях им дают средний ранг, и r_S считают как обычный коэффициент корреляции двух столбцов рангов. Значимая положительная r_S означает, что разброс растёт с x_t.

Коррекция: взвешенный МНК. Пусть дисперсия известна с точностью до множителя: $\sigma_t^2 = \sigma^2 z_t^2$, где $z_t > 0$ — известная величина (например, $z_t = x_t$). Делим уравнение на z_t:

$$\frac{y_t}{z_t} = \alpha\frac{1}{z_t} + \beta\frac{x_t}{z_t} + \frac{\varepsilon_t}{z_t}, \qquad \mathbb{D}\Big(\frac{\varepsilon_t}{z_t}\Big) = \frac{\mathbb{D}(\varepsilon_t)}{z_t^2} = \sigma^2. \tag{5}$$

Ошибка нового уравнения гомоскедастична, поэтому его оценивают обычным МНК. Свободного члена в нём нет: α стоит при $1/z_t$. При $z_t = x_t$ получается $y_t/x_t = \alpha/x_t + \beta + \varepsilon_t/x_t$, и уже β играет роль свободного члена. Деление на z_t означает, что в сумме квадратов наблюдение получает вес $1/z_t^2$: чем больше разброс, тем меньше вес. Если z_t неизвестно, его сначала оценивают по остаткам (*доступный* обобщённый МНК, задача 6.5).

1.2. Автокорреляция ошибок

Автокорреляция — ошибки разных наблюдений коррелированы; обычно встречается во временных рядах, где t — время. Простейшая модель — автокорреляция первого порядка AR(1):

$$\varepsilon_t = \rho\varepsilon_{t-1} + \eta_t, \qquad |\rho| < 1,$$

где ρ — коэффициент автокорреляции (корреляция соседних ошибок), а η_t — независимые случайные величины $N(0, \sigma_\eta^2)$, «новая» часть ошибки в момент t (её называют инновацией). При $\rho > 0$ соседние ошибки обычно одного знака, при $\rho = 0$ автокорреляции нет. Последствия те же, что при гетероскедастичности: оценки МНК несмещённые, но неэффективные, а обычные стандартные ошибки неверны.

Статистика Дарбина–Уотсона:

$$\mathrm{DW} = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \approx 2(1 - \widehat{\rho}), \qquad \widehat{\rho} = \frac{\sum_{t=2}^n e_t e_{t-1}}{\sum_{t=2}^n e_{t-1}^2}, \tag{6}$$

где e_t — остатки МНК, взятые в исходном временном порядке, $\widehat{\rho}$ — оценка ρ по ним. Если соседние остатки похожи ($\rho > 0$), разности $e_t - e_{t-1}$ малы и DW близка к 0; при $\rho = 0$ DW ≈ 2; при $\rho < 0$ DW близка к 4. Гипотезу $H_0\colon \rho = 0$ против $H_1\colon \rho > 0$ проверяют по табличным границам $d_L < d_U$, которые зависят от n и числа регрессоров:

$\mathrm{DW} < d_L$	$d_L \le \mathrm{DW} \le d_U$	$\mathrm{DW} > d_U$
отвергаем H_0	вывода нет	не отвергаем H_0

Таблицы DW применимы к регрессии с константой, в которой среди регрессоров нет лагированной зависимой переменной y_{t-1}.

Коррекция: процедура Кохрейна–Оркатта. Если ρ известно, вычтем из уравнения $y_t = \beta_1 + \beta_2 x_t + \varepsilon_t$ то же уравнение для момента $t-1$, умноженное на ρ:

$$y_t - \rho y_{t-1} = \beta_1(1-\rho) + \beta_2(x_t - \rho x_{t-1}) + \eta_t, \qquad t = 2, \dots, n. \tag{7}$$

Величины $y_t - \rho y_{t-1}$ и $x_t - \rho x_{t-1}$ называют *квазиразностями*. Ошибка η_t уже не автокоррелирована, поэтому уравнение оценивают обычным МНК с константой; первое наблюдение теряется. Константа этого уравнения равна $\beta_1(1-\rho)$, поэтому $\widehat{\beta}_1$ получают делением её оценки на $1-\rho$, а наклон сразу даёт $\widehat{\beta}_2$. На практике ρ неизвестно, и шаги повторяют: 1) МНК исходного уравнения и остатки e_t; 2) $\widehat{\rho}$ по (6); 3) МНК для квазиразностей с $\widehat{\rho}$, оценки $\widehat{\beta}_1$, $\widehat{\beta}_2$; 4) новые остатки *исходного* уравнения $e_t = y_t - \widehat{\beta}_1 - \widehat{\beta}_2 x_t$ и возврат к шагу 2 — пока $\widehat{\rho}$ не перестанет меняться.

2. Задачи

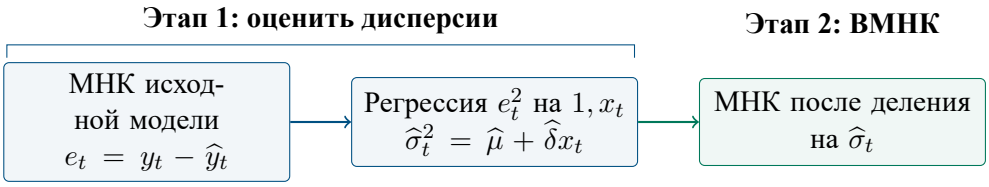
Задача 6.5

Предположим, что для системы $y_t = \alpha + \beta x_t + \varepsilon_t$, $t = 1, \ldots, n$, выполнены все предположения классической нормальной модели, за одним исключением: дисперсии ошибок удовлетворяют соотношениям

$$\sigma_t^2 = \mu + \delta x_t.$$

Предложите двухшаговую процедуру оценивания параметров α и β.

Решение. **Что не так и что хотим получить.** Дисперсия ошибки меняется с x_t, поэтому обычный МНК для исходного уравнения даёт несмещённые, но неэффективные оценки, а его стандартные ошибки неверны. Если бы мы знали стандартные отклонения ошибок σ_t, то разделили бы уравнение на σ_t по (5) (с $z_t = \sigma_t$): у новой ошибки ε_t/σ_t дисперсия равна $\sigma_t^2/\sigma_t^2 = 1$ для всех t, и обычный МНК снова оптимален. Но σ_t неизвестны. Зато известна *форма* дисперсии: $\sigma_t^2 = \mu + \delta x_t$ — она зависит всего от двух неизвестных чисел μ и δ. Отсюда план из двух этапов: **1)** оценить μ и δ и по ним — каждое σ_t; **2)** разделить уравнение на оценённые $\widehat{\sigma}_t$ и применить МНК.



Два этапа включают три регрессии. Во втором этапе вес наблюдения равен $1/\widehat{\sigma}_t^2$; делитель — $\widehat{\sigma}_t$.

Этап 1. Оцениваем дисперсии ошибок.

а) Обычный МНК исходного уравнения. Оцениваем $y_t = \alpha + \beta x_t + \varepsilon_t$ и считаем остатки

$$e_t = y_t - \widetilde{\alpha} - \widetilde{\beta} x_t,$$

где $\widetilde{\alpha}$, $\widetilde{\beta}$ — оценки обычного МНК (тильда отличает их от итоговых оценок этапа 2). Эти оценки несмещённые и при гетероскедастичности, поэтому остатки e_t близки к ненаблюдаемым ошибкам ε_t.

б) Почему квадраты остатков можно регрессировать на x_t. Так как $\mathbb{E}\varepsilon_t = 0$, математическое ожидание квадрата ошибки равно её дисперсии: $\mathbb{E}\varepsilon_t^2 = \mathbb{D}(\varepsilon_t) = \sigma_t^2 = \mu + \delta x_t$. Значит, квадрат ошибки можно записать как

$$\varepsilon_t^2 = \mu + \delta x_t + v_t, \qquad v_t = \varepsilon_t^2 - \sigma_t^2, \quad \mathbb{E}v_t = 0,$$

где v_t — случайное отклонение квадрата ошибки от его среднего. Это обычная линейная регрессия: зависимая переменная ε_t^2, регрессор x_t, параметры μ и δ. Ошибки ε_t мы не видим, поэтому подставляем вместо них остатки из п. а).

в) Вспомогательная регрессия. Оцениваем МНК

$$e_t^2 = \mu + \delta x_t + v_t$$

и получаем $\widehat{\mu}$, $\widehat{\delta}$. Отдельный e_t^2 — очень шумная оценка своей дисперсии, но регрессия по всем n наблюдениям усредняет этот шум и оценивает общую закономерность $\mu + \delta x_t$.

г) Оценки дисперсий и стандартных отклонений. Для каждого наблюдения подставляем x_t в оценённую формулу:

$$\widehat{\sigma}_t^2 = \widehat{\mu} + \widehat{\delta} x_t, \qquad \widehat{\sigma}_t = \sqrt{\widehat{\mu} + \widehat{\delta} x_t}.$$

Перед этапом 2 проверяем, что все $\widehat{\sigma}_t^2 > 0$: иначе корень не извлечь и делить не на что.

Этап 2. Взвешенный МНК. Делим исходное уравнение на $\widehat{\sigma}_t$:

$$\underbrace{\frac{y_t}{\widehat{\sigma}_t}}_{y_t^*} = \alpha \underbrace{\frac{1}{\widehat{\sigma}_t}}_{w_{1t}} + \beta \underbrace{\frac{x_t}{\widehat{\sigma}_t}}_{w_{2t}} + \underbrace{\frac{\varepsilon_t}{\widehat{\sigma}_t}}_{\varepsilon_t^*}, \qquad \mathbb{D}(\varepsilon_t^*) = \frac{\sigma_t^2}{\widehat{\sigma}_t^2} \approx 1.$$

Здесь y_t^*, w_{1t}, w_{2t} — новые переменные, которые считаются по данным, ε_t^* — новая ошибка. Её дисперсия приблизительно постоянна (ровно 1 была бы при точно известных σ_t). Оцениваем обычным МНК регрессию y_t^* на w_{1t} и w_{2t} *без свободного члена*: столбец единиц исходной модели после деления превратился в w_{1t}, и его коэффициент — это α. Полученные коэффициенты при w_{1t} и w_{2t} — и есть искомые оценки $\widehat{\alpha}$ и $\widehat{\beta}$ исходной модели; пересчитывать их обратно не нужно.

Что делает деление. Наблюдения с большим разбросом получают меньший вес. Например, пусть $\widehat{\mu} = 1$, $\widehat{\delta} = 0{,}5$:

x_t	$\widehat{\sigma}_t^2 = 1 + 0{,}5x_t$	$\widehat{\sigma}_t$	вес в сумме квадратов $1/\widehat{\sigma}_t^2$
2	2	1,41	0,50
8	5	2,24	0,20

Наблюдение с $x_t = 8$ более шумное, поэтому влияет на оценки в 2,5 раза слабее, чем наблюдение с $x_t = 2$. Обычный МНК дал бы им одинаковый вес.

Итог: три регрессии.

	Зависимая переменная	Регрессоры	Результат
1	y_t	константа, x_t	остатки e_t
2	e_t^2	константа, x_t	$\widehat{\mu}$, $\widehat{\delta} \Rightarrow \widehat{\sigma}_t$
3	$y_t/\widehat{\sigma}_t$	$1/\widehat{\sigma}_t$, $x_t/\widehat{\sigma}_t$ (без константы)	$\widehat{\alpha}$, $\widehat{\beta}$

Регрессии 1–2 — этап 1, регрессия 3 — этап 2. Оценки $\widehat{\alpha}$, $\widehat{\beta}$ состоятельны и при большом n эффективнее обычного МНК, а стандартные ошибки регрессии 3 приближённо верны.

Задача 6.6

Рассмотрим модель, связывающую количество вакансий w_t и уровень безработицы u_t:

$$\ln w_t = \beta_1 + \beta_2 \ln u_t + \varepsilon_t.$$

Ошибки ε_t независимы и нормально распределены $N(0, \sigma_\varepsilon^2)$.

а) Используя (искусственные) данные из таблицы, найдите МНК-оценки параметров β_1 и β_2, а также 95 %-ный доверительный интервал для β_2.

б) Вычислите статистику Дарбина–Уотсона. Что её значение говорит об исходном предположении об ошибках ε_t? Что можно сказать о доверительном интервале, найденном в п. а)?

в) Оцените модель заново, используя модель автокорреляции первого порядка для ошибок регрессии. Найдите 95 %-ный доверительный интервал для β_2. Сравните результат с интервалом, полученным в п. а).

t	w_t	u_t	t	w_t	u_t	t	w_t	u_t
1	1,73	8,65	9	5,06	2,87	17	3,15	4,72
2	1,94	4,82	10	2,81	5,29	18	1,92	7,45
3	3,05	2,67	11	4,43	3,31	19	2,26	6,21
4	4,17	2,67	12	3,19	5,44	20	6,18	2,64
5	2,52	2,58	13	2,23	6,80	21	2,07	8,55
6	1,71	8,07	14	2,06	8,25	22	8,39	2,60
7	1,95	8,83	15	3,33	3,44	23	2,75	6,25
8	2,57	5,54	16	2,12	7,80	24	6,10	2,70

В Excel. Добавьте столбцы `=LN(w)` и `=LN(u)` и оцените регрессию Анализ данных → Регрессия (галочка Остатки). DW по остаткам $e_1, \ldots, e_{24}$: `=СУММКВРАЗН(`e_2:e_{24}`;` e_1:e_{23}`)/СУММКВ(`e_1:e_{24}`)`. Для п. в) — столбцы $y_t - \widehat{\rho} y_{t-1}$ и $x_t - \widehat{\rho} x_{t-1}$ и регрессия первого на второй с константой. Это один шаг коррекции; для следующего шага пересчитайте остатки исходного уравнения.

Решение. Обозначим $y_t = \ln w_t$, $x_t = \ln u_t$; $n = 24$. Данные — временной ряд: статистика DW сравнивает соседние по времени остатки, поэтому наблюдения не сортируем. План: оценить модель и интервал (п. а), проверить, независимы ли ошибки (п. б), и пересчитать оценки и интервал с учётом автокорреляции (п. в).

а) МНК.

Переменная	Коэффициент	Ст. ошибка	t-статистика	P-значение
const	2,2997	0,1860	12,366	$< 0{,}0001$
$\ln u$	−0,7791	0,1133	−6,875	$< 0{,}0001$
$R^2 = 0{,}6824$; ESS $= 1{,}4119$; DW $= 1{,}1026$				

$\widehat{\beta}_1 = 2{,}30$, $\widehat{\beta}_2 = -0{,}78$: рост безработицы на 1 % сопровождается в среднем снижением числа вакансий на 0,78 %. Доверительный интервал по обычной формуле:

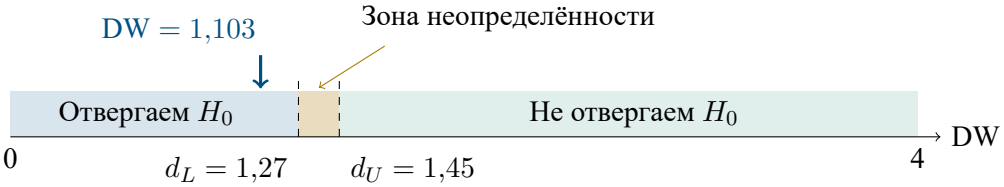
$$\widehat{\beta}_2 \pm t_{0{,}025}(n-2)\, s_{\widehat{\beta}_2} = -0{,}7791 \pm 2{,}074 \cdot 0{,}1133 = (-1{,}014;\ -0{,}544),$$

где $s_{\widehat{\beta}_2} = 0{,}1133$ — стандартная ошибка наклона из таблицы, $t_{0{,}025}(22) = 2{,}074$ — критическое значение при $n - 2 = 22$ степенях свободы.

б) Статистика Дарбина–Уотсона. По остаткам e_t (6):

$$\mathrm{DW} = \frac{\sum_{t=2}^{24}(e_t - e_{t-1})^2}{\sum_{t=1}^{24} e_t^2} = \frac{1{,}5568}{1{,}4119} = 1{,}103, \qquad \widehat{\rho} \approx 1 - \frac{\mathrm{DW}}{2} = 0{,}45,$$

где оценка $\widehat{\rho}$ получена из приближения $\mathrm{DW} \approx 2(1-\widehat{\rho})$ в (6). По таблице DW для $n = 24$ и одного регрессора на уровне 5 % $d_L = 1{,}27$, $d_U = 1{,}45$. $\mathrm{DW} = 1{,}10 < d_L$, поэтому гипотеза об отсутствии автокорреляции отвергается: есть положительная автокорреляция первого порядка. Значит, исходное предположение о *независимости* ошибок нарушено. Оценки МНК остаются несмещёнными, но стандартные ошибки из п. а) посчитаны по формулам, верным только для независимых ошибок, и поэтому ненадёжны. Следовательно, интервал из п. а) тоже ненадёжен: его настоящий уровень доверия может заметно отличаться от 95 %.



Задача 6.6: $H_0 : \rho = 0$ против $H_1 : \rho > 0$, уровень 5 %. Наблюдаемая статистика попадает в область отвержения. Правая область относится только к этой односторонней проверке.

в) Оценка с учётом AR(1). В п. б) выяснилось, что соседние ошибки связаны. Опишем эту связь моделью AR(1):

$$\varepsilon_t = \rho\varepsilon_{t-1} + \eta_t,$$

где ρ — коэффициент автокорреляции ($|\rho| < 1$), η_t — независимые ошибки с постоянной дисперсией. Идея: преобразовать уравнение так, чтобы в нём осталась только ошибка η_t. Тогда предпосылки МНК выполнены, и обычные стандартные ошибки и интервал снова верны.

Шаг 1. Преобразование (пока считаем ρ известным). Запишем модель для моментов t и $t-1$, второе уравнение умножим на ρ:

$$y_t = \beta_1 + \beta_2 x_t + \varepsilon_t, \qquad \rho y_{t-1} = \rho\beta_1 + \rho\beta_2 x_{t-1} + \rho\varepsilon_{t-1}.$$

Вычтем второе из первого. Ошибка становится $\varepsilon_t - \rho\varepsilon_{t-1} = \eta_t$, и получаем модель в квазиразностях (7):

$$\underbrace{y_t - \rho y_{t-1}}_{y_t^*} = \underbrace{\beta_1(1-\rho)}_{\beta_1^*} + \beta_2 \underbrace{(x_t - \rho x_{t-1})}_{x_t^*} + \eta_t, \qquad t = 2, \ldots, 24,$$

где y_t^*, x_t^* — новые переменные, β_1^* — свободный член нового уравнения. Это обычная регрессия y_t^* на x_t^* с константой. Её наклон — это сразу β_2, а β_1 находится из константы:

$\beta_1 = \beta_1^*/(1-\rho)$. Наблюдение $t=1$ теряется: для него нет y_0 и x_0, поэтому остаётся 23 наблюдения.

Шаг 2. Оценка ρ. На деле ρ неизвестно. Уравнение $\varepsilon_t = \rho\varepsilon_{t-1} + \eta_t$ — регрессия ε_t на ε_{t-1} без константы. Заменяем ошибки остатками e_t из п. а) и получаем МНК-оценку (6):

$$\widehat{\rho} = \frac{\sum_{t=2}^{24} e_t e_{t-1}}{\sum_{t=2}^{24} e_{t-1}^2} = \frac{0{,}5911}{1{,}3321} = 0{,}4437.$$

Это близко к грубой оценке $1 - \mathrm{DW}/2 = 0{,}45$ из п. б).

Шаг 3. МНК для квазиразностей с $\widehat{\rho} = 0{,}4437$. Для каждого $t = 2, \ldots, 24$ считаем новые переменные, например для $t=2$:

$$y_2^* = y_2 - 0{,}4437\, y_1 = 0{,}6627 - 0{,}4437 \cdot 0{,}5481 = 0{,}4195,$$
$$x_2^* = x_2 - 0{,}4437\, x_1 = 1{,}5728 - 0{,}4437 \cdot 2{,}1576 = 0{,}6154.$$

Регрессия y_t^* на x_t^* по 23 наблюдениям даёт $\widehat{\beta}_1^* = 1{,}3302$ и $\widehat{\beta}_2 = -0{,}8296$, откуда $\widehat{\beta}_1 = 1{,}3302/(1-0{,}4437) = 2{,}3913$.

Шаг 4. Итерации Кохрейна–Оркатта. Оценка $\widehat{\rho}$ из шага 2 построена по остаткам обычного МНК, который автокорреляцию не учитывал. Теперь у нас есть уточнённые $\widehat{\beta}_1$, $\widehat{\beta}_2$. По ним считаем новые остатки *исходного* уравнения $e_t = y_t - \widehat{\beta}_1 - \widehat{\beta}_2 x_t$, заново оцениваем $\widehat{\rho}$ (шаг 2) и повторяем шаг 3. Останавливаемся, когда $\widehat{\rho}$ перестаёт меняться:

Итерация	$\widehat{\rho}$	$\widehat{\beta}_1^*$	$\widehat{\beta}_1 = \widehat{\beta}_1^*/(1-\widehat{\rho})$	$\widehat{\beta}_2$
1	0,4437	1,3302	2,3913	$-0{,}8296$
2	0,4668	1,2768	2,3948	$-0{,}8312$
3	0,4675	1,2752	2,3949	$-0{,}8312$
4	0,4676	1,2751	2,3949	$-0{,}8312$

Шаг 5. Итоговые оценки. Последняя регрессия: $y_t - 0{,}4676 y_{t-1}$ на $x_t - 0{,}4676 x_{t-1}$. Её константа $\widehat{\beta}_1^* = 1{,}2751$ со стандартной ошибкой $0{,}0889$. Оба числа делим на $1-\widehat{\rho} = 0{,}5324$, чтобы вернуться к β_1: $\widehat{\beta}_1 = 2{,}3949$, $s_{\widehat{\beta}_1} = 0{,}0889/0{,}5324 = 0{,}1669$. Наклон и его ошибка пересчёта не требуют. Стандартные ошибки посчитаны так, будто $\widehat{\rho}$ известно точно:

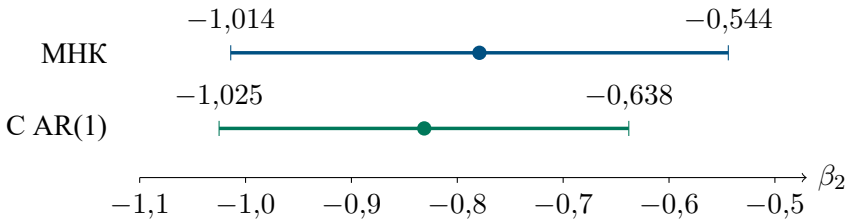
Переменная	Коэффициент	Ст. ошибка	t-статистика	P-значение
const	2,3949	0,1669	14,349	$< 0{,}0001$
$\ln u$	$-0{,}8312$	0,0930	$-8{,}939$	$< 0{,}0001$
$\widehat{\rho} = 0{,}4676$; DW $= 2{,}1617$				

Шаг 6. Интервал. Приближённый интервал для β_2 по конечной регрессии (23 наблюдения, константа и наклон: $23 - 2 = 21$ степень свободы, $t_{0{,}025}(21) = 2{,}080$):

$$-0{,}8312 \pm 2{,}080 \cdot 0{,}0930 = (-1{,}025;\ -0{,}638).$$

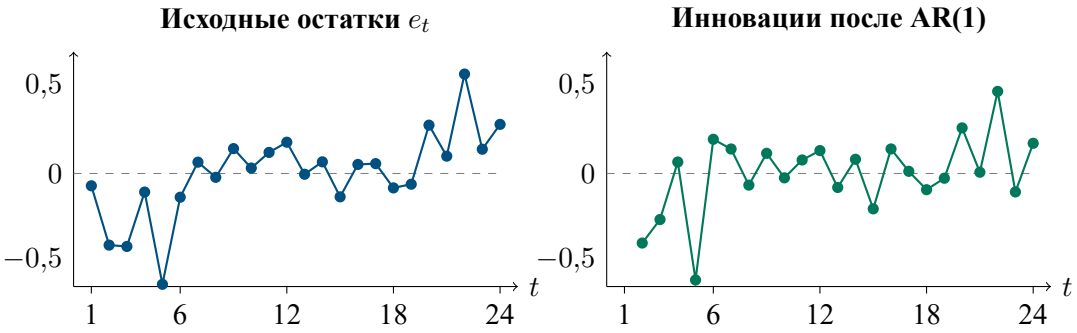
Это приближение: дополнительная неопределённость оценки ρ в обычной формуле стандартной ошибки последнего шага не учитывается.

Сравнение.



Точки — оценки β_2, отрезки — 95 %-ные интервалы. Интервал МНК построен при нарушенной предпосылке независимости; интервал с AR(1) — приближённый.

Оценка наклона изменилась мало ($-0{,}83$ против $-0{,}78$): рост безработицы на 1 % связан со снижением числа вакансий примерно на 0,83 %. Интервал с учётом AR(1) уже (длина 0,39 против 0,47). Но это не доказывает, что точность выросла: интервал из п. а) построен при нарушенной предпосылке, и его ширине нельзя доверять. Второй интервал верен приближённо и только если ошибки действительно следуют AR(1). Проверка: у остатков последней регрессии $\widehat{\eta}_t$ статистика DW $= 2{,}16$, близко к 2, — автокорреляции первого порядка в них не видно (графики ниже).



Данные задачи 6.6, одинаковый масштаб по вертикали. Слева DW $= 1{,}103$, справа $2{,}162$. Справа показаны $\widehat{\eta}_t = \widehat{\varepsilon}_t - \widehat{\rho}\widehat{\varepsilon}_{t-1}$, поэтому ряд начинается с $t = 2$. График дополняет диагностику, но не доказывает независимость.

Задача 6.7

В таблице представлены данные о потребительских расходах C и располагаемом доходе Y_d тридцати семей (долл.): для каждого уровня дохода — расходы трёх семей.

Потребление C			Доход Y_d
10700	10900	11200	12000
11400	11700	12100	13000
12300	12600	13200	14000
13000	13300	13600	15000
13800	14000	14200	16000
14400	14900	15300	17000
15000	15700	16400	18000
15900	16500	16900	19000
16900	17500	18100	20000
17200	17800	18500	21000

а) Проведите регрессию C на Y_d и проверьте наличие или отсутствие гетероскедастичности.

б) Если в п. а) выявлена гетероскедастичность, осуществите коррекцию на гетероскедастичность.

В Excel. Данные — в «Семинар 6 (приложение).xlsx» (30 строк: Y, C). Регрессия — Анализ данных → Регрессия с галочкой Остатки. Для тестов добавьте столбцы e^2, $|e|$, Y^2; Голдфелд–Квандт — две регрессии по строкам 1–12 и 19–30 (данные уже упорядочены по Y); ранги — `=РАНГ.СР(…)`. Для взвешенного МНК — столбцы C/Y и $1/Y$ и регрессия C/Y на $1/Y$ *с константой*. Тридцать семей — тридцать строк: каждый доход повторяется трижды; усреднять потребление по тройкам нельзя.

Решение. Обозначим доход Y ($= Y_d$); $n = 30$.

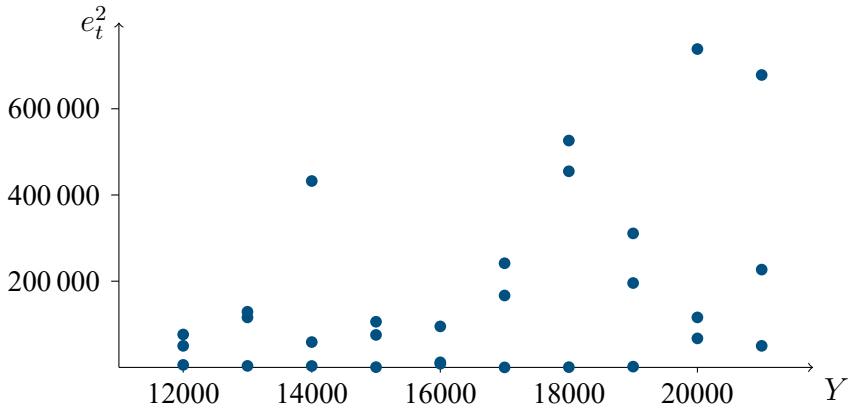
а) Регрессия $C_t = \alpha + \beta Y_t + \varepsilon_t$:

Переменная	Коэффициент	Ст. ошибка	t-статистика	P-значение
const	1580,0	447,56	3,530	0,0015
Y	0,7830	0,0267	29,30	$< 0{,}0001$
$R^2 = 0{,}9684$; ESS $= 4\,948\,727$				

Оценённая модель: $\widehat{C}_t = 1580 + 0{,}78303 Y_t$. Дополнительный доллар дохода связан в среднем с 0,78 доллара потребления. Остатки этой модели используем во всех тестах ниже. Например, для первой семьи $\widehat{C}_1 = 10976{,}36$, $e_1 = 10700 - 10976{,}36 = -276{,}36$, $e_1^2 \approx 76377$. Стандартные ошибки в таблице верны, только если дисперсия ошибок

постоянна; высокий R^2 этого не гарантирует. Поэтому сначала проверяем гетероскедастичность.

Проверка на гетероскедастичность.
1) График. Квадраты остатков против дохода:



С ростом дохода разброс остатков увеличивается: большие e_t^2 встречаются в основном при высоком доходе.

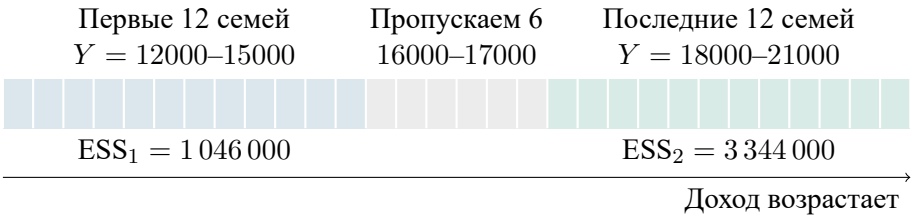
График наводит на мысль о гетероскедастичности: дисперсия ошибок растёт с доходом. Проверим это формально.

2) Тест Голдфелда–Квандта. Наблюдения уже упорядочены по возрастанию Y. Выбрасываем $c = 6$ средних семей (доход 16 000 и 17 000), остаются $30 - 6 = 24$ семьи, по $m = 12$ в группе. Оцениваем регрессию C на Y отдельно по первым 12 и по последним 12 семьям и берём их остаточные суммы квадратов: $\text{ESS}_1 = 1\,046\,000$, $\text{ESS}_2 = 3\,344\,000$. В каждой регрессии $k = 2$ параметра (константа и наклон), поэтому $m - k = 10$ степеней свободы. По (1)

$$F = \frac{\text{ESS}_2/(m-k)}{\text{ESS}_1/(m-k)} = \frac{\text{ESS}_2/10}{\text{ESS}_1/10},$$

$$F = \frac{3\,344\,000/10}{1\,046\,000/10} = 3{,}20 > 2{,}98 = F_{0{,}05}(10, 10), \qquad P = 0{,}040.$$

Гипотеза гомоскедастичности отвергается: в группе с высоким доходом оценка дисперсии ошибок примерно в 3,2 раза выше. Средние шесть семей исключаем только для этого теста; остальные расчёты используют все 30 наблюдений.



Каждая ячейка — одна семья. Оцениваем две отдельные регрессии C на Y с константой; сравниваем $\text{ESS}_2/10$ и $\text{ESS}_1/10$.

3) Тест Бройша–Пагана. Идём по шагам из теории; дисперсия может зависеть от дохода, поэтому $z_t = Y_t$ и $p = 1$.

а) Остатки e_t исходной модели уже есть (п. а).

б) $\widehat{\sigma}^2 = \text{ESS}/n = 4\,948\,727/30 = 164\,958$ (делим на $n = 30$, а не на $n - k = 28$).

в) $g_t = e_t^2/164\,958$; например, для первой семьи $g_1 = 76\,377/164\,958 = 0{,}463$.

г) Регрессия $g_t = a_0 + a_1 Y_t + v_t$; её объяснённая сумма квадратов (в Excel — строка «Регрессия» таблицы дисперсионного анализа) $\mathrm{RSS}_{\text{aux}} = 8{,}22$.

д) По (2)

$$\text{BP} = \frac{\mathrm{RSS}_{\text{aux}}}{2} = \frac{8{,}22}{2} = 4{,}11 > 3{,}84 = \chi^2_{0{,}05}(1), \qquad P = 0{,}043.$$

Гомоскедастичность снова отвергается. Вариант Кёнкера, не требующий нормальности ошибок: R^2 той же вспомогательной регрессии равен $0{,}183$, и $\text{BP}_K = nR^2_{\text{aux}} = 30 \cdot 0{,}183 = 5{,}49 > 3{,}84$, $P = 0{,}019$ — вывод тот же.

4) Тест Уайта. Регрессор в модели один, поэтому произведений нет, и вспомогательная регрессия содержит Y_t и Y_t^2:

$$e_t^2 = a_0 + a_1 Y_t + a_2 Y_t^2 + v_t, \qquad H_0\colon a_1 = a_2 = 0.$$

Её коэффициент детерминации $R^2_{\text{aux}} = 0{,}194$; проверяемых коэффициентов два, поэтому $p = 2$. По (3)

$$W = nR^2_{\text{aux}} = 30 \cdot 0{,}194 = 5{,}82 < 5{,}99 = \chi^2_{0{,}05}(2), \qquad P = 0{,}055.$$

На выбранном заранее уровне 5 % H_0 не отвергаем (на 10 % отвергли бы). Расхождение с тестом Бройша–Пагана объяснимо: у Уайта проверяются два коэффициента вместо одного, а лишняя степень свободы при $n = 30$ снижает мощность теста.

5) Тест Глейзера. Модуль остатка $|e_t|$ показывает, насколько семья отклонилась от линии регрессии, и поэтому служит грубой оценкой стандартного отклонения σ_t её ошибки. Например, у первой семьи $|e_1| = 276{,}36$. Если σ_t растёт с доходом, то и $|e_t|$ в среднем растут с Y_t. Это проверяют регрессией

$$|e_t| = a_0 + a_1 Y_t^{\gamma} + v_t,$$

где a_0, a_1 — параметры, v_t — ошибка, γ — показатель, который задаёт форму зависимости. Какая форма верна, заранее неизвестно, поэтому пробуем три: $\gamma = 1/2,\ 1,\ 2$ (σ_t растёт как $\sqrt{Y_t}$, Y_t или Y_t^2). Для каждой формы проверяем

$$H_0\colon a_1 = 0 \ (|e_t| \text{ не зависит от дохода}), \qquad t = \frac{\widehat{a}_1}{s_{\widehat{a}_1}},$$

где $s_{\widehat{a}_1}$ — стандартная ошибка наклона. H_0 отвергаем, если $|t| > t_{0{,}025}(28) = 2{,}048$; $28 = n - 2$ степеней свободы.

Расчёт для $\gamma = 1$. Регрессия $|e_t|$ на константу и Y_t даёт $\widehat{a}_0 = -228{,}8$, $\widehat{a}_1 = 0{,}03364$, $s_{\widehat{a}_1} = 0{,}01459$:

$$t = \frac{0{,}03364}{0{,}01459} = 2{,}305 > 2{,}048, \qquad P = 0{,}029.$$

Значит, H_0 отвергается. Наклон означает: при росте дохода на 1000 долл. средний модуль остатка растёт примерно на 34 долл., от 175 при $Y = 12\,000$ до 478 при $Y = 21\,000$.

Все три формы:

Регрессия	$\widehat{a}_1$	t наклона	P (прибл.)	R^2
$\lvert e_t\rvert$ на $\sqrt{Y_t}$	8,467	2,270	0,031	0,155
$\lvert e_t\rvert$ на Y_t	0,03364	2,305	0,029	0,159
$\lvert e_t\rvert$ на Y_t^2	$1{,}037 \cdot 10^{-6}$	2,361	0,025	0,166

Во всех трёх регрессиях $t > 2{,}048$, наклон положителен: разброс ошибок растёт с доходом. P-значения приближённые, потому что вместо ошибок ε_t использованы остатки e_t.

Выбрать одну форму по этим данным нельзя: R^2 почти одинаковы (0,155–0,166). На отрезке дохода от 12 000 до 21 000 величины $\sqrt{Y}$, Y и Y^2 почти линейно связаны друг с другом (попарные корреляции больше 0,99), поэтому три регрессии дают по сути один и тот же результат, а не три независимых доказательства. Для коррекции в п. б) берём самую простую форму $\sigma_t \propto Y_t$.

б) Ранговая корреляция Спирмена между $\lvert e_t\rvert$ и Y_t. Если разброс ошибок растёт с доходом, то семьи с бóльшим доходом в среднем имеют бóльшие $\lvert e_t\rvert$. Тест Спирмена проверяет это по рангам: форма зависимости не важна, важно только, растёт ли $\lvert e_t\rvert$ вместе с Y_t.

Шаг 1. Ранги дохода R_Y. Ранг — номер значения в ряду, упорядоченном по возрастанию. Каждый уровень дохода встречается трижды (в данных для каждого дохода приведены расходы трёх семей), и одинаковым значениям даём средний ранг занимаемых ими мест. Доход 12 000 занимает места 1, 2, 3, поэтому у всех трёх семей ранг $(1+2+3)/3 = 2$; доход 13 000 занимает места 4–6 и получает ранг 5; и так далее до 21 000 с рангом 29.

Шаг 2. Ранги модулей остатков $R_{|e|}$. Упорядочиваем 30 значений $\lvert e_t\rvert$ по возрастанию и нумеруем места:

$\lvert e_t\rvert$	8,48	25,45	25,45	42,42	57,58	59,39	76,36	91,52	108,48	223,64	223,64	242,42	259,39	274,55	276,36
ранг	1	2,5	2,5	4	5	6	7	8	9	10,5	10,5	12	13	14	15
семья	17	11	20	23	8	5	2	15	14	3	29	7	26	12	1

$\lvert e_t\rvert$	308,48	325,45	340,61	340,61	359,39	408,48	442,42	476,36	491,52	557,58	657,58	674,55	725,45	823,64	859,39
ранг	16	17	18,5	18,5	20	21	22	23	24	25	26	27	28	29	30
семья	13	10	6	25	4	18	24	30	16	22	9	19	21	28	27

$\lvert e_t\rvert$ возрастает

30 значений $\lvert e_t\rvert$ по возрастанию (вторая строка рисунка — продолжение первой). Ранг — номер места; выделенные цветом ячейки — совпадающие значения, им дан средний ранг занимаемых мест.

Наименьший модуль $8{,}48$ (семья 17) получает ранг 1. Модуль $25{,}45$ встречается дважды (семьи 11 и 20); они занимают места 2 и 3 и получают ранг $(2+3)/2 = 2{,}5$. Так же совпадают $223{,}64$ (семьи 3 и 29, места 10–11, ранг 10,5) и $340{,}61$ (семьи 6 и 25, места 18–19, ранг 18,5).

Шаг 3. Разности рангов. Возвращаем семьи в порядок роста дохода и для каждой считаем $d_t = R_Y - R_{|e|}$:

доход	$Y=12\,000$ $R_Y=2$			$Y=13\,000$ $R_Y=5$			$Y=14\,000$ $R_Y=8$			$Y=15\,000$ $R_Y=11$			$Y=16\,000$ $R_Y=14$		
$R_{\|e\|}$	15	7	10,5	20	6	18,5	12	5	26	17	2,5	14	16	9	8
d_t	−13	−5	−8,5	−15	−1	−13,5	−4	3	−18	−6	8,5	−3	−2	5	6
семья	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15

доход	$Y=17\,000$ $R_Y=17$			$Y=18\,000$ $R_Y=20$			$Y=19\,000$ $R_Y=23$			$Y=20\,000$ $R_Y=26$			$Y=21\,000$ $R_Y=29$		
$R_{\|e\|}$	24	1	21	27	2,5	28	25	4	22	18,5	13	30	29	10,5	23
d_t	−7	16	−4	−7	17,5	−8	−2	19	1	7,5	13	−4	0	18,5	6
семья	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30

Семьи в порядке роста дохода (вторая строка — продолжение первой). Чем больше ранг $|e_t|$, тем темнее ячейка; $d_t = R_Y - R_{|e|}$, $\sum d_t^2 = 2931{,}5$. Тёмные ячейки чаще во второй строке, но не только там: связь положительная, но слабая.

Например, у семьи 1: $R_Y = 2$, $R_{|e|} = 15$, $d_1 = -13$, $d_1^2 = 169$.

Шаг 4. Коэффициент Спирмена. По (4)

$$r_S = 1 - \frac{6\sum d_t^2}{n(n^2-1)} = 1 - \frac{6 \cdot 2931{,}5}{30 \cdot 899} = 1 - 0{,}652 = 0{,}348.$$

Из-за совпадающих рангов эта формула приближённая. Точное значение — обычный коэффициент корреляции столбцов R_Y и $R_{|e|}$ (в Excel `=КОРРЕЛ(…)`): $r_S = 0{,}345$. Разница мала, дальше используем $0{,}345$. Знак положительный: при большем доходе модули остатков в среднем больше.

Шаг 5. Значимость. H_0: ранговой связи нет. По (4)

$$t = \frac{r_S\sqrt{n-2}}{\sqrt{1-r_S^2}} = \frac{0{,}345\sqrt{28}}{\sqrt{1-0{,}345^2}} = 1{,}94 < 2{,}048 = t_{0{,}025}(28), \qquad P \approx 0{,}062.$$

На уровне 5 % H_0 не отвергаем, на уровне 10 % отвергли бы.

Сводка диагностики при уровне 5 %.

Метод	P	Решение о нулевой гипотезе
Голдфелд–Квандт	0,040	Отвергаем
Бройш–Паган	0,043	Отвергаем
Уайт	0,055	Не отвергаем
Глейзер: $\|e\|$ на Y	0,029	Отвергаем нулевой наклон
Спирмен	$\approx 0{,}062$	Не отвергаем нулевую корреляцию

График, Голдфелд–Квандт, Бройш–Паган и Глейзер указывают на рост дисперсии с доходом. Уайт и Спирмен показывают ту же направленность, но значимы только на уровне 10 %. Неотвержение H_0 не доказывает гомоскедастичность: при $n = 30$ у этих тестов малая мощность. Вывод: гетероскедастичность есть, и её нужно учесть.

б) Коррекция: взвешенный МНК. Для взвешенного МНК нужна форма зависимости дисперсии от дохода. Её подсказывает тест Глейзера: $|e_t|$ — грубая мера стандартного отклонения ошибки, и регрессия $|e_t|$ на Y_t даёт значимый положительный наклон,

то есть масштаб ошибок растёт примерно пропорционально доходу. Поэтому в качестве рабочей модели примем $\sigma_t = \sigma Y_t$, где σ — неизвестная постоянная (так же сделано в сборнике), и по (5) с $z_t = Y_t$ разделим уравнение на Y_t:

$$\frac{C_t}{Y_t} = \alpha \frac{1}{Y_t} + \beta + \frac{\varepsilon_t}{Y_t}, \qquad \mathbb{D}\Big(\frac{\varepsilon_t}{Y_t}\Big) = \frac{\sigma^2 Y_t^2}{Y_t^2} = \sigma^2.$$

Ошибка нового уравнения гомоскедастична. В нём β стала свободным членом, а α — коэффициентом при $1/Y_t$. Поэтому оцениваем регрессию C_t/Y_t на $1/Y_t$ с константой:

Переменная	Коэффициент	Ст. ошибка	t-статистика	P-значение
$1/Y$ (α)	1557,0	392,28	3,969	0,0005
const (β)	0,7844	0,0249	31,46	$< 0{,}0001$
$R^2 = 0{,}360$ (для C/Y); $R^2 = 0{,}968$ для исходной переменной C				

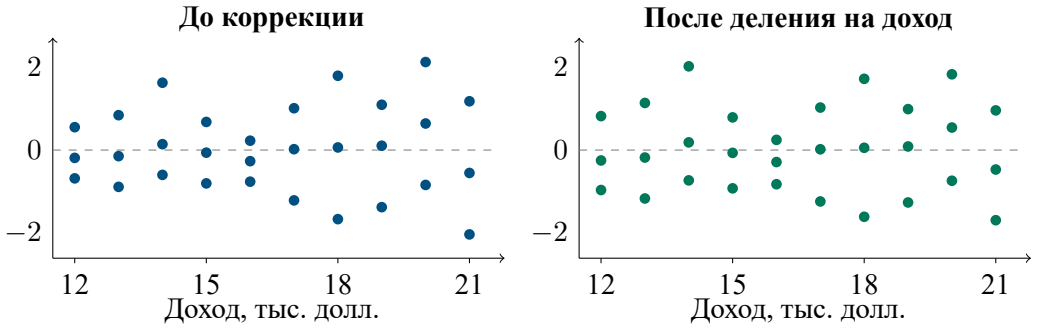
Подставляя оценки в исходное уравнение, получаем

$$\widehat{C} = 1557{,}0 + 0{,}7844\, Y.$$

Помогло ли деление? Возьмём остатки преобразованной модели $\widehat{v}_t = C_t/Y_t - \widehat{\alpha}/Y_t - \widehat{\beta}$ (а не остатки в долларах) и проведём для них тест Уайта: регрессия $\widehat{v}_t^2$ на константу, $1/Y_t$ и $1/Y_t^2$ даёт

$$nR^2_{\text{aux}} = 1{,}06 < 5{,}99 = \chi^2_{0{,}05}(2), \qquad P = 0{,}59.$$

Гомоскедастичность не отвергается: после деления на доход признаков непостоянной дисперсии не видно. Это согласуется с выбранной моделью $\sigma_t = \sigma Y_t$, хотя и не доказывает её.



Данные задачи 6.7: слева остатки МНК e_t, справа остатки ВМНК $\widehat{v}_t = (C_t - \widehat{\alpha} - \widehat{\beta} Y_t)/Y_t$. Чтобы ряды были в одном масштабе, каждый разделён на корень из среднего квадрата своих значений. Слева у 15 семей с высоким доходом разброс почти вдвое больше, чем у 15 семей с низким (1,24 против 0,69); справа разница заметно меньше (1,12 против 0,87).

Замечание. *Наклоны МНК и ВМНК близки (*$0{,}7830$ *и* $0{,}7844$*): обе оценки несмещённые, но в другой выборке они могли бы разойтись сильнее. Стандартные ошибки (*$0{,}0267$ *у МНК и* $0{,}0249$ *у ВМНК) напрямую сравнивать нельзя: первая неверна при гетероскедастичности, вторая верна, только если верна модель $\sigma_t = \sigma Y_t$. R^2 преобразованной модели (*$0{,}36$*) нельзя сравнивать с R^2 исходной (*$0{,}968$*): у них разные зависимые переменные (C/Y и C), поэтому снижение R^2 не означает, что модель стала хуже.*